



**ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ**  
**ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ**  
**ΤΕΧΝΟΛΟΓΙΑΣ ΥΠΟΛΟΓΙΣΤΩΝ**

**ΤΟΜΕΑΣ ΕΠΙΒΛΕΠΟΝΤΟΣ**  
**ΕΡΓΑΣΤΗΡΙΟ ΕΠΙΒΛΕΠΟΝΤΟΣ**

---

## **Θεματική ανάλυση ιστορικού αρχείου τονίμα του Πανεπιστημίου Πατρών**

**ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ**

**ΠΕΡΔΙΚΟΥΡΗΣ ΔΗΜΗΤΡΙΟΣ**

**ΕΠΙΒΛΕΠΩΝ: ΑΒΟΥΡΗΣ ΝΙΚΟΛΑΟΣ**

**ΠΑΤΡΑ - ΟΚΤΩΒΡΙΟΣ 2026**

Πανεπιστήμιο Πατρών, Τμήμα Ηλεκτρολόγων Μηχανικών και Τεχνολογίας Υπολογιστών.

ΠΕΡΔΙΚΟΥΡΗΣ ΔΗΜΗΤΡΙΟΣ

© 2026 – Με την επιφύλαξη παντός δικαιώματος

Το σύνολο της εργασίας αποτελεί πρωτότυπο έργο, παραχθέν από τον/την Περδικούρη Δημήτριο, και δεν παραβιάζει δικαιώματα τρίτων καθ' οιονδήποτε τρόπο. Αν η εργασία περιέχει υλικό, το οποίο δεν έχει παραχθεί από τον/την ίδιο/α, αυτό είναι ευδιάκριτο και αναφέρεται ρητώς εντός του κειμένου της εργασίας ως προϊόν εργασίας τρίτου, σημειώνοντας με παρομοίως σαφή τρόπο τα στοιχεία ταυτοποίησής του, ενώ παράλληλα βεβαιώνει πως στην περίπτωση χρήσης αυτούσιων γραφικών αναπαραστάσεων, εικόνων, γραφημάτων κ.λπ., έχει λάβει τη χωρίς περιορισμούς άδεια του κατόχου των πνευματικών δικαιωμάτων για την συμπερίληψη και επακόλουθη δημοσίευση του υλικού αυτού.

# ΠΙΣΤΟΠΟΙΗΣΗ

Πιστοποιείται ότι η Διπλωματική Εργασία με τίτλο

## **Θεματική ανάλυση ιστορικού αρχείου tonima του Πανεπιστημίου Πατρών**

του φοιτητή του Τμήματος Ηλεκτρολόγων Μηχανικών και Τεχνολογίας  
Υπολογιστών

**ΠΕΡΔΙΚΟΥΡΗ ΔΗΜΗΤΡΗ ΤΟΥ ΑΡΙΣΤΕΙΔΗ**

Αριθμός Μητρώου: UP1046824

Παρουσιάστηκε δημόσια στο Τμήμα Ηλεκτρολόγων Μηχανικών και  
Τεχνολογίας Υπολογιστών στις

12/10/2026

και εξετάστηκε από την ακόλουθη εξεταστική επιτροπή:

Νικόλαος Αβούρης, Ομότιμος Καθηγητής, ΤΗΜΤΥ (επιβλέπων)

Χρήστος Φείδας, Αναπληρωτής Καθηγητής, ΤΗΜΤΥ (μέλος επιτροπής)

Δασκαλάκη Σοφία, Επίκουρη Καθηγήτρια, ΤΗΜΤΥ (μέλος επιτροπής)

Ο Επιβλέπων

Ο Διευθυντής του Τομέα

Νικόλαος Αβούρης  
Ομότιμος Καθηγητής

Γεώργιος Θεοδωρίδης  
Αναπληρωτής Καθηγητής

# Περιεχόμενα

|                                                                         |    |
|-------------------------------------------------------------------------|----|
| Κεφάλαιο 1 – Εισαγωγή .....                                             | 6  |
| 1.1 Σκοπός και ερευνητικά ερωτήματα .....                               | 7  |
| 1.2 Συνεισφορά .....                                                    | 8  |
| 1.3 Δομή της διπλωματικής .....                                         | 8  |
| 1.4 Σχέση με υπάρχουσες προσεγγίσεις θεματικής μοντελοποίησης .....     | 8  |
| Κεφάλαιο 2 – Θεωρητικό Υπόβαθρο.....                                    | 10 |
| 2.1 Βασικές έννοιες μηχανικής μάθησης .....                             | 10 |
| 2.2 Παραδείγματα μάθησης .....                                          | 11 |
| 2.3 Τεχνητά νευρωνικά δίκτυα .....                                      | 11 |
| 2.4 Επεξεργασία φυσικής γλώσσας .....                                   | 12 |
| 2.5 Από τις καταμετρήσεις λέξεων στις κατανεμημένες αναπαραστάσεις..... | 13 |
| 2.6 Κωδικοποιητές transformer και ενσωματώσεις προτάσεων.....           | 14 |
| 2.7 Γεωμετρία υψηλών διαστάσεων και μείωση διαστάσεων .....             | 15 |
| 2.8 Παραδείγματα συσταδοποίησης .....                                   | 15 |
| 2.9 Αξιολόγηση ανεπίβλεπτης δομής.....                                  | 16 |
| 2.10 Μπεϋζιανή βελτιστοποίηση υπερπαραμέτρων .....                      | 17 |
| 2.11 Επεξεργασία φυσικής γλώσσας για τα Νέα Ελληνικά.....               | 17 |
| Κεφάλαιο 3 – Συλλογή και Έλεγχος Δεδομένων .....                        | 19 |
| 3.1 Συλλογή δεδομένων.....                                              | 19 |
| 3.2 Προέλευση δεδομένων και προστασία προσωπικών δεδομένων.....         | 19 |
| 3.3 Διερευνητική ανάλυση δεδομένων .....                                | 20 |
| 3.4 Σχήμα εισόδου χωρίς συλλογή από το διαδίκτυο .....                  | 21 |
| Κεφάλαιο 4 – Δομική Προεπεξεργασία .....                                | 22 |
| 4.1 Κανονικοποίηση του πεδίου παραληπτών .....                          | 22 |
| Κεφάλαιο 5 – Γλωσσική Προεπεξεργασία .....                              | 23 |
| 5.1 Δύο παράλληλες αναπαραστάσεις κειμένου .....                        | 23 |
| 5.2 Δομικός καθαρισμός κειμένου με μετρημένη κάλυψη.....                | 23 |
| 5.3 Λημματοποίηση και η διόρθωση των σύνθετων λημμάτων .....            | 24 |
| 5.4 Φιλτράρισμα stopwords για ελληνικά και αγγλικά .....                | 25 |
| 5.5 Κανονικοποίηση μοτίβων, θορυβώδεις μονάδες και όρια μήκους .....    | 25 |
| Κεφάλαιο 6 – Σηματολογικές Αναπαραστάσεις Εγγράφων.....                 | 27 |
| 6.1 Υπόβαθρο και μέτρο ομοιότητας .....                                 | 27 |
| 6.2 Πείραμα επιλογής μοντέλου .....                                     | 27 |
| 6.3 Παραγωγή των ενσωματώσεων.....                                      | 28 |
| Κεφάλαιο 7 – Συσταδοποίηση.....                                         | 29 |
| 7.1 Επισκόπηση .....                                                    | 29 |
| 7.2 Προ-μείωση με PCA .....                                             | 29 |
| 7.3 UMAP .....                                                          | 29 |
| 7.4 HDBSCAN.....                                                        | 30 |
| 7.5 Αντικειμενική συνάρτηση και αναζήτηση υπερπαραμέτρων .....          | 30 |
| 7.6 Μετεπεξεργασία .....                                                | 32 |
| 7.6.1 Συγχώνευση σχεδόν όμοιων συστάδων .....                           | 32 |
| 7.6.2 Συντηρητική επανατοποθέτηση θορύβου .....                         | 32 |

|                                                                         |    |
|-------------------------------------------------------------------------|----|
| 7.7 Απεικόνιση διανυσμάτων και συστάδων .....                           | 33 |
| Κεφάλαιο 8 – Χαρακτηρισμός Συστάδων και Θεματική Ταξινόμια .....        | 37 |
| 8.1 Εξαγωγή όρων με TF-IDF .....                                        | 37 |
| 8.2 Θεματική ταξινόμια .....                                            | 38 |
| Κεφάλαιο 9 – Επικύρωση .....                                            | 39 |
| 9.1 Σύγκριση με μεθόδους αναφοράς .....                                 | 39 |
| 9.2 Λεξιλογική συνοχή NPMI .....                                        | 39 |
| 9.3 Ανάλυση ευαισθησίας .....                                           | 40 |
| Κεφάλαιο 10 – Διαχρονική Ανάλυση .....                                  | 42 |
| 10.1 Συνολική κίνηση του ιστορικού αρχείου .....                        | 42 |
| 10.2 Θεματική σύνθεση ανά έτος .....                                    | 42 |
| 10.3 Η πανδημία ως έλεγχος χρονικής εγκυρότητας .....                   | 43 |
| 10.4 Θεσμικοί εκλογικοί κύκλοι .....                                    | 44 |
| 10.5 Ακαδημαϊκή εποχικότητα .....                                       | 45 |
| 10.6 Εποχικές ευχές και προσκλήσεις μεταπτυχιακών .....                 | 45 |
| 10.7 Συζητήσεις αναδιάρθρωσης και αυξανόμενη θεματολογία ισότητας ..... | 48 |
| 10.8 Υποδομές, ψηφιακές υπηρεσίες και εξ αποστάσεως λειτουργία .....    | 51 |
| Κεφάλαιο 11 – Συμπεράσματα, Περιορισμοί και Μελλοντικά Βήματα .....     | 52 |
| 11.1 Περιορισμοί .....                                                  | 52 |
| 11.2 Συμπεράσματα .....                                                 | 53 |
| 11.3 Μελλοντικά βήματα .....                                            | 54 |
| Βιβλιογραφία .....                                                      | 55 |
| Παράρτημα Α: Κατάλογος Συστάδων .....                                   | 57 |

# Περίληψη

Η παρούσα διπλωματική εργασία εξετάζει την ανεπίβλεπτη ανακάλυψη θεμάτων στο ιστορικό αρχείο της ομάδας ηλεκτρονικού ταχυδρομείου *tonima* του Πανεπιστημίου Πατρών, συμπεριλαμβανομένων των μηνυμάτων της υποομάδας *announcements*. Το τελικό σώμα περιλαμβάνει 13.637 μηνύματα στα ελληνικά και τα αγγλικά, για την περίοδο 2018–2023. Η ροή συνδυάζει δομικό και γλωσσικό καθαρισμό, ενσωματώσεις BGE-M3, μείωση διαστάσεων με PCA και UMAP και συσταδοποίηση με HDBSCAN. Οι υπερπαραμέτροι επιλέγονται με 200 δοκιμές Optuna. Η εφαρμογή αποτελεί *proof of concept* θεματικής μοντελοποίησης, με προοπτική αξιοποίησης σε μελλοντική υπηρεσία του Πανεπιστημίου.

Η μέθοδος αναδεικνύει 107 συστάδες και 16 κύριες θεματικές, με το 14,7% των μηνυμάτων να παραμένει μη ανατεθειμένο. Η σημασιολογική συνοχή είναι 0,8111, έναντι 0,7999 για το *k-means* και 0,8005 για τη Ward. Το NPMI είναι αντίστοιχα 0,2067, 0,1892 και 0,1945, με τις πιθανότητες να υπολογίζονται σε κοινό σώμα αναφοράς. Η ανάλυση ευαισθησίας δείχνει μικρή μεταβολή της συνοχής στις τέσσερις διακριτές υπερπαραμέτρους που εξετάστηκαν.

Η διαχρονική ανάλυση δείχνει ότι οι συστάδες αποτυπώνουν πραγματικά θεσμικά γεγονότα: η πανδημία εμφανίζεται ως αιχμή του Μαρτίου 2020 σε θεματική που το 2019 σχεδόν δεν υπήρχε, οι πρυτανικές εκλογές κυριαρχούν τον Ιούλιο του 2020, ενώ η εργασιακή θεματολογία αυξάνει το μερίδιό της κατά 3,4 ποσοστιαίες μονάδες μεταξύ 2018 και 2022, χωρίς η συσταδοποίηση να έχει λάβει καμία χρονική πληροφορία.

# Abstract

This thesis examines unsupervised topic discovery in the historical archive of the University of Patras tovima email group, including messages from its announcements subgroup. The final corpus contains 13,637 Greek and English emails from 2018–2023. The pipeline combines structural and linguistic preprocessing, BGE-M3 embeddings, PCA and UMAP dimensionality reduction, and HDBSCAN clustering. Hyperparameters are selected through 200 Optuna trials. The application is a proof of concept for topic modeling that could support a future university service.

The method produces 107 clusters grouped into 16 major topics, leaving 14.7% of emails unassigned. Semantic coherence is 0.8111, compared with 0.7999 for k-means and 0.8005 for Ward. NPMI is 0.2067, 0.1892 and 0.1945 respectively, with all probabilities estimated from a shared reference corpus. Sensitivity analysis shows limited variation in coherence across the four discrete hyperparameters examined.

Temporal analysis shows the clusters track real institutional events: the pandemic appears as a March 2020 spike in a topic that scarcely existed in 2019, rectorial elections dominate July 2020, and labour-affairs traffic grows by 3.4 percentage points of share between 2018 and 2022, although the clustering was given no temporal information.

## Ευρετήριο Εικόνων

|                                                                                                                                                     |    |
|-----------------------------------------------------------------------------------------------------------------------------------------------------|----|
| Εικόνα 1.1: Ροή επεξεργασίας του ιστορικού αρχείου tonima, με τα μηνύματα της υποομάδας announcements .....                                         | 7  |
| Εικόνα 7.1: Προβολές PCA δύο διαστάσεων των αρχικών ενσωματώσεων BGE-M3 (πάνω) και της αποθηκευμένης εξόδου UMAP 13 διαστάσεων (κάτω), με...        | 34 |
| Εικόνα 7.2: Κατανομή των μεγεθών των 107 συστάδων (διάμεσος 72, μέγιστο 938).....                                                                   | 34 |
| Εικόνα 7.3: Τα αναγνωριστικά των 107 τελικών συστάδων στην προβολή PCA της εξόδου UMAP. ....                                                        | 35 |
| Εικόνα 7.4: Συνημιτονική ομοιότητα των κεντροειδών των τελικών συστάδων στις αρχικές ενσωματώσεις, ταξινομημένων ανά κύρια θεματική. ....           | 36 |
| Εικόνα 9.1: Σύγκριση HDBSCAN, k-means και Ward ως προς τη σημασιολογική συνοχή και το NPMI, με άξονες που ξεκινούν από το μηδέν. ....               | 40 |
| Εικόνα 10.1: Μηνύματα ανά έτος (αριστερά· το 2023 ελλιπές, με διαγράμμιση) και μέσος όρος μηνυμάτων ανά μήνα (δεξιά). ....                          | 42 |
| Εικόνα 10.2: Μερίδιο κάθε κύριας θεματικής στην κίνηση του ιστορικού αρχείου tonima ανά έτος, για τις οκτώ μεγαλύτερες θεματικές (* 2023:....       | 43 |
| Εικόνα 10.3: Μηνιαίος όγκος συστάδων σχετικών με COVID-19 .....                                                                                     | 44 |
| Εικόνα 10.4: Θεματική Elections & Governance, μηνιαίος όγκος.....                                                                                   | 44 |
| Εικόνα 10.5: Μερίδιο της Academic Events στη συνολική μηνιαία κίνηση, με συνάθροιση μόνο των πλήρων ετών 2018–2022. ....                            | 45 |
| Εικόνα 10.6: Μηνιαίος όγκος Campus Life και Holiday Greetings .....                                                                                 | 46 |
| Εικόνα 10.7: Μηνιαίος όγκος Postgraduate Programmes και Postgraduate & Doctoral Admissions / Programme Announcements, με άξονα μήνα και έτους. .... | 47 |
| Εικόνα 10.8: Μηνιαίος όγκος Academic Events, Master’s Thesis Presentations και PhD Defense Announcements. ....                                      | 48 |
| Εικόνα 10.9: Μηνιαίος όγκος University Administration και University Restructuring, TEI Merger & Law School Debate. ...                             | 49 |
| Εικόνα 10.10: Μηνιαίος όγκος της κύριας και ειδικής θεματικής ισότητας.....                                                                         | 50 |
| Εικόνα 10.11: Μηνιαίος όγκος Infrastructure & Digital Services, eClass & Exams Platform Announcements και IT Services & Network Interruptions. .... | 51 |

## Ευρετήριο Πινάκων

|                                                                                                     |    |
|-----------------------------------------------------------------------------------------------------|----|
| Πίνακας 1.1: Τα στάδια της ροής επεξεργασίας και τα παραγόμενα αρχεία. ....                         | 6  |
| Πίνακας 3.1: Ευρήματα του ελέγχου δεδομένων και η απόφαση καθαρισμού που υπαγόρευσε το καθένα. .... | 20 |
| Πίνακας 3.2: Σχήμα εισόδου για εφαρμογή χωρίς scraping.....                                         | 21 |
| Πίνακας 6.1: Σύγκριση μοντέλων ενσωματώσεων σε 30 ζεύγη γνωστής αλήθειας. ....                      | 27 |
| Πίνακας 8.1: Η ταξινομία κύριων θεματικών πάνω στις 107 συστάδες. ....                              | 38 |
| Πίνακας 9.1: Σύγκριση με τις μεθόδους αναφοράς και στα δύο μέτρα. ....                              | 40 |
| Πίνακας 9.2: Ευαισθησία της λύσης σε διαταραχές υπερπαραμέτρων $\pm 20\%$ . ....                    | 41 |
| Πίνακας A.1: Οι 107 συστάδες της τελικής λύσης. ....                                                | 60 |

## Ευρετήριο Αποσπασμάτων Κώδικα

|                                                                                                               |    |
|---------------------------------------------------------------------------------------------------------------|----|
| Απόσπασμα 5.1: Η διόρθωση των σύνθετων λημμάτων (04_nlp_preprocessing.ipynb). ....                            | 25 |
| Απόσπασμα 7.1: Το μέτρο σημασιολογικής συνοχής (07_clustering.ipynb). ....                                    | 31 |
| Απόσπασμα 7.2: Αποτίμηση της αντικειμενικής συνάρτησης μέσα στη δοκιμή του Optuna (07_clustering.ipynb). .... | 31 |
| Απόσπασμα 7.3: Συγχώνευση συστάδων ανεξάρτητη από τη σειρά επεξεργασίας (07_clustering.ipynb).....            | 32 |

# Κεφάλαιο 1

## Εισαγωγή


Η εργασία μελετά την οργάνωση του ιστορικού αρχείου της ομάδας ηλεκτρονικού ταχυδρομείου tovima του Πανεπιστημίου Πατρών σε θεματικές ενότητες. Στο αρχείο περιλαμβάνονται και μηνύματα της υποομάδας announcements. Η αρχική συλλογή αποτελείται από 14.277 μηνύματα της περιόδου 2018–2023, κυρίως στα ελληνικά, με αγγλικό περιεχόμενο όπως περιλήψεις εργασιών και προσκλήσεις συνεδρίων. Στόχος είναι να εντοπιστούν σημασιολογικά συνεκτικές ομάδες χωρίς προηγούμενη επισήμανση των μηνυμάτων. Πρόκειται για μελέτη εφαρμογής (proof of concept): εξετάζεται η καταλληλότητα της μεθοδολογίας για το συγκεκριμένο αρχείο, ως πρώτο βήμα προς μια πανεπιστημιακή υπηρεσία αναζήτησης, θεματικής πλοήγησης ή παρακολούθησης ανακοινώσεων.

Η μεθοδολογία υλοποιείται σε διαδοχικά notebooks. Κάθε στάδιο καταναλώνει το αρχείο εξόδου του προηγούμενου, με διακριτή φυσική και λεξιλογική αναπαράσταση του ίδιου μηνύματος. Ο Πίνακας 1.1 καταγράφει τις εισόδους και τις εξόδους της εφαρμογής και η Εικόνα 1.1 συνοψίζει τη συνολική ροή.

| Στάδιο                        | Notebook                      | Είσοδος                | Έξοδος                                  |
|-------------------------------|-------------------------------|------------------------|-----------------------------------------|
| Συλλογή δεδομένων             | 01_make_dataset.ipynb         | mailarchive.upatras.gr | tovima.csv (14.277 γραμμές)             |
| Έλεγχος δεδομένων (EDA)       | 02_eda_data_audit.ipynb       | tovima.csv             | ευρήματα ελέγχου                        |
| Δομικός καθαρισμός            | 03_preprocessing.ipynb        | tovima.csv             | tovima_clean.csv (13.692)               |
| Γλωσσική προεπεξεργασία       | 04_nlp_preprocessing.ipynb    | tovima_clean.csv       | tovima_nlp_ready.csv (13.637)           |
| Επιλογή μοντέλου ενσωματώσεων | 05_compare_embeddings.ipynb   | tovima_nlp_ready.csv   | απόφαση μοντέλου (BGE-M3)               |
| Παραγωγή ενσωματώσεων         | 06_embedding_generation.ipynb | tovima_nlp_ready.csv   | διανύσματα 13.637×1024                  |
| Συσταδοποίηση                 | 07_clustering.ipynb           | ενσωματώσεις           | tovima_clustered.csv (107 συστάδες)     |
| Χαρακτηρισμός & ταξινόμια     | 08_tfidf_labeling.ipynb       | tovima_clustered.csv   | tovima_final.csv                        |
| Επικύρωση                     | 09_validation.ipynb           | tovima_final.csv       | μέθοδοι αναφοράς, NPMI, ευαισθησία      |
| Διαχρονική ανάλυση            | 10_temporal_analysis.ipynb    | tovima_final.csv       | θεματικές τάσεις 2018–2023, διαγράμματα |

Πίνακας 1.1: Τα στάδια της ροής επεξεργασίας και τα παραγόμενα αρχεία.

## From university emails to topics



Εικόνα 1.1: Ροή επεξεργασίας του ιστορικού αρχείου *tonima*, με τα μηνύματα της υποομάδας *announcements*. Εικονογράφηση με εργαλείο παραγωγής εικόνας.

Ο σχεδιασμός της ροής λαμβάνει υπόψη το δίγλωσσο περιεχόμενο των μηνυμάτων και την απουσία προκαθορισμένων θεματικών ετικετών. Η προεπεξεργασία προσαρμόζεται στα χαρακτηριστικά του αρχείου, ενώ η συσταδοποίηση βασίζεται σε σημασιολογικές ενσωματώσεις. Οι επιλογές αυτές τεκμηριώνονται στα επόμενα κεφάλαια και αξιολογούνται με μετρικές συνοχής και σύγκριση με μεθόδους αναφοράς.

### 1.1 Σκοπός και ερευνητικά ερωτήματα

Οι ανακοινώσεις και οι συζητήσεις που διακινούνται μέσω πανεπιστημιακών ομάδων ηλεκτρονικού ταχυδρομείου συσσωρεύονται σε αρχεία που είναι δύσκολο να εξεταστούν εκ των υστέρων. Η χρονολογική πρόσβαση βοηθά στην εύρεση ενός γνωστού μηνύματος, αλλά δεν δίνει άμεσα εικόνα των θεμάτων και της εξέλιξής τους. Στην περίπτωση της *tonima*, το ελληνικό και αγγλικό περιεχόμενο προσθέτει και γλωσσικές απαιτήσεις στην ανάλυση. Το κίνητρο της εργασίας είναι να εξεταστεί αν οι σημασιολογικές ενσωματώσεις και η ανεπίβλεπτη συσταδοποίηση μπορούν να οργανώσουν αυτό το υλικό χωρίς εκ των προτέρων ταξινομία. Ως *proof of concept*, η εφαρμογή μπορεί να αποτελέσει αφετηρία για υπηρεσία του Πανεπιστημίου, στην οποία η αυτόματη οργάνωση θα συνδυάζεται με την ανθρώπινη ερμηνεία των θεμάτων.

Τρία ερευνητικά ερωτήματα διατρέχουν την εργασία. **EE1:** Μπορεί μια ροή συσταδοποίησης βασισμένη σε ενσωματώσεις να ανακτήσει σημασιολογικά ουσιαστική θεματική δομή από ένα δίγλωσσο ελληνικό θεσμικό σώμα κειμένων; **EE2:** Μπορεί κάθε στάδιο μιας τέτοιας ροής (κανόνες καθαρισμού, επιλογή μοντέλου, υπερπαραμέτροι, κατώφλια μετεπεξεργασίας) να τεκμηριωθεί εμπειρικά έναντι του ίδιου του σώματος κειμένων; **EE3:** Αποτυπώνει η δομή που ανακαλύπτεται τη

θεσμική πραγματικότητα, όπως αυτό μπορεί να ελεγχθεί μέσω της χρονικής της συμπεριφοράς έναντι γνωστών γεγονότων;

## 1.2 Συνεισφορά

Η συνεισφορά της εργασίας είναι η εφαρμογή και αξιολόγηση μιας ροής θεματικής μοντελοποίησης σε ελληνικό και αγγλικό πανεπιστημιακό ηλεκτρονικό ταχυδρομείο. Τα 13.637 μηνύματα οργανώνονται σε 107 συστάδες και 16 κύριες θεματικές, με 14,7% μη ανατεθειμένα. Η σύγκριση με k-means και Ward εξετάζει τη σημασιολογική και λεξιλογική συνοχή, ενώ η ανάλυση ευαισθησίας τη μεταβολή της συνοχής υπό αλλαγές υπερπαραμέτρων. Οι όροι και οι περιορισμοί αυτών των συγκρίσεων παρουσιάζονται στο Κεφάλαιο 9. Η διαχρονική ανάλυση συσχετίζει τα θέματα με την πανδημία, τους εκλογικούς κύκλους, τις εορταστικές ευχές και τις συζητήσεις αναδιάρθρωσης, παρότι ο χρόνος δεν χρησιμοποιείται ως χαρακτηριστικό στη συσταδοποίηση.

## 1.3 Δομή της διπλωματικής

Η εργασία οργανώνεται ως εξής. Το Κεφάλαιο 2 παρέχει το θεωρητικό υπόβαθρο, από τις βασικές έννοιες της μηχανικής μάθησης, τα παραδείγματα μάθησης και τα νευρωνικά δίκτυα, μέχρι την αναπαράσταση κειμένου, τις ενσωματώσεις προτάσεων με transformers, τη μείωση διαστάσεων, την πυκνωτική συσταδοποίηση, την αξιολόγηση ανεπίβλεπτης δομής, τη μπεϋζιανή βελτιστοποίηση υπερπαραμέτρων και τις ιδιαιτερότητες της νέας ελληνικής. Το Κεφάλαιο 3 καλύπτει τη συλλογή και τον έλεγχο των δεδομένων, το Κεφάλαιο 4 τον δομικό καθαρισμό και το Κεφάλαιο 5 τη γλωσσική προεπεξεργασία. Το Κεφάλαιο 6 επιλέγει και εφαρμόζει το μοντέλο ενσωματώσεων, το Κεφάλαιο 7 αναπτύσσει τη συσταδοποίηση με τη βελτιστοποίηση και τη μετεπεξεργασία της, και το Κεφάλαιο 8 παράγει τους χαρακτηρισμούς των συστάδων και τη θεματική ταξινόμια. Το Κεφάλαιο 9 επικυρώνει το αποτέλεσμα έναντι μεθόδων αναφοράς, ενός ανεξάρτητου μέτρου και διαταραχών, και το Κεφάλαιο 10 αναλύει το σώμα κειμένων διαχρονικά. Το Κεφάλαιο 11 συνοψίζει τα συμπεράσματα, τους περιορισμούς και τα μελλοντικά βήματα.

## 1.4 Σχέση με υπάρχουσες προσεγγίσεις θεματικής μοντελοποίησης

Η ανακάλυψη θεματικών ενοτήτων σε συλλογές εγγράφων έχει κλασικά διατυπωθεί ως πιθανοτική γενετική μοντελοποίηση, με χαρακτηριστικό εκπρόσωπο το Latent Dirichlet Allocation (LDA) [1]: τα έγγραφα είναι μείγματα θεμάτων και τα θέματα κατανομές πάνω σε ένα λεξιλόγιο σακούλας λέξεων (bag of words). Για το συγκεκριμένο σώμα κειμένων, η οικογένεια αυτή είναι ακατάλληλη για τρεις λόγους. Τα ελληνικά είναι έντονα κλιτή γλώσσα, οπότε ένα λεξιλόγιο σακούλας λέξεων διασπά κάθε έννοια σε δεκάδες επιφανειακούς τύπους αν δεν προηγηθεί επιθετική λημματοποίηση· το σώμα κειμένων είναι δίγλωσσο, και το LDA δεν διαθέτει μηχανισμό για να αναγνωρίσει ότι μια ελληνική ανακοίνωση και το αγγλικό της αντίστοιχο αφορούν το ίδιο θέμα· και πολλά μηνύματα είναι σύντομα, δηλαδή στην περιοχή όπου οι εκτιμήσεις συνεμφάνισης λέξεων γίνονται αναξιόπιστες.

Μια δεύτερη οικογένεια αντικαθιστά τις καταμετρήσεις λέξεων με πυκνές σημασιολογικές αναπαραστάσεις: τα έγγραφα ενσωματώνονται με έναν προεκπαιδευμένο transformer ενσωματώσεων προτάσεων [10], προβάλλονται σε χώρο χαμηλότερης διάστασης και συσταδοποιούνται, με κάθε συστάδα να περιγράφεται στη συνέχεια λεξιλογικά. Το Top2Vec [11] και,

κυρίως, το BERTopic [2] ακολουθούν αυτή τη συνταγή: το BERTopic συνθέτει ενσωματώσεις προτάσεων, UMAP [3], HDBSCAN [4, 5] και ένα TF-IDF βασισμένο σε κλάσεις (c-TF-IDF) για την περιγραφή των συστάδων. Η ροή που αναπτύσσεται στην παρούσα εργασία ανήκει σαφώς σε αυτή την οικογένεια και βρίσκεται αρχιτεκτονικά πολύ κοντά στο BERTopic: η αλληλουχία σταδίων των Κεφαλαίων 6–8 (ενσωμάτωση, μείωση, πυκνοτική συσταδοποίηση, περιγραφή με TF-IDF) είναι η ίδια. Πρόκειται για συνειδητή επιλογή μιας δοκιμασμένης αρχιτεκτονικής, και η συνεισφορά της εργασίας πρέπει να διαβαστεί αντίστοιχα: ως μια μετρημένη, τεκμηριωμένη και επικυρωμένη εφαρμογή μιας καθιερωμένης αρχιτεκτονικής σε ένα δίγλωσσο ελληνικό θεσμικό σώμα κειμένων.

Μέσα σε αυτή την αρχιτεκτονική, η ροή αποκλίνει από το τυπικό BERTopic σε πέντε σημεία, καθένα για λόγο που τεκμηριώνεται στο αντίστοιχο κεφάλαιο. Πρώτον, στην περιγραφή των συστάδων: το c-TF-IDF του BERTopic συνενώνει τα μέλη κάθε συστάδας και υπολογίζει κανονικοποιημένη συχνότητα όρων ανά κλάση με αντίστροφη στάθμιση βάσει της συνολικής συχνότητας όρων στις κλάσεις [2]. Δεν ταυτίζεται με το τυπικό TF-IDF του scikit-learn πάνω σε συγκεντρωτικά έγγραφα. Η συνένωση χάνει πάντως τη διάκριση μεταξύ συχνής παρουσίας ενός όρου σε πολλά μηνύματα και πολλών επαναλήψεών του σε λίγα μηνύματα. Η Ενότητα 8.1 μετρά το φαινόμενο πάνω στο σώμα κειμένων και υιοθετεί TF-IDF σε επίπεδο εγγράφου με μέσους όρους βαρών ανά συστάδα. Δεύτερον, στις υπερπαραμέτρους: αντί για τις προεπιλογές των βιβλιοθηκών, οι παράμετροι των UMAP και HDBSCAN επιλέγονται με αναζήτηση 200 δοκιμών μέσω Optuna [7] υπό αντικειμενική συνάρτηση βαθμονομημένη στο σώμα κειμένων (Ενότητα 7.5), και η συνοχή εξετάζεται ως προς τοπικές μεταβολές των διακριτών υπερπαραμέτρων (Ενότητα 9.3). Τρίτον, στην προεπεξεργασία: ο σχεδιασμός δύο παράλληλων κειμενικών αναπαραστάσεων του Κεφαλαίου 5 (φυσικό δίγλωσσο κείμενο για το μοντέλο ενσωματώσεων BGE-M3 [6], λημματοποιημένα ελληνικά για τις λεξιλογικές στατιστικές), μαζί με τις μετρημένες διορθώσεις ελληνικών ιδιαιτεροτήτων (το ελάττωμα σύνθετων λημμάτων του ελληνικού μοντέλου του spaCy [9] στην Ενότητα 5.3, η κανονικοποίηση τόνων στην Ενότητα 8.1) αντιμετωπίζει αστοχίες που μια έτοιμη ροή θα κληρονομούσε σιωπηλά. Τέταρτον, στη μετεπεξεργασία: η συγχώνευση μέσω συνεκτικών συνιστωσών, ανεξάρτητη από τη σειρά επεξεργασίας, και η βαθμονομημένη, σκόπιμα συντηρητική επανατοποθέτηση θορύβου της Ενότητας 7.6 αποτελούν τις συγκεκριμένες επιλογές μετεπεξεργασίας της εφαρμογής. Πέμπτον, στην επικύρωση: η σύγκριση με μεθόδους αναφοράς, ο ανεξάρτητος έλεγχος NPMI [8] και η ανάλυση ευαισθησίας του Κεφαλαίου 9 είναι εξωτερικά ως προς οποιαδήποτε βιβλιοθήκη.

Η χωριστή υλοποίηση των σταδίων επιτρέπει την εξέταση των κανόνων ελληνικής προεπεξεργασίας, της επιλογής μοντέλου, της αξιολόγησης και της μετεπεξεργασίας. Η εργασία τεκμηριώνει τις επιλογές αυτές για το συγκεκριμένο σώμα κειμένων.

# Κεφάλαιο 2

## Θεωρητικό Υπόβαθρο

Το κεφάλαιο αυτό συγκεντρώνει τις έννοιες πάνω στις οποίες στηρίζεται η ροή επεξεργασίας των Κεφαλαίων 3–10. Κάθε ενότητα συνδέει τη γενική διατύπωση μιας μεθόδου με τον τρόπο που η εργασία τη χρησιμοποιεί.

### 2.1 Βασικές έννοιες μηχανικής μάθησης

Η μηχανική μάθηση μελετά αλγορίθμους που βελτιώνουν την επίδοσή τους σε μια εργασία μέσω της εμπειρίας, δηλαδή μέσω της έκθεσης σε δεδομένα, αντί μέσω ρητών, χειρόγραφων κανόνων [26]. Ένα σύστημα μάθησης αποτελείται από τρία μέρη: ένα μοντέλο, δηλαδή μια οικογένεια συναρτήσεων παραμετροποιημένη από ρυθμιζόμενες παραμέτρους· μια αντικειμενική συνάρτηση (ή συνάρτηση κόστους) που βαθμολογεί πόσο καλά αποδίδει μια συγκεκριμένη επιλογή παραμέτρων στα διαθέσιμα δεδομένα· και μια διαδικασία βελτιστοποίησης που αναζητά στον χώρο των παραμέτρων μια επιλογή με καλή βαθμολογία. Η μάθηση είναι επομένως προσαρμογή: ο αλγόριθμος δεν γνωρίζει εκ των προτέρων τίποτα για λίστες ηλεκτρονικού ταχυδρομείου, ελληνική μορφολογία ή πανεπιστημιακές εκλογές. Ό,τι συλλαμβάνει, το συλλαμβάνει επειδή κάποιο ποσοτικό κριτήριο το επιβράβευσε πάνω σε δεδομένα.

Η κεντρική δυσκολία της μάθησης είναι η γενίκευση. Ένα μοντέλο με αρκετή χωρητικότητα μπορεί πάντοτε να προσαρμοστεί τέλεια στα δεδομένα εκπαίδευσής του, μαζί με τον θόρυβο και τις συμπτώσεις τους, και ένα μοντέλο προσαρμοσμένο έτσι αποδίδει κακώς σε δεδομένα που δεν έχει δει. Η αστοχία αυτή ονομάζεται υπερπροσαρμογή (overfitting). Η αντίθετη αστοχία, η υποπροσαρμογή, εμφανίζεται όταν η οικογένεια μοντέλων είναι υπερβολικά περιοριστική για να εκφράσει την πραγματική δομή. Στην πράξη, τα δεδομένα που χρησιμοποιούνται για την προσαρμογή των παραμέτρων διαχωρίζονται από τα δεδομένα με τα οποία κρίνεται η προσαρμογή. Διακρίνονται επίσης οι παράμετροι (που ορίζονται από τη διαδικασία βελτιστοποίησης) από τις υπερπαραμέτρους, δηλαδή ρυθμίσεις της ίδιας της διαδικασίας, όπως το μέγεθος του μοντέλου, κατώφλια ή πλήθη γειτόνων, που πρέπει να επιλεγούν με αναζήτηση σε επίπεδο πάνω από τον βρόχο εκπαίδευσης. Και οι δύο έννοιες επανέρχονται στην εργασία με ανεπίβλεπτη μορφή: το στάδιο συσταδοποίησης του Κεφαλαίου 7 εκθέτει πέντε υπερπαραμέτρους που επιλέγονται με αυτοματοποιημένη αναζήτηση, ενώ η ανάλυση ευαισθησίας του Κεφαλαίου 9 εξετάζει πώς μεταβάλλεται η συνοχή με τοπικές αλλαγές των ρυθμίσεων στο ίδιο σώμα κειμένων. Η αξιολόγηση σε νέα δεδομένα αποτελεί αντικείμενο μελλοντικής επέκτασης της εφαρμογής.

Δίπλα στην επιλογή παραδείγματος μάθησης βρίσκεται η οπτική μεροληψίας–διακύμανσης για το σφάλμα ενός μοντέλου: η μεροληψία είναι σφάλμα από υποθέσεις υπερβολικά άκαμπτες για να συλλάβουν την αλήθεια, η διακύμανση σφάλμα από ευαισθησία στο συγκεκριμένο δείγμα. Τα πλούσια μοντέλα ανταλλάσσουν μεροληψία με διακύμανση. Η ομαλοποίηση, τα περισσότερα δεδομένα και η προσεκτική αξιολόγηση διαχειρίζονται την ανταλλαγή. Στην εργασία αυτή η ανταλλαγή εμφανίζεται σε ασυνήθιστο σημείο, στη λεπτομέρεια της συσταδοποίησης: ένα πολύ μικρό ελάχιστο μέγεθος συστάδας παράγει πολλές σφιχτές συστάδες που προσαρμόζονται στις

συμπτώσεις του δείγματος (υψηλή διακύμανση), ενώ ένα πολύ μεγάλο συγχωνεύει πραγματικά θέματα (υψηλή μεροληψία). Η ποινή κατακερματισμού και το βαθμονομημένο εύρος αναζήτησης του Κεφαλαίου 7 συγκεκριμενοποιούν αυτή την ανταλλαγή.

## 2.2 Παραδείγματα μάθησης

Τα προβλήματα μάθησης ταξινομούνται με βάση την εποπτεία που φέρουν τα δεδομένα. Στην επιβλεπόμενη μάθηση κάθε παράδειγμα εκπαίδευσης είναι ζεύγος εισόδου και επιθυμητής εξόδου (ένα μήνυμα και η θεματική του ετικέτα, μια εικόνα και η κατηγορία της) και το μοντέλο μαθαίνει την απεικόνιση από την είσοδο στην έξοδο. Η ταξινόμηση (διακριτές έξοδοι) και η παλινδρόμηση (συνεχείς έξοδοι) είναι οι δύο βασικές της μορφές. Οι επιβλεπόμενες μέθοδοι είναι ισχυρές αλλά προϋποθέτουν ετικέτες, και οι ετικέτες είναι αυτό που ένα αρχείο 13.637 μηνυμάτων δεν διαθέτει: η παραγωγή τους είναι η δαπανηρή χειροκίνητη εργασία που η παρούσα διπλωματική επιδιώκει να αποφύγει.

Η αυτο-επιβλεπόμενη μάθηση παράγει στόχους από τα ίδια τα δεδομένα, όπως στην πρόβλεψη καλυμμένων μονάδων. Οι προεκπαιδευμένοι κωδικοποιητές μπορούν επίσης να προσαρμοστούν με αντιθετική εκπαίδευση σε επιβλεπόμενα ή συνθετικά ζεύγη. Το BGE-M3 συνδυάζει πηγές δεδομένων και στόχους ανάκτησης [6]. Στην παρούσα εργασία χρησιμοποιείται ο έτοιμος κωδικοποιητής. Ανεπίβλεπτη είναι η συσταδοποίηση του πανεπιστημιακού σώματος, για την οποία δεν χρησιμοποιούνται ετικέτες μηνυμάτων. Οι ονομασίες των θεμάτων αποδίδονται μετά τη συσταδοποίηση, με ανθρώπινη ερμηνεία.

## 2.3 Τεχνητά νευρωνικά δίκτυα

Τα μοντέλα πίσω από τις σύγχρονες αναπαραστάσεις κειμένου είναι τεχνητά νευρωνικά δίκτυα [25]. Η στοιχειώδης μονάδα τους, ο τεχνητός νευρώνας, υπολογίζει ένα σταθμισμένο άθροισμα των εισόδων του, προσθέτει έναν όρο μεροληψίας και περνά το αποτέλεσμα από μια μη γραμμική συνάρτηση ενεργοποίησης  $\phi$ :

$$a = \phi(w \cdot x + b)$$

Ένας μεμονωμένος νευρώνας μπορεί να χαράξει μόνο γραμμικό σύνορο. Τα δίκτυα αποκτούν την εκφραστική τους ισχύ διατάσσοντας νευρώνες σε στρώματα, με τις εξόδους κάθε στρώματος να τροφοδοτούν το επόμενο, ώστε τα μεταγενέστερα στρώματα να υπολογίζουν χαρακτηριστικά χαρακτηριστικών. Με επαρκές πλάτος ακόμη και ένα κρυφό στρώμα μπορεί να προσεγγίσει οποιαδήποτε συνεχή συνάρτηση σε φραγμένο χωρίο, το βάθος όμως είναι αυτό που κάνει την προσέγγιση αποδοτική: η ιεραρχική σύνθεση ταιριάζει με την ιεραρχική δομή των πραγματικών σημάτων, όπου γράμματα συνθέτουν λέξεις, λέξεις φράσεις και φράσεις νόημα.

Η εκπαίδευση ενός δικτύου σημαίνει επιλογή των βαρών του ώστε να ελαχιστοποιείται μια συνάρτηση κόστους  $L$  πάνω στα δεδομένα εκπαίδευσης. Η βασική διαδικασία είναι η κατάβαση κλίσης: υπολογίζεται η κλίση του κόστους ως προς κάθε βάρος (αποδοτικά μέσω της οπισθοδιάδοσης, μιας συστηματικής εφαρμογής του κανόνα της αλυσίδας προς τα πίσω μέσα από τα στρώματα), και κάθε βάρος μετακινείται αντίθετα προς την κλίση του,

$$\theta \leftarrow \theta - \eta \nabla L(\theta)$$

όπου η είναι ο ρυθμός μάθησης. Στην πράξη οι κλίσεις εκτιμώνται σε μικρές τυχαίες υποομάδες των δεδομένων (στοχαστική κατάβαση κλίσης), ανταλλάσσοντας ακριβείς κλίσεις με πολλά φθηνά, θορυβώδη βήματα. Κανένα δίκτυο δεν εκπαιδεύεται στην παρούσα εργασία: ο κωδικοποιητής transformer της Ενότητας 2.6 έρχεται πλήρως προεκπαιδευμένος από τρίτους σε τεράστια σώματα κειμένων. Η κατανόηση όμως του τρόπου εκπαίδευσής του εξηγεί τι περιμένει ως είσοδο: τα βάρη του διαμορφώθηκαν από φυσικές, διατεταγμένες, κλιτές προτάσεις, και γι' αυτό το Κεφάλαιο 5 του τροφοδοτεί φυσικό κείμενο και επιφυλάσσει το λημματοποιημένο, απαλλαγμένο από stopwords κείμενο για τις μεθόδους που βασίζονται σε καταμετρήσεις.

Οι συναρτήσεις ενεργοποίησης και οι συναρτήσεις κόστους καθορίζουν τι μπορεί να εκφράσει ένα δίκτυο και τι βελτιστοποιεί. Τα πρώτα δίκτυα χρησιμοποιούσαν κορεννύμενες ενεργοποιήσεις (τη σιγμοειδή και την tanh), των οποίων οι κλίσεις μηδενίζονται για μεγάλες εισόδους, στερώντας από τα βαθιά δίκτυα σήμα μάθησης. Η ανορθωμένη γραμμική μονάδα,  $\text{ReLU}(z) = \max(0, z)$ , διατηρεί τις κλίσεις ζωντανές και έτσι κατέστησε εφικτό το σύγχρονο βάθος. Για την παλινδρόμηση η καθιερωμένη συνάρτηση κόστους είναι το μέσο τετραγωνικό σφάλμα· για την ταξινόμηση η διασταυρούμενη εντροπία,

$$L = - \sum_i y_i \log \hat{y}_i$$

η οποία τιμωρεί αυστηρά τις βέβαιες λανθασμένες προβλέψεις και, ελαχιστοποιούμενη, ωθεί την προβλεπόμενη κατανομή προς την αληθινή. Η διασταυρούμενη εντροπία επανεμφανίζεται δύο φορές στην εργασία με άλλη μορφή: ως η οικογένεια στόχων εκπαίδευσης πίσω από τα προεκπαιδευμένα γλωσσικά μοντέλα της Ενότητας 2.6, και ως η συνάρτηση κόστους αντιστοίχισης γράφων που ελαχιστοποιεί το UMAP στην Ενότητα 2.7.

## 2.4 Επεξεργασία φυσικής γλώσσας

Η επεξεργασία φυσικής γλώσσας (Natural Language Processing, NLP) ασχολείται με το να καταστεί η ανθρώπινη γλώσσα υπολογίσιμη. Το κείμενο είναι δύσκολο σήμα: είναι διακριτό αντί αριθμητικό, αμφίσημο σε κάθε επίπεδο (λέξεις με πολλές σημασίες, προτάσεις με πολλές συντακτικές αναλύσεις) και, σε μορφολογικά πλούσιες γλώσσες όπως τα ελληνικά, ένα λέξημα διασκορπίζεται σε δεκάδες επιφανειακούς τύπους. Πριν λειτουργήσει οποιαδήποτε στατιστική μέθοδος, το ακατέργαστο κείμενο περνά από μια αλυσίδα προεπεξεργασίας με σταθερά στάδια, ακόμη κι όταν οι υλοποιήσεις τους είναι γλωσσο-εξαρτημένες. Ο τεμαχισμός (tokenisation) χωρίζει τη ροή χαρακτήρων σε μονάδες (λέξεις, στίξη, αριθμούς). Η κανονικοποίηση εξαλείφει την πλασματική ποικιλομορφία: πεζά/κεφαλαία, εναλλακτικές κωδικοποιήσεις Unicode του ίδιου τονισμένου χαρακτήρα, κενά. Η αφαίρεση stopwords απορρίπτει τις λειτουργικές λέξεις (άρθρα, προθέσεις, αντωνυμίες) που φέρουν γραμματική και όχι θεματική πληροφορία — πολύτιμη για τις μεθόδους καταμέτρησης, επιζήμια για μοντέλα που διαβάζουν ολόκληρες προτάσεις.

Το βαθύτερο βήμα κανονικοποίησης αφορά τη μορφολογία. Η αποκοπή καταλήξεων (stemming) περικόπτει τους κλιτούς τύπους σε ένα χονδρικό κοινό πρόθημα με κανόνες· είναι γρήγορη αλλά καταστροφική, και για τα ελληνικά, όπου η κλίση αλλάζει τις καταλήξεις με τρόπους συνυφασμένους με την παραγωγή, παράγει δυσανάγνωστα, συγκρουόμενα θέματα. Η λημματοποίηση αντιθέτως απεικονίζει κάθε τύπο στο λεξικογραφικό του λήμμα μέσω μορφολογικής ανάλυσης, διατηρώντας αναγνώσιμες, γλωσσολογικά πραγματικές μονάδες. Είναι η μέθοδος που χρησιμοποιείται στην

εργασία (Κεφάλαιο 5), όπου η συγκεκριμένη συμπεριφορά της στα ελληνικά, μαζί με ένα συστηματικό ελάττωμα, μετριέται πάνω στο σώμα κειμένων. Πάνω στο προεπεξεργασμένο κείμενο, η κλασική NLP χτίζει αναπαραστάσεις καταμέτρησης (συχνότητες όρων, n-grams, TF-IDF), ενώ η σύγχρονη NLP χτίζει μαθημένες, πυκνές αναπαραστάσεις. Οι επόμενες ενότητες αναπτύσσουν και τις δύο, γιατί η εργασία χρησιμοποιεί καθεμία εκεί όπου είναι ισχυρότερη: πυκνές ενσωματώσεις για την ανακάλυψη της θεματικής δομής, στατιστικές καταμέτρησης για την περιγραφή και την επικύρωσή της.

Ακόμη και μετά την προεπεξεργασία, το NLP παραμένει δύσκολο εξαιτίας δύο ιδιοτήτων της γλώσσας. Η αμφισημία διαπερνά κάθε επίπεδο: η «γραμμή» μπορεί να είναι ευθεία, ουρά ή πολιτική τοποθέτηση ανάλογα με τα συμφραζόμενα, και το ίδιο θέμα μηνύματος μπορεί να ανακοινώνει ένα σεμινάριο ή να το ακυρώνει. Επιπλέον, το νόημα είναι συνθετικό αλλά όχι αθροιστικό: η σειρά των λέξεων μετρά, η άρνηση αντιστρέφει το περιεχόμενο, οι ιδιωτισμοί ξεφεύγουν από τα συστατικά τους. Γι' αυτό οι αναπαραστάσεις που αγνοούν τη σειρά (οι μέθοδοι καταμέτρησης) μπορούν να περιγράψουν θέματα αλλά δυσκολεύονται με τις αποχρώσεις, και γι' αυτό υπάρχουν τα μοντέλα της Ενότητας 2.6 που λαμβάνουν υπόψη τη σειρά. Τα κλασικά συστήματα ανακτούν μερικώς τα συμφραζόμενα με n-grams, δηλαδή συνεχόμενες ακολουθίες n μονάδων. Η εργασία χρησιμοποιεί unigrams και bigrams στο στάδιο TF-IDF (Κεφάλαιο 8), όπου bigrams όπως «διδασκαλίας διατριβής» αποσαφηνίζουν ό,τι τα unigrams μόνα τους δεν μπορούν.

## 2.5 Από τις καταμετρήσεις λέξεων στις κατανεμημένες αναπαραστάσεις

Η κλασική αναπαράσταση ενός εγγράφου είναι η σακούλα λέξεων: ένα διάνυσμα καταμετρήσεων όρων πάνω σε σταθερό λεξιλόγιο, βελτιωμένο με στάθμιση TF-IDF [15, 16] ώστε να κυριαρχούν οι όροι που είναι συχνόι στο έγγραφο αλλά σπάνιοι στη συλλογή. Τα μοντέλα σακούλας λέξεων είναι διαφανή και παραμένουν το κατάλληλο εργαλείο όταν αντικείμενο μελέτης είναι η ακριβής ταυτότητα των μονάδων. Γι' αυτό η εργασία διατηρεί το TF-IDF για την περιγραφή των συστάδων (Κεφάλαιο 8). Ως βάση για τη μέτρηση ομοιότητας εγγράφων, όμως, έχουν δύο δομικές αδυναμίες. Αγνοούν τη συνωνυμία και την παράφραση: δύο ανακοινώσεις για το ίδιο σεμινάριο γραμμένες με διαφορετικό λεξιλόγιο μοιράζονται λίγες συντεταγμένες. Και κλιμακώνονται κακώς με τη μορφολογία: κάθε κλιτός επιφανειακός τύπος είναι ξεχωριστή διάσταση αν δεν προηγηθεί λημματοποίηση.

Οι κατανεμημένες αναπαραστάσεις απαντούν και στις δύο αδυναμίες ενσωματώνοντας λέξεις (και αργότερα ολόκληρες προτάσεις) ως πυκνά διανύσματα σε έναν χώρο όπου η γεωμετρική εγγύτητα προσεγγίζει τη σημασιολογική ομοιότητα. Η κατανεμητική υπόθεση (λέξεις που εμφανίζονται σε παρόμοια συμφραζόμενα έχουν παρόμοιες σημασίες) υλοποιήθηκε πρώτη φορά σε κλίμακα από τα στατικά μοντέλα ενσωματώσεων λέξεων. Ο περιορισμός τους είναι ότι κάθε τύπος λέξης λαμβάνει ένα μόνο διάνυσμα ανεξαρτήτως συμφραζομένων, οπότε η πολυσημία εξομαλύνεται και η σειρά των λέξεων χάνεται εντελώς. Τα συμφραστικά μοντέλα το επιλύουν υπολογίζοντας αναπαράσταση για κάθε μονάδα ως συνάρτηση ολόκληρης της περιβάλλουσας πρότασης.

Το πέρασμα από τις αραιές στις πυκνές αναπαραστάσεις φαίνεται καθαρότερα στα ίδια τα διανύσματα. Ένα διάνυσμα one-hot έχει μήκος όσο το λεξιλόγιο και είναι σχεδόν εξ ολοκλήρου μηδενικό. Κάθε ζεύγος διαφορετικών λέξεων απέχει εξίσου, οπότε η αναπαράσταση δεν γνωρίζει

τίποτα. Στατικά μοντέλα όπως το word2vec μαθαίνουν αντ' αυτού μερικές εκατοντάδες πυκνές διαστάσεις μέσω μιας αυτο-επιβλεπόμενης βοηθητικής εργασίας, δηλαδή την πρόβλεψη μιας λέξης από τους γείτονές της (CBOW) ή των γειτόνων από τη λέξη (skip-gram), και η γεωμετρία που προκύπτει τοποθετεί τα συνώνυμα κοντά και κωδικοποιεί σχέσεις ως κατευθύνσεις. Η ομοιότητα σε τέτοιους χώρους μετριέται κατά σύμβαση με το συνημίτονο της γωνίας μεταξύ διανυσμάτων αντί με ευκλείδεια απόσταση, επειδή το μήκος του διανύσματος συσχετίζεται με τη συχνότητα και όχι με τη σημασία. Γι' αυτόν τον λόγο κάθε ενσωμάτωση στην εργασία κανονικοποιείται κατά L2 πριν υπολογιστεί οποιαδήποτε απόσταση.

## 2.6 Κωδικοποιητές transformer και ενσωματώσεις προτάσεων

Ο transformer [24] υπολογίζει συμφραστικές αναπαραστάσεις μέσω αυτο-προσοχής (self-attention): κάθε μονάδα σχηματίζει ένα διάνυσμα ερωτήματος  $q$ , ένα διάνυσμα κλειδιού  $k$  και ένα διάνυσμα τιμής  $v$ , και «προσέχει» όλες τις άλλες μονάδες αναλογικά προς τη συμβατότητα ερωτήματος–κλειδιού,

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

όπου  $d_k$  είναι η διάσταση των κλειδιών και η κλιμάκωση σταθεροποιεί τις κλίσεις. Η στοίβαξη στρωμάτων προσοχής με μπλοκ πρόσθιας τροφοδότησης δίνει κωδικοποιητές όπως το BERT [23], προεκπαιδευμένους με μοντελοποίηση καλυμμένης γλώσσας σε μεγάλα σώματα κειμένων. Ένας προεκπαιδευμένος κωδικοποιητής παράγει ένα διάνυσμα ανά μονάδα. Μια ενσωμάτωση εγγράφου απαιτεί τη συγκέντρωση (pooling) αυτών σε ένα ενιαίο διάνυσμα, και οι κωδικοποιητές που έχουν προεκπαιδευτεί μόνο σε γλωσσική μοντελοποίηση παράγουν συγκεντρωμένα διανύσματα με γεωμετρία ακατάλληλη για συγκρίσεις ομοιότητας. Τα μοντέλα ενσωματώσεων προτάσεων όπως το Sentence-BERT [10] μικρορυθμίζουν επομένως τον κωδικοποιητή με αντιθετικούς στόχους που έλκουν κοντά τα σημασιολογικά όμοια κείμενα και απωθούν τα ανόμοια, καθιστώντας τη συνημιτονική ομοιότητα μεταξύ των συγκεντρωμένων διανυσμάτων ουσιαστική.

Οι πολυγλωσσικές ενσωματώσεις επιτρέπουν την αναπαράσταση ελληνικών και αγγλικών μηνυμάτων σε κοινό χώρο, χωρίς να εγγυώνται τέλεια διαγλωσσική αντιστοίχιση. Το BGE-M3 [6], βασισμένο σε XLM-RoBERTa, υποστηρίζει περισσότερες από 100 γλώσσες και εισόδους έως 8.192 υπολεξικές μονάδες. Το M3 αναφέρεται σε πολυγλωσσικότητα, πολλαπλές λειτουργίες ανάκτησης (dense, sparse και multi-vector) και διαφορετικές κλίμακες μήκους εισόδου. Η αυτο-απόσταση συνδυάζει βαθμολογίες των λειτουργιών ανάκτησης σε κοινό σήμα διδασκαλίας. Στην εργασία χρησιμοποιείται μόνο η πυκνή αναπαράσταση 1.024 διαστάσεων μέσω Ollama, όχι οι αραιές ή οι πολλαπλές αναπαραστάσεις. Η φυσική σειρά και οι λειτουργικές λέξεις διατηρούνται στην είσοδο των ενσωματώσεων· η ληματοποιημένη αναπαράσταση προορίζεται για λεξιλογική ανάλυση.

Ο κωδικοποιητής παράγει συμφραστικές αναπαραστάσεις υπολεξικών μονάδων. Στο πυκνό σκέλος του BGE-M3, το διάνυσμα του εγγράφου λαμβάνεται από την ειδική μονάδα [CLS], με CLS pooling [6], όπως δηλώνεται και στα μεταδεδομένα του μοντέλου Ollama. Η αυτο-προσοχή επιτρέπει στις υπόλοιπες μονάδες να επηρεάζουν αυτή την αναπαράσταση. Η περικοπή της εισόδου μπορεί επομένως να αφαιρέσει χρήσιμη πληροφορία, ακόμη και όταν αφορά το τέλος του μηνύματος. Οι

κανόνες κανονικοποίησης του tokenizer εξαρτώνται από το συγκεκριμένο μοντέλο και εξετάζονται χωριστά από τη μέθοδο pooling.

## 2.7 Γεωμετρία υψηλών διαστάσεων και μείωση διαστάσεων

Οι χώροι ενσωματώσεων είναι πολυδιάστατοι, και οι πολλές διαστάσεις συμπεριφέρονται αντίθετα με τη διαίσθηση: καθώς η διάσταση αυξάνεται, οι αποστάσεις τυχαίων σημείων συγκεντρώνονται, η αντίθεση μεταξύ κοντινότερου και μακρινότερου γείτονα συρρικνώνεται, και οι εκτιμήσεις πυκνότητας απαιτούν εκθετικά περισσότερα δεδομένα. Η πυκνοτική συσταδοποίηση απευθείας σε 1.024 διαστάσεις είναι επομένως αναξιόπιστη, και ένα βήμα μείωσης αποτελεί καθιερωμένη πρακτική. Η ανάλυση κύριων συνιστωσών (PCA) [14] παρέχει το γραμμικό μέρος: προβάλλει στις ορθοκανονικές κατευθύνσεις μέγιστης διακύμανσης, περιορίζοντας τη διάσταση της αναπαράστασης. Στο συγκεκριμένο σώμα κειμένων η διακύμανση φθίνει σταδιακά (οι 256 συνιστώσες διατηρούν το 87,7%), οπότε η PCA λειτουργεί ως υπολογιστική προ-μείωση και όχι ως η τελική γεωμετρία.

Η υπόθεση της πολλαπλότητας δέχεται ότι τα πραγματικά δεδομένα συγκεντρώνονται κοντά σε μια χαμηλοδιάστατη καμπυλωμένη επιφάνεια μέσα στον περιβάλλοντα χώρο. Οι μη γραμμικές μέθοδοι επιδιώκουν να ανακτήσουν συντεταγμένες πάνω σε αυτή την επιφάνεια. Το UMAP [3] το επιτυγχάνει κατασκευάζοντας έναν ασαφή γράφο  $k$  κοντινότερων γειτόνων στον χώρο εισόδου και βελτιστοποιώντας μια χαμηλοδιάστατη διάταξη της οποίας ο ασαφής γράφος ταιριάζει με τον αρχικό υπό συνάρτηση κόστους διασταυρούμενης εντροπίας (η τυπική κατασκευή δίνεται στην Ενότητα 7.3). Το UMAP μπορεί να διατηρεί μέρος της ευρύτερης δομής, χωρίς εγγύηση πιστής διατήρησης όλων των αποστάσεων. Κλιμακώνεται πρακτικά σε μεγάλα σύνολα και, καθοριστικά εδώ, υποστηρίζει διάσταση εξόδου μεγαλύτερη από δύο, ώστε να μπορεί να παραγάγει τον χώρο 13 διαστάσεων στον οποίο πραγματοποιείται η συσταδοποίηση και όχι μόνο δισδιάστατες απεικονίσεις. Η στοχαστικότητα του και η ευαισθησία του στις υπερπαραμέτρους αποτελούν πραγματικό κόστος. Στην εργασία αντιμετωπίζονται με σταθερό seed και με την ανάλυση ευαισθησίας του Κεφαλαίου 9.

## 2.8 Παραδείγματα συσταδοποίησης

Οι διαμεριστικές μέθοδοι αναθέτουν κάθε σημείο σε ακριβώς μία από  $k$  συστάδες. Ο  $k$ -means ελαχιστοποιεί την ενδοσυσταδική διακύμανση,

$$J = \sum_j \sum_{x \in C_j} \|x - \mu_j\|^2$$

κριτήριο που ευνοεί συμπαγείς, περίπου σφαιρικές συστάδες υπό ευκλείδεια απόσταση. Ο αριθμός  $k$  προκαθορίζεται, ενώ τα μεγέθη των συστάδων μπορούν να διαφέρουν. Η συσσωρευτική (agglomerative) συσταδοποίηση χτίζει μια ιεραρχία από κάτω προς τα πάνω. Το κριτήριο του Ward [22] συγχωνεύει το ζεύγος συστάδων του οποίου η ένωση αυξάνει λιγότερο τη συνολική ενδοσυσταδική διακύμανση. Και οι δύο μέθοδοι χρησιμοποιούνται στο Κεφάλαιο 9 ως μέθοδοι αναφοράς.

Οι πυκνοτικές μέθοδοι ορίζουν αντιθέτως τις συστάδες ως συνεκτικές περιοχές υψηλής πυκνότητας σημείων, χωρισμένες από αραιές περιοχές, και, κρίσιμο για ένα αρχείο λιστών, επιτρέπουν σε σημεία

να μην ανήκουν σε καμία συστάδα. Το DBSCAN το τυποποιεί με ένα καθολικό κατώφλι πυκνότητας, το οποίο αποτυγχάνει όταν οι συστάδες έχουν διαφορετικές πυκνότητες. Το HDBSCAN [4, 5] αίρει το καθολικό κατώφλι χτίζοντας την ιεραρχία των πυκνοτικά συνεκτικών συνιστωσών για όλα τα κατώφλια ταυτόχρονα, με αποστάσεις αμοιβαίας προσβασιμότητας, και επιλέγοντας κατόπιν το σύνολο των μη επικαλυπτόμενων συστάδων με μέγιστη σταθερότητα (κριτήριο *excess-of-mass*: οι τυπικοί ορισμοί δίνονται στην Ενότητα 7.4). Οι ιδιότητες που το καθιστούν τη μέθοδο της παρούσας εργασίας συμπίπτουν με τις ιδιότητες των δεδομένων: θεματικές συστάδες πολύ διαφορετικών μεγεθών και πυκνοτήτων, καμία υπερασπίσιμη εκ των προτέρων εκτίμηση για το  $k$ , και ένας πραγματικός πληθυσμός μεμονωμένων μηνυμάτων που πρέπει να χαρακτηριστούν θόρυβος αντί να εξαναγκαστούν στην κοντινότερη θεματική.

Για πληρότητα, το πυκνοτικό παράδειγμα γίνεται πιο εύληπτο μέσα από τους ορισμούς του DBSCAN, τους οποίους το HDBSCAN γενικεύει. Ορίζονται μια ακτίνα  $\epsilon$  και ένα πλήθος  $\text{minPts}$ : ένα σημείο είναι σημείο πυρήνα αν τουλάχιστον  $\text{minPts}$  σημεία βρίσκονται σε απόσταση έως  $\epsilon$  από αυτό· σημεία εντός  $\epsilon$  από σημείο πυρήνα είναι πυκνοτικά προσβάσιμα από αυτό· μια συστάδα είναι ένα μέγιστο σύνολο αμοιβαία πυκνοτικά συνδεδεμένων σημείων· σημεία μη προσβάσιμα από κανένα σημείο πυρήνα είναι θόρυβος. Η κατασκευή είναι κομψή αλλά εξαρτάται από ένα και μόνο καθολικό  $\epsilon$  (ένα κατώφλι πυκνότητας για ολόκληρο το σύνολο δεδομένων), το οποίο αποτυγχάνει όποτε οι πραγματικές συστάδες έχουν διαφορετικές πυκνότητες, όπως συμβαίνει με τις θεματικές συστάδες ενός αρχείου ηλεκτρονικού ταχυδρομείου (μια συστάδα 938 ανακοινώσεων διπλωματικών είναι πολύ πυκνότερη από μια συστάδα 33 μηνυμάτων Erasmus). Η συνεισφορά του HDBSCAN είναι η άρση του  $\epsilon$ : εξετάζει όλα τα κατώφλια ταυτόχρονα και αφήνει κάθε συστάδα να γεννιέται και να διαλύεται στη δική της πυκνότητα.

## 2.9 Αξιολόγηση ανεπίβλεπτης δομής

Η σημασιολογική συνοχή αξιολογεί τη συμπαγή δομή στον χώρο ενσωματώσεων και αποτελεί μέρος της αντικειμενικής συνάρτησης. Για τον συμπληρωματικό έλεγχο χρησιμοποιείται η κανονικοποιημένη σημειακή αμοιβαία πληροφορία (NPMI) [8], μέτρο λεξιλογικής συσχέτισης που έχει μελετηθεί σε σχέση με ανθρώπινες κρίσεις θεματικής συνοχής [27]. Υπολογίζεται από το ίδιο σώμα κειμένων, χωρίς χρήση των διανυσμάτων. Η ανάλυση ευαισθησίας εξετάζει επιπλέον τη μεταβολή της συνοχής σε επιλεγμένες αλλαγές υπερπαραμέτρων.

Όταν υπάρχουν ετικέτες αναφοράς, εξωτερικοί δείκτες όπως ο διορθωμένος δείκτης Rand ή η κανονικοποιημένη αμοιβαία πληροφορία βαθμολογούν τη συμφωνία μεταξύ της διαμέρισης που ανακαλύφθηκε και της αληθινής. Τέτοιες ετικέτες δεν υπάρχουν για το συγκεκριμένο σώμα κειμένων (η παραγωγή τους είναι αυτό που η ροή αντικαθιστά), οπότε η εξωτερική επικύρωση παίρνει εδώ δύο υποκατάστατες μορφές: στοχευμένη χειροκίνητη επιθεώρηση συστάδων έναντι των μηνυμάτων-μελών τους (Κεφάλαιο 8), και τον χρονικό έλεγχο του Κεφαλαίου 10, στον οποίο η δομή που ανακαλύφθηκε αντιπαραβάλλεται με ανεξάρτητα γνωστά θεσμικά γεγονότα. Ο δεύτερος αποτελεί, στην ουσία, έλεγχο εξωτερικής εγκυρότητας με βάση ανεξάρτητα γνωστά γεγονότα αντί για χειροκίνητες ετικέτες.

## 2.10 Μπεϋζιανή βελτιστοποίηση υπερπαραμέτρων

Το στάδιο συσταδοποίησης εκθέτει πέντε αλληλεπιδρώσες υπερπαραμέτρους, των οποίων η από κοινού επίδραση στην αντικειμενική συνάρτηση είναι μη κυρτή, μη παραγωγίσιμη και ακριβή στην αποτίμηση, δηλαδή ένα πρόβλημα βελτιστοποίησης μαύρου κουτιού. Η αναζήτηση πλέγματος κλιμακώνεται εκθετικά και η τυχαία αναζήτηση σπαταλά αποτιμήσεις σε κακές περιοχές. Η ακολουθιακή βελτιστοποίηση βασισμένη σε μοντέλο προσαρμόζει αντ' αυτού ένα υποκατάστατο μοντέλο στα παρατηρημένα ζεύγη (παραμέτροι, βαθμολογία) και προτείνει την επόμενη δοκιμή εκεί όπου η αναμενόμενη βελτίωση είναι μεγαλύτερη. Ο Tree-structured Parzen Estimator [18], όπως υλοποιείται στο Optuna [7], μοντελοποιεί τις πυκνότητες  $l(x)$  των παραμέτρων στις καλές δοκιμές και  $g(x)$  στις υπόλοιπες, και προτείνει σημεία που μεγιστοποιούν τον λόγο

$$EI(x) \propto \frac{l(x)}{g(x)}$$

ο οποίος κατευθύνει τις δοκιμές σε περιοχές με υψηλές βαθμολογίες, διατηρώντας και εξερεύνηση. Η αναζήτηση περιλάμβανε 200 δοκιμές Optuna. Ο MedianPruner δηλώνεται στον κώδικα αλλά παραμένει ανενεργός, καθώς η αντικειμενική συνάρτηση δεν καλεί `trial.report` και `trial.should_prune`.

Η κύρια εναλλακτική οικογένεια υποκατάστατων μοντέλων είναι οι γκαουσιανές διαδικασίες, που μοντελοποιούν την ίδια την αντικειμενική συνάρτηση και προτείνουν σημεία με βάση την αναμενόμενη βελτίωση υπό αυτό το μοντέλο. Οι γκαουσιανές διαδικασίες διαπρέπουν σε ομαλούς, χαμηλοδιάστατους, συνεχείς χώρους αλλά χειρίζονται αδέξια ακέραιες, κατηγορικές και υπό συνθήκη παραμέτρους και κλιμακώνονται κυβικά με το πλήθος των παρατηρήσεων. Ο TPE αντιστρέφει τη μοντελοποίηση (πυκνότητες παραμέτρων δεδομένης της επίδοσης, αντί επίδοση δεδομένων των παραμέτρων), γεγονός που καθιστά φυσικούς τους μεικτούς και υπό συνθήκη χώρους αναζήτησης. Ο χώρος αναζήτησης του Κεφαλαίου 7 είναι τέτοιος (ακέραιοι, μία συνεχής παράμετρος, και ένα εύρος `min_samples` που εξαρτάται από το `min_cluster_size`), και γι' αυτό ο TPE αποτελεί εδώ την κατάλληλη επιλογή.

## 2.11 Επεξεργασία φυσικής γλώσσας για τα Νέα Ελληνικά

Τα νέα ελληνικά είναι έντονα κλιτή, συμφωρηματική γλώσσα: ουσιαστικά και επίθετα κλίνονται σε τέσσερις πτώσεις, δύο αριθμούς και τρία γένη, και τα ρήματα κλίνονται κατά χρόνο, ποιόν ενεργείας, φωνή, έγκλιση και πρόσωπο. Ένα λέξημα εμφανίζεται έτσι συστηματικά σε δεκάδες τύπους: στο συγκεκριμένο σώμα κειμένων το λέξημα «φοιτητής» εμφανίζεται σε 40 διακριτούς επιφανειακούς τύπους. Για τις στατιστικές συχνότητων αυτό καθιστά τη λημματοποίηση απαραίτητη και την ποιότητά της πρωτεύον ζήτημα. Η καθιερωμένη υποδομή είναι το μοντέλο `el_core_news_lg` του spaCy [9], του οποίου οι συστηματικές συμπεριφορές στο σώμα κειμένων (συμπεριλαμβανομένου ενός ελαττώματος σύνθετων λημμάτων για τα προθετικά συμφύματα) μετρώνται και διορθώνονται στο Κεφάλαιο 5. Το ελληνικό θεσμικό κείμενο, επιπλέον, σπάνια είναι μονόγλωσσο: οι ανακοινώσεις ενσωματώνουν αγγλικές περιλήψεις, ονόματα και ορολογία, οπότε μια ροή που απορρίπτει τις

λατινικές μονάδες απορρίπτει περιεχόμενο. Τα ελληνικά παραμένουν συγκριτικά γλώσσα περιορισμένων πόρων (η κάλυψή τους στις πολυγλωσσικές αξιολογήσεις ενσωματώσεων είναι πενιχρή), και γι' αυτό το Κεφάλαιο 6 επιλέγει το μοντέλο ενσωματώσεων με άμεση μέτρηση στο σώμα κειμένων αντί να εμπιστευθεί δημόσιους πίνακες κατάταξης.

Τέλος, το ίδιο το σύστημα γραφής επιβάλλει τεχνικούς περιορισμούς. Τα νέα ελληνικά χρησιμοποιούν από το 1982 το μονοτονικό σύστημα (μία οξεία και τα διαλυτικά), αλλά το Unicode επιτρέπει κάθε τονισμένο γράμμα να κωδικοποιείται είτε ως ένας συντεθειμένος χαρακτήρας είτε ως βασικό γράμμα συν συνδυαζόμενο σημάδι, και τα πραγματικά κείμενα αναμειγνύουν ελεύθερα τις δύο μορφές. Μια ροή που συγκρίνει μονάδες σε επίπεδο byte χωρίς κανονικοποίηση θα αντιμετωπίσει σιωπηλά τη «διατριβή» και το αποσυντεθειμένο δίδυμό της ως διαφορετικές λέξεις. Οι συμβάσεις προσθέτουν επιπλέον παγίδες: τα κεφαλαία ελληνικά κατά κανόνα δεν τονίζονται (ΕΚΛΟΓΕΣ έναντι εκλογές), και το σίγμα διαθέτει διακριτό τελικό τύπο (ς). Καθένα από αυτά εμφανίζεται κάπου στην εργασία: στην αφαίρεση τόνων του σταδίου χαρακτηρισμού, στα μη ευαίσθητα σε πεζά/κεφαλαία μοτίβα καθαρισμού, και στα ευρήματα κανονικοποίησης Unicode της Ενότητας 11.1. Με το υπόβαθρο αυτό, τα επόμενα κεφάλαια περνούν από τις έννοιες στο ίδιο το σώμα κειμένων.

# Κεφάλαιο 3

## Συλλογή και Έλεγχος Δεδομένων

### 3.1 Συλλογή δεδομένων

Τα δεδομένα συλλέχθηκαν από το ιστορικό αρχείο της tonima του Πανεπιστημίου Πατρών (mailarchive.upatras.gr), στο οποίο η πρόσβαση απαιτεί σύνδεση μέσω του πανεπιστημιακού VPN και χρήση πανεπιστημιακού λογαριασμού. Η ομάδα περιλαμβάνει μέλη ΔΕΠ, εργαζομένους, μεταπτυχιακούς φοιτητές και υποψήφιους διδάκτορες· οι προπτυχιακοί φοιτητές δεν αποτελούν μέλη της. Η announcements είναι υποομάδα της tonima και τα μηνύματά της περιλαμβάνονται στο ίδιο αρχείο. Οι σελίδες ευρετηρίου HTML εμφανίζουν είκοσι μηνύματα η καθεμία. Κάθε μήνυμα έχει χωριστή σελίδα, με πεδία Author, Date, To και Subject και σώμα μέσα σε στοιχείο <div class="messageBody">.

Ο scraper υλοποιήθηκε σε Python με τις βιβλιοθήκες urllib.request, ssl, certifi και BeautifulSoup [19]. Η BeautifulSoup προτιμήθηκε από ένα βαρύτερο πλαίσιο όπως το Scrapy επειδή η εργασία απαιτεί μόνο εξαγωγή απλού κειμένου από έναν μικρό, καλά δομημένο ιστότοπο χωρίς απόδοση JavaScript. Για κάθε σελίδα ευρετηρίου ο scraper συλλέγει τις σχετικές διευθύνσεις των είκοσι μηνυμάτων, τις συμπληρώνει με τον κόμβο του αρχείου, αναλύει κάθε σελίδα μηνύματος και εξάγει τα πέντε πεδία με εντοπισμό των μπλοκ HTML και διαχωρισμό των ετικετών των κεφαλίδων. Η διεύθυνση της επόμενης σελίδας ευρετηρίου λαμβάνεται από το στοιχείο σελιδοποίησης, και η διαδικασία επαναλαμβάνεται μέχρι να καλυφθεί το επιθυμητό χρονικό εύρος.

Επειδή το σώμα κειμένων αναμειγνύει ελληνική και λατινική γραφή, όλο το κείμενο κωδικοποιήθηκε και αποκωδικοποιήθηκε ως UTF-32 κατά τη συλλογή, και το σύνολο δεδομένων αποθηκεύτηκε ως αρχείο CSV με διαχωριστικό στηλοθέτη σε UTF-32. Εκ των υστέρων, το UTF-8 θα ήταν εξίσου ορθή και σημαντικά συμπαγέστερη επιλογή. Το UTF-32 διατηρήθηκε σε όλη τη ροή αποκλειστικά για συμβατότητα μεταξύ των σταδίων. Το ακατέργαστο σύνολο δεδομένων (tonima.csv) περιέχει 14.277 γραμμές και πέντε στήλες: Author, Date, To, Subject, Message.

### 3.2 Προέλευση δεδομένων και προστασία προσωπικών δεδομένων

Το ιστορικό αρχείο της tonima και της υποομάδας announcements έχει περιορισμένη πρόσβαση μέσω του VPN και λογαριασμού του Πανεπιστημίου Πατρών. Τα πρωτογενή δεδομένα χρησιμοποιήθηκαν για την ανάλυση της διπλωματικής και δεν δημοσιεύονται ούτε διατίθενται μαζί με την εργασία. Διατηρήθηκαν μόνο μέχρι την ολοκλήρωση της ανάλυσης και την παραγωγή των αποτελεσμάτων και στη συνέχεια διαγράφηκαν. Στο κείμενο παρουσιάζονται συγκεντρωτικά αποτελέσματα, όπως συχνότητες θεμάτων, στατιστικές συστάδων και χαρακτηριστικοί όροι, χωρίς αναπαραγωγή πλήρων μηνυμάτων. Κατά τον δομικό καθαρισμό, 1.380 από τα 13.692 μηνύματα (10,1%) επισημάνθηκαν στη στήλη contains\_pii\_pattern λόγω μοτίβων τηλεφώνων ή διευθύνσεων ηλεκτρονικού ταχυδρομείου.

### 3.3 Διερευνητική ανάλυση δεδομένων

Πριν από οποιονδήποτε καθαρισμό, ένα ειδικό notebook ελέγχου (02\_eda\_data\_audit.ipynb) χαρτογράφησε τα ακατέργαστα δεδομένα. Ο σκοπός του σταδίου είναι μεθοδολογικός: κάθε επόμενη ενέργεια καθαρισμού πρέπει να ανάγεται σε ένα καταγεγραμμένο, ποσοτικοποιημένο εύρημα. Τα ευρήματα που ακολουθούν αποτελούν το σημείο αναφοράς για τον δομικό και τον γλωσσικό καθαρισμό των δύο επόμενων κεφαλαίων. Τα κύρια ευρήματα συνοψίζονται στον Πίνακα 3.1.

| # | Εύρημα                                               | Μέγεθος                                          | Απόφαση                                                                     |
|---|------------------------------------------------------|--------------------------------------------------|-----------------------------------------------------------------------------|
| 1 | Διπλότυπα περιεχομένου στο ζεύγος (Subject, Message) | 327 γραμμές (έναντι μόλις 115 πλήρως ταυτόσημων) | Απαλοιφή διπλοτύπων βάσει περιεχομένου, διατήρηση της πρωιμότερης εμφάνισης |
| 2 | Μη αναλύσιμες ημερομηνίες                            | 3 γραμμές                                        | Διαγραφή                                                                    |
| 3 | Ελλιπές έτος 2017 (μόνο Δεκέμβριος)                  | 10 γραμμές                                       | Διαγραφή· θόρυβος εκκίνησης του scraper                                     |
| 4 | Ελλιπές έτος 2023 (Ιαν–Ιούλ)                         | 7 μήνες                                          | Διατήρηση· επισήμανση στα ετήσια διαγράμματα                                |
| 5 | Υπολείμματα HTML/CSS στα σώματα                      | ~20% των μηνυμάτων                               | Δομική αφαίρεση ετικετών· επισήμανση γραμμών                                |
| 6 | Αλυσίδες απαντήσεων/προωθήσεων στα θέματα            | ~6% των θεμάτων                                  | Επισήμανση, όχι διαγραφή                                                    |
| 7 | Σχεδόν κενά μηνύματα (<20 χαρακτήρες)                | 276 γραμμές                                      | Διαγραφή                                                                    |
| 8 | Ακατάστατο πεδίο παραληπτών (To)                     | 1.981 διακριτές ακατέργαστες τιμές               | Κανονικοποίηση σε κανονικές ετικέτες λιστών                                 |
| 9 | Ενσωματωμένα στοιχεία επικοινωνίας (PII)             | ~8–9% των μηνυμάτων                              | Επισήμανση για ελέγχους απόκρυψης στα παρατιθέμενα παραδείγματα             |

Πίνακας 3.1: Ευρήματα του ελέγχου δεδομένων και η απόφαση καθαρισμού που υπαγόρευσε το καθένα.

### 3.4 Σχήμα εισόδου χωρίς συλλογή από το διαδίκτυο

Η χρήση της ροής σε άλλο σώμα κειμένων μπορεί να ξεκινήσει απευθείας από dataframe, παρακάμπτοντας τη συλλογή από το διαδίκτυο. Ο πίνακας περιέχει μία γραμμή ανά μήνυμα και τις πέντε στήλες του Πίνακα 3.2. Το ίδιο σχήμα μπορεί να χρησιμοποιηθεί ως είσοδος σε μελλοντικό API.

Πίνακας 3.2: Σχήμα εισόδου για εφαρμογή χωρίς scraping.

| Στήλη   | Τύπος  | Περιεχόμενο                                                                     |
|---------|--------|---------------------------------------------------------------------------------|
| Author  | string | Αποστολέας ή κενό string όταν δεν διατίθεται.                                   |
| Date    | string | Έγκυρη ημερομηνία με ζώνη ώρας, π.χ. 2023-06-15 10:30 UTC.                      |
| To      | string | Λίστα ή παραλήπτες σε κείμενο· κενό string αν δεν υπάρχουν.                     |
| Subject | string | Θέμα στη φυσική γλώσσα· επιτρέπεται κενό string.                                |
| Message | string | Σώμα μηνύματος στη φυσική γλώσσα, πριν από ληματοποίηση και αφαίρεση stopwords. |

Τα ονόματα των στηλών διατηρούνται όπως στον πίνακα. Τα κενά κειμενικά πεδία δηλώνονται με κενή συμβολοσειρά και η Date πρέπει να είναι έγκυρη για τον καθαρισμό και τη χρονική ανάλυση. Για συμβατότητα με τα notebooks, η αποθήκευση γίνεται με διαχωριστικό tab και κωδικοποίηση UTF-32, χωρίς στήλη index. Οι cleaned\_text, embedding\_text, Date\_parsed, Year και θεματικές ετικέτες παράγονται στα επόμενα στάδια. Ένα API μπορεί να δέχεται UTF-8 JSON records και να τα μετατρέπει σε αυτό το σχήμα.

Σε νέο σώμα κειμένων χρειάζεται προσαρμογή των φίλτρων χρονικής κάλυψης και ερμηνεία των νέων συστάδων. Ειδικότερα, ο αποκλεισμός του 2017 αφορά μόνο την παρούσα συλλογή. Ένα μοναδικό document\_id θα διευκόλυνε την αντιστοίχιση μηνυμάτων και αποτελεσμάτων μετά από φιλτράρισμα ή ταξινόμηση. Στην υπάρχουσα υλοποίηση η αντιστοίχιση βασίζεται στη σειρά των γραμμών.

# Κεφάλαιο 4

## Δομική Προεπεξεργασία

Το δομικό στάδιο (03\_preprocessing.ipynb) υλοποιεί τις αποφάσεις ποιότητας δεδομένων σε επίπεδο γραμμής που υπαγόρευσε ο έλεγχος. Δεν εκτελεί καμία γλωσσική επεξεργασία. Η διατήρηση των δύο ζητημάτων σε ξεχωριστά notebooks καθιστά το καθένα ανεξάρτητα ελέγχιμο. Μετά την αφαίρεση ενός τεχνήματος του scraper (ένα αρχικό κενό σε κάθε πεδίο), το στάδιο διαγράφει τις 3 γραμμές με μη αναλύσιμες ημερομηνίες, τις 10 γραμμές του ελλιπούς έτους 2017, 326 διπλότυπα περιεχομένου (απαλοιφή βάσει του ζεύγους (Subject, Message) με διατήρηση της πρωιμότερης εμφάνισης, καθώς οι μεταγενέστερες ταυτόσημες εμφανίσεις αντιμετωπίζονται ως επαναποστολές) και 246 σχεδόν κενά μηνύματα, μειώνοντας το σώμα κειμένων από 14.277 σε 13.692 γραμμές: συνολική απώλεια 4,1%, με κάθε διαγραμμένη γραμμή να ανάγεται σε συγκεκριμένο εύρημα του ελέγχου.

Οι ετικέτες HTML αφαιρούνται με κανονική έκφραση αντιστοίχισης ετικετών, και οι επηρεαζόμενες γραμμές επισημαίνονται στη στήλη `had_html_markup` αντί να ξαναγράφονται σιωπηλά, ώστε η κλίμακα της παρέμβασης να παραμένει ορατή. Τα θέματα απαντήσεων/προωθήσεων επισημαίνονται ομοίως (`is_reply_or_forward`) αντί να διαγράφονται, αφού μια απάντηση μπορεί να φέρει πράγματι νέο περιεχόμενο.

### 4.1 Κανονικοποίηση του πεδίου παραληπτών

Το ακατέργαστο πεδίο Το περιείχε 1.981 διακριτές τιμές για ό,τι στην πραγματικότητα είναι μια χούφτα λιστών. Τα προβλήματα ήταν τρία. Ορισμένες γραμμές περιείχαν ολόκληρα αποσπάσματα συγκεντρωτικών μηνυμάτων (Old-Topics:, New-Topics:, CC:), ακόμη και πλήρη θέματα προωθημένων μηνυμάτων συνενωμένα μέσα στη συμβολοσειρά των παραληπτών, τέχνημα του scraper από διαφορετική διάταξη σελίδας του αρχείου. Οτιδήποτε από τους δείκτες αυτούς και μετά απορρίφθηκε ως μη ανακτήσιμο. Επιπλέον, παραλλαγές πεζών/κεφαλαίων, εισαγωγικών και γραφής των ίδιων λιστών (tovima, TOVIMA, tovima@upatras.gr, το βήμα, ανακοινώσεις, ...) ενοποιήθηκαν μέσω ρητής αντιστοίχισης σε έξι ετικέτες: `tovima` (69,0% των γραμμών), `announcements` (36,4%), `studentnews` (4,0%), `sdp` (2,1%), `info` (1,5%) και `all` (0,9%). Τέλος, μια μακριά ουρά αρκετών εκατοντάδων ονομάτων προσώπων και διευθύνσεων τμημάτων διατηρήθηκε σε ξεχωριστή στήλη `to_other_recipients` αντί να εξαναγκαστεί σε ψευδή κατηγορία. Η προκύπτουσα στήλη `to_lists` παρέχει ένα αδρό, ημι-ανεξάρτητο σήμα που αξιοποιείται αργότερα για ελέγχους λογικότητας των ανεπίβλεπτων συστάδων.

# Κεφάλαιο 5

## Γλωσσική Προεπεξεργασία

### 5.1 Δύο παράλληλες αναπαραστάσεις κειμένου

Η κεντρική σχεδιαστική απόφαση αυτού του σταδίου (04\_nlp\_preprocessing.ipynb) είναι ότι η ροή παράγει δύο παράλληλες στήλες κειμένου που εξυπηρετούν δύο διαφορετικούς καταναλωτές.

**embedding\_text:** αποθορυβοποιημένο αλλά γλωσσικά φυσικό δίγλωσσο κείμενο (αφαιρούνται διευθύνσεις URL, γραμμές παραθέσεων, προσφωνήσεις και αποφωνήσεις· τίποτε άλλο δεν θίγεται). Αυτή είναι η είσοδος του μοντέλου ενσωματώσεων. Τα σύγχρονα μοντέλα transformer εκπαιδεύονται σε φυσική γλώσσα. Η τροφοδότησή τους με λημματοποιημένο κείμενο χωρίς stopwords αλλοιώνει τη φυσική συντακτική δομή και αφαιρεί λειτουργικές λέξεις και κλιτική πληροφορία (για παράδειγμα, την ελληνική πτωτική σήμανση που διακρίνει το υποκείμενο από το αντικείμενο) που το μοντέλο εκπαιδεύτηκε να αξιοποιεί.

**cleaned\_text:** λημματοποιημένες, φιλτραρισμένες από stopwords και θόρυβο ακολουθίες μονάδων. Αυτή είναι η είσοδος της λεξιλογικής-στατιστικής πλευράς της ροής (χαρακτηρισμός συστάδων με TF-IDF και συνοχή NPMI), όπου η ακριβής αντιστοίχιση ταυτότητας μονάδων είναι το ζητούμενο. Τα ελληνικά είναι έντονα κλιτή γλώσσα: η άμεση μέτρηση στο σώμα κειμένων έδειξε την έννοια «φοιτητής» κατακερματισμένη σε 40 διακριτούς επιφανειακούς τύπους. Χωρίς λημματοποίηση, οι στατιστικές συχνοτήτων αντιμετωπίζουν τους τύπους αυτούς ως άσχετες μονάδες, αραιώνοντας κάθε καταμέτρηση στην οποία συμμετέχουν.

Η συγχώνευση των δύο αναπαραστάσεων (δηλαδή η τροφοδότηση λημματοποιημένου κειμένου και στο μοντέλο ενσωματώσεων) εξετάστηκε και απορρίφθηκε για τους παραπάνω λόγους.

### 5.2 Δομικός καθαρισμός κειμένου με μετρημένη κάλυψη

**Αφαίρεση διευθύνσεων URL.** Μια απλοϊκή έκφραση όπως `https?://\S+` κάνει διάκριση πεζών/κεφαλαίων και υποθέτει ότι δεν υπάρχουν κενά γύρω από τον διαχωριστή του σχήματος. Μετρημένη στο σώμα κειμένων, αφήνει υπόλειμμα `http/https` στο 2,8% των μηνυμάτων, λόγω διευθύνσεων γραμμένων με κεφαλαία και διευθύνσεων που αναδιπλώνονται σε νέα γραμμή με κενό πριν από το «`://`». Η έκφραση που υιοθετήθηκε αγνοεί πεζά/κεφαλαία και ανέχεται κενά γύρω από τον διαχωριστή, μειώνοντας το υπόλειμμα στο 0,9%. Το υπόλοιπο είναι μια μακριά ουρά μεμονωμένα κακοσχηματισμένων διευθύνσεων (αλυσίδες ανακατευθύνσεων με percent-encoding, ελλείποντα σύμβολα άνω-κάτω τελείας) που έγινε αποδεκτή ως τεκμηριωμένος υπολειπόμενος θόρυβος.

**Γραμμές παραθέσεων.** 939 μηνύματα (6,9%) περιέχουν γραμμές παράθεσης με πρόθεμα «>», σε ορισμένες περιπτώσεις μάλιστα αυτές συνιστούν ολόκληρο το σώμα. Αξιοσημείωτα, το σύνολο αυτό επικαλύπτεται μόνο μερικώς με την επισήμανση απαντήσεων/προωθήσεων στα θέματα (τα δύο σήματα διαφωνούν σε 770 γραμμές), επιβεβαιώνοντας ότι το παρατιθέμενο περιεχόμενο πρέπει να

ανιχνεύεται απευθείας στο σώμα. Οι γραμμές παράθεσης αφαιρούνται με έκφραση πολλαπλών γραμμών.

**Προσφωνήσεις.** Το πρώτο μοτίβο που αξιολογήθηκε περιοριζόταν στους τύπους ενικού του επιθέτου (αγαπητέ/αγαπητή). Η άμεση καταμέτρηση έδειξε ότι οι τύποι πληθυντικού (αγαπητοί: 985 εμφανίσεις, αγαπητές: 333, αγαπητά: 315) υπερτερούν των τύπων ενικού με λόγο περίπου τρία προς ένα, οπότε ένα τέτοιο μοτίβο χάνει περίπου το 80% των πραγματικών προσφωνήσεων, καλύπτοντας μόλις το 6,5% των μηνυμάτων. Το μοτίβο που υιοθετήθηκε καλύπτει όλους τους κλιτούς τύπους και δεσμεύεται ως προς τη θέση: μια αντιστοίχιση γίνεται δεκτή μόνο μέσα στους πρώτους 80 χαρακτήρες του μηνύματος, αφού η προσφώνηση εξ ορισμού ανοίγει ένα μήνυμα. Η κάλυψη ανέβηκε στο 16,6% χωρίς να βρεθούν ψευδώς θετικά στη χειροκίνητη επιθεώρηση.

**Αποφώνησεις.** Ένα μοτίβο αποφώνησης αγκυρωμένο στο τέλος του κειμένου ενεργοποιείται μόλις στο 0,1% των μηνυμάτων (οι υπογραφές σπανίως τερματίζουν το ακατέργαστο κείμενο), ενώ οι λέξεις-κλειδιά αποφώνησης (με εκτίμηση, ευχαριστώ, φιλικά) εμφανίζονται μεμονωμένα σε περίπου 6% των μηνυμάτων. Το αντίθετο άκρο, η άπληστη αντιστοίχιση από μια λέξη-κλειδί μέχρι το τέλος του κειμένου, υπερδιορθώνει: το 43% τέτοιων αντιστοιχίσεων θα παρέσυρε πάνω από 500 χαρακτήρες περιεχομένου, επειδή τα ελληνικά θεσμικά μηνύματα χρησιμοποιούν συχνά το «ευχαριστώ» ως ουσιαστικό περιεχόμενο («θα θέλαμε να ευχαριστήσουμε τον Πρύτανη για...») και όχι ως αποφώνηση. Ο κανόνας που υιοθετήθηκε αφαιρεί από την τελευταία εμφάνιση λέξης-κλειδιού μέσα στο τελευταίο τέταρτο του μηνύματος, και μόνο εφόσον η ουρά που προκύπτει είναι κάτω από 400 χαρακτήρες, μέγεθος συμβατό με πραγματικό μπλοκ υπογραφής. Η κάλυψη είναι 4,7%, με συνειδητή ανταλλαγή ανάκλησης έναντι ακρίβειας. Παραμένει μικρή υπολειπόμενη ανακρίβεια για μηνύματα που ευχαριστούν ουσιαστικά κάποιον και συγχρόνως κλείνουν τυπικά κοντά στο τέλος τους. Αυτή δηλώνεται ως γνωστός περιορισμός.

### 5.3 Λημματοποίηση και η διόρθωση των σύνθετων λημμάτων

Η λημματοποίηση χρησιμοποιεί το μοντέλο `el_core_news_lg` του spaCy [9]. Κατά την επαλήθευση εντοπίστηκε ένα συστηματικό ελάττωμα: ο λημματοποιητής επιστρέφει για τα ελληνικά προθετικά συμφύματα (πρόθεση + άρθρο) μια ενιαία συμβολοσειρά λήμματος με εσωτερικό κενό: το «στην» (σε + την) λημματοποιείται στην ενιαία μονάδα «σε ο». Επειδή το σύνολο των `stopwords` περιέχει μόνο μονολεκτικές εγγραφές, οι συγχωνευμένες αυτές μονάδες δεν αντιστοιχίζονταν με τίποτα και περνούσαν το φίλτρο, για να διασπαστούν κατόπιν μηχανικά ξανά σε δύο μονάδες κατά τη σειριοποίηση του καθαρισμένου κειμένου, εμφανιζόμενες ως μαζική διαρροή των `stopwords` «σε» και «ο» (μαζί 6,75% όλων των μονάδων του σώματος κειμένων). Η δειγματοληψία έδειξε ότι το 2,31% όλων των λημματικών μονάδων ήταν σύνθετα με κενό, εκ των οποίων το 99,3% ήταν η καθαρή περίπτωση σε+άρθρο. Η διόρθωση διασπά κάθε λήμμα που περιέχει κενό στις συνιστώσες μονάδες του πριν από το φιλτράρισμα `stopwords` (Απόσπασμα 5.1). Μετά τη διόρθωση, η μετρημένη διαρροή λειτουργικών λέξεων έπεσε από 6,75% σε 0,012% του σώματος κειμένων, ένα υπολειπόμενο δάπεδο θορύβου από διάσπαρτες οριακές περιπτώσεις τύπου/λήμματος.

```
# Το el_core_news_lg επιστρέφει "σε ο" ως ενιαίο λήμμα για συμφύματα
# όπως το "στην". τα λήμματα με κενό διασπώνται ΠΡΙΝ το φίλτρο
# stopwords, αλλιώς η συγχωνευμένη μονάδα δεν αντιστοιχίζεται πουθενά
lemmas = []
for token in doc:
    for part in token.lemma_.lower().split():
```

```

lemmas.append(part)
tokens = [t for t in lemmas
           if t not in GREEK_STOPWORDS and is_informative(t)]

```

Απόσπασμα 5.1: Η διόρθωση των σύνθετων λημμάτων (04\_nlp\_preprocessing.ipynb).

## 5.4 Φιλτράρισμα stopwords για ελληνικά και αγγλικά

Μια λίστα stopwords παραγόμενη από το ίδιο το σώμα κειμένων (απλώς οι 100 συχνότερες λέξεις) αξιολογήθηκε και απορρίφθηκε: λέξεις περιεχομένου ειδικές του ιδρύματος, όπως το «πανεπιστημίου», κατατάσσονται στην πρώτη τριακοντάδα κατά ακατέργαστη συχνότητα απλώς και μόνο επειδή κάθε μήνυμα προέρχεται από το ίδιο πανεπιστήμιο. Η αφαίρεσή τους αφαιρεί πραγματικό θεματικό σήμα. Η ροή χρησιμοποιεί αντ' αυτής τη γλωσσολογικά επιμελημένη ελληνική λίστα stopwords του spaCy (663 εγγραφές).

Τα αγγλικά απαίτησαν δική τους αντιμετώπιση. Το σώμα κειμένων περιέχει τρία είδη περιεχομένου σε λατινική γραφή: δομικό θόρυβο (οι ετικέτες θεμάτων [TOVIMA]/[ANNOUNCEMENTS]), τυποποιημένο κείμενο υπογραφών («University of Patras», «Department of Biology», παρόν στο 24% των μηνυμάτων) και γνήσιο αγγλικό περιεχόμενο (περιλήψεις εργασιών, προσκλήσεις συνεδρίων, τεχνικούς όρους όπως «biology» ή «semiconductor»). Δοκιμάστηκαν και απορρίφθηκαν, μετά από μέτρηση, ενδιαμέσοι σχεδιασμοί που αφαιρούσαν λατινικές μονάδες βάσει μήκους: κανένα κατώφλι μήκους δεν διαχωρίζει τα μεταγραμμένα ονόματα προσώπων από τον θόρυβο («thramboulidis» και «biochemistry» έχουν και τα δύο 12 χαρακτήρες), και η συλλήβδην αφαίρεση όλων των λατινικών μονάδων διαγράφει ακριβώς τις λέξεις περιεχομένου που μια σημασιολογική συσταδοποίηση οφείλει να ανακαλύψει. Ο τελικός σχεδιασμός είναι συμμετρικός με την ελληνική πλευρά: η αγγλική λίστα stopwords του spaCy (326 εγγραφές, μόνο λειτουργικές λέξεις) εφαρμόζεται στον επιφανειακό τύπο πριν από τη λημματοποίηση, και οι αγγλικές λέξεις περιεχομένου διατηρούνται. Το φιλτράρισμα πριν αγγίζει το κείμενο ο ελληνικός λημματοποιητής παρακάμπτει επίσης οποιαδήποτε απροσδιόριστη συμπεριφορά μιας ελληνικής υποδομής σε είσοδο λατινικής γραφής.

## 5.5 Κανονικοποίηση μοτίβων, θορυβώδεις μονάδες και όρια μήκους

Επιφανειακά μοτίβα με μεγάλη ποικιλομορφία αλλά ισοδύναμη σημασία αντικαθίστανται με δεσμευτικές μονάδες (placeholders) πριν από τη λημματοποίηση: ώρες ρολογιού (ΩΡΑ), ημερολογιακές ημερομηνίες και έτη (ΗΜΕΡΟΜΗΝΙΑ), ελληνικοί αριθμοί τηλεφώνου (ΤΗΛΕΦΩΝΟ), αναφορές αιθουσών (ΑΙΘΟΥΣΑ) και κωδικοί μαθημάτων (ΜΑΘΗΜΑ). Ένα φίλτρο θορύβου σε επίτεδο μονάδας αφαιρεί υπολείμματα HTML/CSS (nbsp, mso, Opt, style, width, ...), αμιγώς αριθμητικές μονάδες, μονάδες μόνο με στίξη και μονάδες ενός ή δύο χαρακτήρων.

Το στάδιο κλείνει με δύο όρια μήκους. Το ελάχιστο όριο μονάδων (min\_tokens = 5, εφαρμοζόμενο μετά τη λημματοποίηση και την αφαίρεση stopwords) αφαιρεί 51 γραμμές των οποίων το περιεχόμενο περιορίζεται σε λιγότερες από πέντε πληροφοριακές μονάδες, συμπληρωματικός έλεγχος προς το δομικό φίλτρο σχεδόν κενών μηνυμάτων, που πιάνει μηνύματα μακριά σε χαρακτήρες αλλά αποτελούμενα σχεδόν εξ ολοκλήρου από stopwords. Η μέγιστη περικοπή ορίστηκε

στις 1.000 μονάδες μετά από μέτρηση των υποψήφιων τιμών: στις 500 μονάδες θα περικοβόταν το 14,9% του σώματος κειμένων, και η επιθεώρηση των μακροσκελών μηνυμάτων στο όριο αυτό έδειξε ότι το αφαιρούμενο περιεχόμενο είναι ανάπτυξη του ίδιου θέματος και όχι θεματική μετατόπιση. Ένα αυστηρότερο όριο απορρίπτει σήμα χωρίς να προστατεύει τίποτα. Στις 1.000 μονάδες επηρεάζεται μόλις το 3,8% του σώματος κειμένων. Η τελική γλωσσική έξοδος είναι το `tonima_nlp_ready.csv` με 13.637 γραμμές.

## Κεφάλαιο 6

# Σημασιολογικές Αναπαραστάσεις Εγγράφων

### 6.1 Υπόβαθρο και μέτρο ομοιότητας

Με το κείμενο καθαρισμένο, η ροή περνά από τις μονάδες στη γεωμετρία: κάθε μήνυμα αναπαρίσταται ως πυκνό διάνυσμα παραγόμενο από μοντέλο ενσωματώσεων βασισμένο σε transformer [10]. Η σημασιολογική ομοιότητα δύο εγγράφων  $u$  και  $v$  μετριέται με τη συνημιτονική ομοιότητα:

$$\cos(u, v) = \frac{u \cdot v}{\|u\| \|v\|}$$

Στα αποθηκευμένα διανύσματα της συγκεκριμένης υλοποίησης γίνεται κανονικοποίηση L2 πριν από τη σημασιολογική σύγκριση. Για μοναδιαία διανύσματα, η συνημιτονική ομοιότητα ισούται με το εσωτερικό γινόμενο και η ευκλείδεια απόσταση είναι μονότονη συνάρτησή της. Η ιδιότητα αφορά αυτόν τον κανονικοποιημένο χώρο και δεν μεταφέρεται αυτόματα στην έξοδο του UMAP. Στον κώδικα το HDBSCAN χρησιμοποιεί ευκλείδεια απόσταση πάνω στην έξοδο UMAP 13 διαστάσεων, χωρίς πρόσθετη L2 κανονικοποίηση των μειωμένων συντεταγμένων.

### 6.2 Πείραμα επιλογής μοντέλου

Συγκρίθηκαν δύο τοπικά εκτελέσιμα υποψήφια μοντέλα: το qwen3-embedding:4b [13] (4,0 δισεκατομμύρια παράμετροι, έξοδος 2.560 διαστάσεων) και το BGE-M3 [6] (567 εκατομμύρια παράμετροι, 1.024 διαστάσεις). Αντί εμπιστοσύνης σε δημόσιους πίνακες κατάταξης (οι συνολικές επιδόσεις τους δεν αρκούν για το συγκεκριμένο ελληνικό πανεπιστημιακό σώμα), τα μοντέλα συγκρίθηκαν απευθείας στο σώμα κειμένων με έλεγχο ζευγών γνωστής αλήθειας. Ως αλήθεια αναφοράς χρησιμοποιήθηκαν τέσσερις κατηγορίες θεμάτων που είναι αδιαμφισβήτητες με απλή επιθεώρηση: παρουσιάσεις διπλωματικών/διδακτορικών (1.201 μηνύματα στο σώμα κειμένων), ανακοινώσεις COVID (117), αγγελίες πένθους (112) και τμηματικές εκλογές (129). Ελήφθησαν έξι μηνύματα ανά κατηγορία, από τα οποία σχηματίστηκαν 15 ζεύγη ίδιου θέματος και 15 ζεύγη διαφορετικού θέματος (23 μοναδικά κείμενα). Κάθε μοντέλο ενσωμάτωσε τα ίδια κείμενα, και υπολογίστηκαν δύο στατιστικές: το χάσμα (μέση ομοιότητα ίδιου θέματος μείον μέση ομοιότητα διαφορετικού θέματος, όπου μεγαλύτερο είναι καλύτερο) και η επικάλυψη (το ποσό κατά το οποίο το χειρότερο ζεύγος ίδιου θέματος βαθμολογείται κάτω από το καλύτερο ζεύγος διαφορετικού θέματος, όπου μικρότερη είναι καλύτερη, με το μηδέν να σημαίνει διαχωρίσιμες κατανομές).

| Μοντέλο            | Μ.Ο. ίδιου θέματος | Μ.Ο. διαφορετικού | Χάσμα | Επικάλυψη |
|--------------------|--------------------|-------------------|-------|-----------|
| qwen3-embedding:4b | 0,630              | 0,500             | 0,130 | 0,179     |
| BGE-M3             | 0,598              | 0,481             | 0,117 | 0,093     |

Πίνακας 6.1: Σύγκριση μοντέλων ενσωματώσεων σε 30 ζεύγη γνωστής αλήθειας.

Το qwen3 πετυχαίνει οριακά μεγαλύτερο μέσο χάσμα, αλλά το BGE-M3 μειώνει την επικάλυψη σχεδόν στο μισό (0,093 έναντι 0,179). Για τη συσταδοποίηση, η επικάλυψη είναι η στατιστική με τις

μεγαλύτερες συνέπειες: ένα μοντέλο του οποίου οι κατανομές ομοιότητας ίδιου και διαφορετικού θέματος διασταυρώνονται μπορεί να δυσκολεύεται στις οριακές περιπτώσεις, χωρίς το μικρό αυτό δείγμα να αποδεικνύει τη συμπεριφορά του σε όλο το σώμα. Η επιθεώρηση των χειρότερων ζευγών έδειξε ότι και τα δύο μοντέλα δυσκολεύτηκαν με τα ίδια γνησίως αμφίσημα στοιχεία (ιδίως μια ανακοίνωση για πρωτόκολλα COVID κατά την ημέρα εκλογών, που δικαιολογημένα εκτείνεται σε δύο κατηγορίες, ένδειξη ότι ο έλεγχος μετρά πραγματική δυσκολία και όχι τεχνήματα των μοντέλων). Επιλέχθηκε το BGE-M3. Ένας πρακτικός περιορισμός ενίσχυσε την επιλογή: το μοντέλο των 4 δισεκατομμυρίων παραμέτρων υπερβαίνει τα 4 GB VRAM της διαθέσιμης κάρτας γραφικών (GTX 970) και είναι υπολογιστικά βαρύτερο στο συγκεκριμένο υλικό, ενώ το BGE-M3 εκτελείται άνετα. Και τα δύο μοντέλα αξιολογήθηκαν αποκλειστικά σε CPU (πaráμετρος num\_gpus 0 στο Modelfile του Ollama) ώστε η σύγκριση να είναι ισότιμη.

### 6.3 Παραγωγή των ενσωματώσεων

Και τα 13.637 μηνύματα ενσωματώθηκαν από τη στήλη embedding\_text με BGE-M3 μέσω Ollama [20], σε CPU, με Modelfile num\_ctx 8192, num\_batch 8192 και num\_gpus 0. Οι είσοδοι περιορίστηκαν σε 7.000 χαρακτήρες, επηρεάζοντας 511 μηνύματα (3,7%). Το όριο χαρακτήρων δεν ταυτίζεται με όριο 8.192 υπολεξικών μονάδων. Η περικοπή είναι πρακτική επιλογή της εφαρμογής και μπορεί να αφαιρεί θεματικά χρήσιμο περιεχόμενο· η αναπαράσταση CLS δεν προσφέρει εγγύηση αμελητέας επίδρασης. Η εκτέλεση διήρκεσε περίπου 2 ώρες και 11 λεπτά σε Intel i5-6500 και παρήγαγε πίνακα  $13.637 \times 1.024$  τύπου float32 χωρίς NaN ή ολομηδενικές γραμμές, ευθυγραμμισμένο με το dataframe. Δεν μετρήθηκε στην παρούσα εφαρμογή η μεταβολή των ενσωματώσεων με και χωρίς περικοπή.

# Κεφάλαιο 7

## Συσταδοποίηση

### 7.1 Επισκόπηση

Το στάδιο συσταδοποίησης είναι ο αναλυτικός πυρήνας της ροής: απεικονίζει τις κανονικοποιημένες ενσωματώσεις μέσω PCA (γραμμική προ-μείωση), κατόπιν UMAP (μη γραμμική μείωση σε χαμηλοδιάστατη πολλαπλότητα) και τέλος HDBSCAN (πυκνотική συσταδοποίηση). Οι υπερπαραμέτροι του συνδυασμού UMAP+HDBSCAN επιλέγονται με αναζήτηση 200 δοκιμών μέσω Optuna που μεγιστοποιεί μια αντικειμενική συνάρτηση βασισμένη στη συνοχή, ακολουθούμενη από δύο βήματα μετεπεξεργασίας: συγχώνευση σχεδόν όμοιων συστάδων ανεξάρτητη από τη σειρά επεξεργασίας, και συντηρητική επανατοποθέτηση σημείων θορύβου.

### 7.2 Προ-μείωση με PCA

Η PCA [14] προβάλλει τις ενσωματώσεις 1.024 διαστάσεων στις κύριες κατευθύνσεις διακύμανσης. Με τον πίνακα προβολής  $W$  περιορισμένο σε ορθοκανονικές στήλες, οι συνιστώσες μεγιστοποιούν τη διατηρούμενη διακύμανση. Το σώμα κειμένων παρουσιάζει σταδιακή φθορά της διακύμανσης χωρίς έντονο «αγκώνα» (τυπικό των αναπαραστάσεων οικογένειας BERT), με τις 300 συνιστώσες να διατηρούν το 91,0% της διακύμανσης. Η ροή χρησιμοποιεί 256 συνιστώσες, διατηρώντας το 87,7%, ως συμβιβασμό μεταξύ της δομής που διατηρείται και του κόστους κατασκευής του γράφου γειτόνων του UMAP. Η PCA λειτουργεί εδώ αμιγώς ως υπολογιστική προ-μείωση· τη μη γραμμική δομή που ενδιαφέρει τη συσταδοποίηση την ανακτά το UMAP.

### 7.3 UMAP

Το UMAP [3] (Uniform Manifold Approximation and Projection) κατασκευάζει έναν ασαφή γράφο πάνω στους  $k$  κοντινότερους γείτονες κάθε σημείου στον χώρο εισόδου και βρίσκει μια χαμηλοδιάστατη διάταξη της οποίας ο ασαφής γράφος ταιριάζει με τον αρχικό. Για το σημείο  $i$  με γείτονα  $j$ , η κατευθυνόμενη ισχύς συμμετοχής είναι

$$p_{j|i} = \exp\left(-\frac{\max(0, d(x_i, x_j) - \rho_i)}{\sigma_i}\right)$$

όπου  $\rho_i$  είναι η απόσταση προς τον πλησιέστερο γείτονα (εξασφαλίζοντας τοπική συνεκτικότητα) και  $\sigma_i$  ένα εύρος ανά σημείο επιλεγμένο ώστε το ενεργό μέγεθος γειτονιάς να ταιριάζει με το  $n\_neighbors$ . Οι συμμετρικοποιημένες συμμετοχές  $p_{ij} = p_{j|i} + p_{i|j} - p_{j|i} p_{i|j}$  ορίζουν τον ασαφή γράφο υψηλών διαστάσεων. Στον χώρο ενσωμάτωσης, η ομοιότητα σημείων  $y_i, y_j$  μοντελοποιείται ως  $q_{ij} = (1 + a\|y_i - y_j\|^{2b})^{-1}$ , και η διάταξη ελαχιστοποιεί τη διασταυρούμενη εντροπία ασαφών συνόλων μεταξύ των δύο γράφων:

$$CE = \sum_{ij} \left[ p_{ij} \ln \frac{p_{ij}}{q_{ij}} + (1 - p_{ij}) \ln \frac{1 - p_{ij}}{1 - q_{ij}} \right]$$

Το UMAP εκτελείται με συνημιτονική μετρική πάνω στην έξοδο της PCA. Οι παράμετροι `n_neighbors` (τοπικότητα της εκτίμησης της πολλαπλότητας), `n_components` (διάσταση-στόχος) και `min_dist` (πυκνότητα διάταξης) αφήνονται στην αναζήτηση υπερπαραμέτρων αντί να καθοριστούν εκ των προτέρων.

## 7.4 HDBSCAN

Το HDBSCAN [4, 5] εκτελεί ιεραρχική πυκνοτική συσταδοποίηση. Η πυκνότητα αποτυπώνεται μέσω της απόστασης πυρήνα ενός σημείου, δηλαδή της απόστασης προς τον  $k$ -οστό κοντινότερο γείτονα του ( $k = \text{min\_samples}$ ), και της απόστασης αμοιβαίας προσβασιμότητας μεταξύ σημείων  $a$  και  $b$ :

$$d_{\text{mreach}}(a, b) = \max\{\text{core}_k(a), \text{core}_k(b), d(a, b)\}$$

Ένα ελάχιστο συνδετικό δένδρο πάνω στις αποστάσεις αμοιβαίας προσβασιμότητας δίνει μια ιεραρχία συνεκτικών συνιστωσών καθώς μεταβάλλεται ένα κατώφλι πυκνότητας  $\lambda = 1/d$ . Συστάδες μικρότερες από `min_cluster_size` αντιμετωπίζονται ως σημεία που εγκαταλείπουν τη μητρική τους συστάδα και όχι ως συστάδες. Η σταθερότητα κάθε συστάδας είναι το ολοκλήρωμα της συμμετοχής της στο εύρος του  $\lambda$  για το οποίο επιβιώνει,

$$S(C) = \sum_{x \in C} (\lambda_x - \lambda_{\text{birth}}(C))$$

και το κριτήριο excess-of-mass (EOM) επιλέγει το σύνολο των μη επικαλυπτόμενων συστάδων που μεγιστοποιεί τη συνολική σταθερότητα. Σημεία που δεν απορροφώνται ποτέ από καμία επιλεγμένη συστάδα λαμβάνουν την ετικέτα θορύβου (-1), έγκυρο αποτέλεσμα πρώτης τάξης: μεμονωμένες ανακοινώσεις χωρίς σημασιολογικούς γείτονες υπάρχουν πράγματι σε ένα αρχείο λιστών, και ο εξαναγκασμός τους σε συστάδες μόνο θα τις μόλυνε. Το HDBSCAN χρησιμοποιεί ευκλείδεια απόσταση στον μειωμένο χώρο 13 διαστάσεων που παράγει το UMAP. Η μετρική εφαρμόζεται στις μειωμένες συντεταγμένες, όπως περιγράφεται στην Ενότητα 6.1.

## 7.5 Αντικειμενική συνάρτηση και αναζήτηση υπερπαραμέτρων

Το σήμα ποιότητας που καθοδηγεί την αναζήτηση είναι η σημασιολογική συνοχή, υπολογιζόμενη στον αρχικό (προ-PCA) χώρο ενσωματώσεων ώστε να είναι ανεξάρτητη από τη μείωση που ρυθμίζεται. Για μια επισήμανση  $L$  με συστάδες  $C_1 \dots C_m$  και κεντροειδή  $\mu_j$ :

$$\text{Coh}(L) = \frac{\sum_j |C_j| \cdot \text{median}_{x \in C_j} \cos(x, \mu_j)}{\sum_j |C_j|}$$

Η διάμεσος (αντί του μέσου όρου) καθιστά τη βαθμολογία κάθε συστάδας ανθεκτική σε λίγα ακραία μέλη. Η στάθμιση κατά μέγεθος εμποδίζει πολλές μικροσκοπικές σφιχτές συστάδες να κυριαρχήσουν στη βαθμολογία επιπέδου σώματος κειμένων. Το Απόσπασμα 7.1 δείχνει την υλοποίηση. Σημειώνεται ότι δέχεται τις αρχικές ενσωματώσεις 1.024 διαστάσεων, όχι τη μειωμένη αναπαράσταση που ρυθμίζεται.

```
def semantic_coherence(embeddings, labels, min_cluster_size=10):
    scores, weights = [], []
    for c in set(labels) - {-1}:
        idx = np.where(labels == c)[0]
```

```

if len(idx) < min_cluster_size:
    continue
vecs = embeddings[idx]
centroid = vecs.mean(axis=0, keepdims=True)
sims = cosine_similarity(vecs, centroid).ravel()
scores.append(np.median(sims))
weights.append(len(idx))
return float(np.average(scores, weights=weights))

```

Απόσπασμα 7.1: Το μέτρο σημασιολογικής συνοχής (07\_clustering.ipynb).

Η πλήρης αντικειμενική συνάρτηση είναι

$$S = Coh(L) - 1.0 \cdot \max(0, \nu - 0.15) - 0.3 \cdot \max\left(0, 1 - \frac{\tilde{m}}{50}\right)$$

όπου  $\nu$  το ποσοστό θορύβου και  $\tilde{m}$  το διάμεσο μέγεθος συστάδας. Και οι δύο σταθερές ποινής βαθμονομήθηκαν στα δεδομένα: πιλοτικές εκτελέσεις έδειξαν ότι με λογικές παραμέτρους προκύπτει φυσικά περίπου 15% θόρυβος, οπότε η ανοχή τοποθετείται εκεί (μια χαλαρότερη ανοχή 20% με το μισό βάρος δοκιμάστηκε και σχεδόν ποτέ δεν ενεργοποιήθηκε). Ο όρος κατακερματισμού αναμένει οι συστάδες να έχουν κατά μέσο όρο τουλάχιστον 50 μηνύματα σε σώμα 13.637 μηνυμάτων. Αποτελέσματα με λιγότερες από 5 ή περισσότερες από 200 συστάδες απορρίπτονται εξ αρχής. Δύο συνιστώσες που εμφανίζονται συχνά σε τέτοιες αντικειμενικές συναρτήσεις δοκιμάστηκαν και απορρίφθηκαν. Μια εκ των προτέρων προτίμηση  $\nu$  για το πλήθος συστάδων αποκλείστηκε επειδή στερείται ερείσματος για πυκνοτική συσταδοποίηση και αντιστρατεύεται ενεργά την ικανότητα του αλγορίθμου να βρει τη δομή που πράγματι υπάρχει. Η βαθμολογία σταθερότητας του HDBSCAN αποκλείστηκε ομοίως από την αντικειμενική συνάρτηση (παραμένει καταγεγραμμένη ανά δοκιμή) αφού μια σάρωση παραμέτρων έδειξε ισχυρή συσχέτισή της με την παραγωγή λιγότερων, μεγαλύτερων συστάδων (η σταθερότητα ήταν κατά μέσο όρο 0,32 σε λύσεις 7 συστάδων έναντι 0,15 σε λύσεις 21 συστάδων), οπότε η στάθμισή της θα μερολήπτει συστηματικά την αναζήτηση προς αδρές λύσεις.

Το Απόσπασμα 7.2 δείχνει τον πυρήνα βαθμολόγησης της αντικειμενικής συνάρτησης, όπως αποτιμάται σε κάθε δοκιμή.

```

n_clusters = len(set(labels) - {-1})
if n_clusters < 5 or n_clusters > 200:
    return -999.0 # άμεση απόρριψη
noise_pct = float(np.mean(labels == -1))
coherence = semantic_coherence(embeddings_orig, labels)
sizes = [np.sum(labels == c) for c in set(labels) - {-1}]
median_size = float(np.median(sizes))
noise_penalty = max(0.0, noise_pct - 0.15) * 1.0
frag_penalty = max(0.0, 1.0 - median_size / 50.0) * 0.3
score = coherence - noise_penalty - frag_penalty

```

Απόσπασμα 7.2: Αποτίμηση της αντικειμενικής συνάρτησης μέσα στη δοκιμή του Optuna (07\_clustering.ipynb).

Ο χώρος αναζήτησης ήταν:  $n\_neighbors \in [10, 50]$ ,  $n\_components \in [5, 20]$ ,  $min\_dist \in [0, 0.1]$ ,  $min\_cluster\_size \in [30, 150]$  (το ανυψωμένο κατώτατο όριο λειτουργεί ως δομικό ανάχωμα κατά του κατακερματισμού, συμπληρωματικό της ποινής στην αντικειμενική συνάρτηση),  $min\_samples \in [3, min\_cluster\_size/3]$ . Ο δειγματολήπτης TPE του Optuna [7, 18] εκτέλεσε 200 δοκιμές χωρίς ενεργό pruning. Η καλύτερη δοκιμή πέτυχε βαθμολογία 0,8081 με  $n\_neighbors = 11$ ,  $n\_components = 13$ ,  $min\_dist = 0,0141$ ,  $min\_cluster\_size = 32$ ,  $min\_samples = 4$ , παράγοντας 116 συστάδες με 15,45% θόρυβο και συνοχή 0,8126.

## 7.6 Μετεπεξεργασία

### 7.6.1 Συγχώνευση σχεδόν όμοιων συστάδων

Το HDBSCAN κατά περίπτωση υπερτεμαχίζει ένα θέμα για λόγους πυκνότητας. Ζεύγη συστάδων των οποίων τα κεντροειδή υπερβαίνουν συνημιτονική ομοιότητα 0,92 συγχωνεύονται. Το κατώφλι βαθμονομήθηκε έναντι της εμπειρικής κατανομής των ανά ζεύγη ομοιοτήτων κεντροειδών: η δια-συσταδική ομοιότητα συγκεντρώνεται γύρω στο 0,73, λιγότερα από δέκα ζεύγη υπερέβαιναν το 0,92 σε πιλοτική λύση, και κανένα δεν υπερέβαινε το 0,95. Το 0,92 βρίσκεται δηλαδή σε αραιή περιοχή και δεν τέμνει πυκνή ζώνη. Η συγχώνευση υπολογίζεται ως συνεκτικές συνιστώσες του γράφου με ακμές τα ζεύγη πάνω από το κατώφλι (Απόσπασμα 7.3), κατασκευή ανεξάρτητη από τη σειρά επεξεργασίας. Η προφανής άπληστη εναλλακτική (απορρόφηση, για κάθε συστάδα κατά σειρά αναγνωριστικού, κάθε αχρησιμοποίητης συστάδας πάνω από το κατώφλι) απορρίφθηκε επειδή η έξοδος της εξαρτάται από τη σειρά των αναγνωριστικών όποτε υπάρχουν τρίγωνα ομοιότητας (οι συστάδες 15/22/23 στην πιλοτική λύση σχημάτιζαν τέτοιο τρίγωνο: και οι τρεις ανά ζεύγη ομοιότητες υπερέβαιναν ή πλησίαζαν το κατώφλι, οπότε η έξοδος ενός άπληστου βρόχου εξαρτάται από το ποια συστάδα τυχαίνει να επεξεργαστεί πρώτη). Η συγχώνευση μείωσε τις 116 συστάδες σε 107.

```
sims = cosine_similarity(centroid_matrix) # k x k
adj = {i: set() for i in range(k)}
for i in range(k):
    for j in range(i + 1, k):
        if sims[i, j] > 0.92:
            adj[i].add(j); adj[j].add(i)
# συνεκτικές συνιστώσες μέσω BFS: κάθε αμοιβαία όμοια ομάδα
# συγχωνεύεται ως σύνολο, ανεξάρτητα από τη σειρά επεξεργασίας
visited, groups = set(), []
for start in range(k):
    if start in visited: continue
    comp, queue = [], [start]
    while queue:
        node = queue.pop()
        if node in visited: continue
        visited.add(node); comp.append(node)
        queue.extend(adj[node] - visited)
    groups.append(comp)
```

*Απόσπασμα 7.3: Συγχώνευση συστάδων ανεξάρτητη από τη σειρά επεξεργασίας (07\_clustering.ipynb).*

### 7.6.2 Συντηρητική επανατοποθέτηση θορύβου

Ορισμένα σημεία που το HDBSCAN χαρακτηρίζει θόρυβο είναι οριακές περιπτώσεις υπάρχουσας συστάδας. Ένα σημείο θορύβου επανατοποθετείται στο πλησιέστερο επιλέξιμο κεντροειδές μόνο εφόσον ισχύουν και οι τρεις συνθήκες: ομοιότητα με το κεντροειδές αυτό τουλάχιστον 0,80· μέτρο εσωτερικής διασποράς της συστάδας ( $1 - \text{μέση ομοιότητα μέλους-κεντροειδούς}$ ) το πολύ 0,25· και


διαφορά ομοιότητας τουλάχιστον 0,05 από το δεύτερο πλησιέστερο επιλέξιμο κεντροειδές (φραγή αμφισημίας: ένα σημείο σχεδόν ισαπέχον από δύο συστάδες βρίσκεται πράγματι ανάμεσά τους). Στην τελική λύση, 302 από τα 2.107 σημεία θορύβου (14,3%) έχουν ομοιότητα τουλάχιστον 0,80 με κάποιο κεντροειδές συστάδας που ικανοποιεί το όριο εσωτερικής διασποράς. Από αυτά, 96 σημεία ικανοποιούν και την απαίτηση διαφοράς τουλάχιστον 0,05 από το δεύτερο πλησιέστερο επιλέξιμο κεντροειδές και επανατοποθετούνται (4,6% του αρχικού θορύβου). Ο συνδυασμός των κριτηρίων περιορίζει την επανατοποθέτηση σε περιπτώσεις με σαφέστερη αντιστοίχιση προς υπάρχουσα συστάδα. Τα υπόλοιπα σημεία διατηρούν την ετικέτα θορύβου και εξετάζονται με τους περιορισμούς που αναφέρονται στη συνέχεια. Τελικό αποτέλεσμα: 107 συστάδες, 2.011 σημεία θορύβου (14,7%), διάμεσο μέγεθος συστάδας 72, μεγαλύτερη 938, μικρότερη 32.

Η ετικέτα -1 αποδίδεται στα μηνύματα που παραμένουν εκτός συστάδων μετά τη μετεπεξεργασία. Σε αυτά μπορεί να περιλαμβάνονται μεμονωμένες ανακοινώσεις, αμφίσημα μηνύματα και μικρές θεματικές ομάδες. Το αποτέλεσμα εξαρτάται από την αναπαράσταση και τα κατώφλια της μεθόδου. Για μια μελλοντική υπηρεσία, η εξέταση αυτών των μηνυμάτων θα μπορούσε να συμβάλει στον εντοπισμό νέων θεμάτων (Ενότητα 11.3).


Το ποσοστό θορύβου 14,7% περιγράφει την κάλυψη της συγκεκριμένης διαμέρισης. Αξιολογείται μαζί με τη συνοχή και την ερμηνευσιμότητα των συστάδων, αφού αυστηρότερα κατώφλια μπορούν να αυξάνουν τη συνοχή των διατηρούμενων ομάδων αφήνοντας περισσότερα μηνύματα μη ανατεθειμένα.

## 7.7 Απεικόνιση διανυσμάτων και συστάδων


Η Εικόνα 7.1 παρουσιάζει δισδιάστατες προβολές PCA των κανονικοποιημένων ενσωματώσεων BGE-M3 και της εξόδου UMAP 13 διαστάσεων. Οι δύο πρώτες συνιστώσες διατηρούν αντίστοιχα 8,99% και 60,70% της διακύμανσης. Ο χρωματισμός ακολουθεί τις τελικές θεματικές ετικέτες. Η απώλεια πληροφορίας, ιδιαίτερα στην πρώτη προβολή, περιορίζει την ερμηνεία των οπτικών αποστάσεων και επικαλύψεων.



Εικόνα 7.1: Προβολές PCA δύο διαστάσεων των αρχικών ενσωματώσεων BGE-M3 (πάνω) και της αποθηκευμένης εξόδου UMAP 13 διαστάσεων (κάτω), με χρώμα ανά κύρια θεματική και γκριζο θόρυβο.




Εικόνα 7.2: Κατανομή των μεγεθών των 107 συστάδων (διάμεσος 72, μέγιστο 938).



Εικόνα 7.3: Τα αναγνωριστικά των 107 τελικών συστάδων στην προβολή PCA της εξόδου UMAP.

Η Εικόνα 7.4 συμπληρώνει τις προβολές με τη συνημιτονική ομοιότητα των κεντροειδών στον αρχικό χώρο 1.024 διαστάσεων. Οι συστάδες ταξινομούνται ανά κύρια θεματική και οι λευκές γραμμές διαχωρίζουν τις κατηγορίες. Η ομοιότητα εκφράζει τη συγγένεια των μέσων αναπαραστάσεων.

Για τη διαδραστική εξερεύνηση των αποτελεσμάτων δημιουργήθηκε το συνοδευτικό εργαλείο `cluster_explorer.html`. Ο χρήστης μπορεί να εναλλάσσει τις διαστάσεις προβολές των αρχικών ενσωματώσεων BGE-M3 και της αποθηκευμένης εξόδου UMAP, να χρωματίζει τα σημεία ανά κύρια θεματική ή συστάδα και να φιλτράρει τη θεματική που τον ενδιαφέρει. Το αναπτυσσόμενο μενού συστάδων περιορίζεται στις διαθέσιμες επιλογές της επιλεγμένης θεματικής, ενώ η μετακίνηση του δείκτη πάνω από ένα σημείο εμφανίζει την ετικέτα του χωρίς το σώμα του μηνύματος. Οι προβολές διευκολύνουν την οπτική επιθεώρηση της λύσης, με τον περιορισμό της απώλειας πληροφορίας κατά τη μείωση σε δύο διαστάσεις.



Εικόνα 7.4: Συνημιτονική ομοιότητα των κεντροειδών των τελικών συστάδων στις αρχικές ενσωματώσεις, ταξινομημένων ανά κύρια θεματική.

## Κεφάλαιο 8

# Χαρακτηρισμός Συστάδων και Θεματική Ταξινόμια

### 8.1 Εξαγωγή όρων με TF-IDF

Για να αξιοποιηθεί η δομή που ανακαλύφθηκε, κάθε συστάδα πρέπει να μπορεί να διαβαστεί. Χαρακτηρίζεται επομένως από τους πλέον διακριτικούς της όρους, υπολογισμένους με TF-IDF [15, 16] πάνω στη λημματοποιημένη στήλη `cleaned_text` των 11.626 επισημασμένων μηνυμάτων. Με τη διατύπωση του `scikit-learn` [12] και υπογραμμική συχνότητα όρων, το βάρος του όρου  $t$  στο έγγραφο  $d$  είναι

$$w(t, d) = (1 + \ln tf(t, d)) \cdot \left( \ln \frac{1 + N}{1 + df(t)} + 1 \right)$$

ακολουθούμενο από κανονικοποίηση L2 κάθε διανύσματος εγγράφου. Η υπογραμμική κλιμάκωση εμποδίζει ένα μεμονωμένο μήνυμα που επαναλαμβάνει μια λέξη πενήντα φορές (σύνηθες στις προωθημένες ανακοινώσεις) να κυριαρχήσει. Η εξομαλυσμένη IDF υποβαθμίζει τους όρους που είναι κοινοί σε όλο το σώμα κειμένων. Περιορισμοί λεξιλογίου: `unigrams` και `bigrams`: ένας όρος πρέπει να εμφανίζεται σε τουλάχιστον 5 μηνύματα (`min_df = 5`, ρύθμιση που εξαλείφει μεμονωμένα τεχνήματα λημματοποίησης και θραύσματα προσωπικών ονομάτων από υπογραφές) και σε έως 60% των μηνυμάτων· οι μονάδες πρέπει να έχουν τουλάχιστον 4 χαρακτήρες (οι τρίγραμμα μονάδες στο σώμα κειμένων είναι σχεδόν αποκλειστικά θραύσματα ή θόρυβος).

Η εναλλακτική εφαρμογή τυπικού TF-IDF σε ένα συγκεντρωτικό έγγραφο ανά συστάδα μειώνει τη λεπτομέρεια των συχνοτήτων εγγράφων και δεν διατηρεί την κατανομή παρουσίας ενός όρου ανά μήνυμα. Δεν είναι το ίδιο με το `c-TF-IDF` του `BERTopic`, του οποίου η αντίστροφη στάθμιση βασίζεται στις συνολικές συχνότητες όρων στις κλάσεις [2]. Η παρούσα ροή προσαρμόζει τυπικό TF-IDF σε όλα τα 11.626 επισημασμένα μηνύματα χωριστά (λεξιλόγιο 64.088 όρων) και χρησιμοποιεί τον μέσο όρο των βαρών των μελών ως περιγραφή συστάδας. Η διάκριση αυτή επιτρέπει να λαμβάνεται υπόψη πόσο συστηματικά εμφανίζεται ένας όρος στα μέλη της.

Της διανυσματοποίησης προηγούνται δύο κανονικοποιήσεις σε επίπεδο κειμένου. Κατ' αρχάς, μια ρητή λίστα εξαιρέσεων αφαιρείται από το ίδιο το κείμενο (όχι απλώς εκ των υστέρων από τις λίστες κορυφαίων όρων, πράγμα που θα άφηνε μολυσμένα `bigrams` όπως «`tonima` διανομη»): οι δεσμευτικές μονάδες των μοτίβων (ημερομηνια, ωρα, ...), οι δομικές ετικέτες λιστών (`tonima`, `announcements`) και το υπολειπόμενο αγγλικό τυποποιημένο κείμενο (`the`, `and`, `of`, `university`). Οι μονάδες αυτές δεν φέρουν θεματικό σήμα: οι δεσμευτικές μονάδες εμφανίζονται σχεδόν σε κάθε ανακοίνωση και οι ετικέτες σχεδόν σε κάθε θέμα εκ κατασκευής. Έπειτα, οι ελληνικοί τόνοι αφαιρούνται μέσω αποσύνθεσης Unicode NFD (αφαίρεση συνδυαζόμενων σημαδιών), ενοποιώντας τις τονισμένες/άτονες παραλλαγές λημμάτων της ίδιας λέξης (διπλωματική/διπλωματική) που ο λημματοποιητής εκπέμπει ασυνεπώς και που διαφορετικά θα διασπούσαν τις καταμετρήσεις των όρων.

## 8.2 Θεματική ταξινόμια

Οι 15 κορυφαίοι όροι ανά συστάδα, μαζί με δειγματοληπτημένα θέματα μηνυμάτων, στήριξαν τη χειροκίνητη απόδοση ετικέτας δύο επιπέδων σε κάθε συστάδα: μιας ειδικής θεματικής που περιγράφει το περιεχόμενό της και μιας κύριας θεματικής που ομαδοποιεί συγγενείς συστάδες. Οι 107 συστάδες οργανώνονται σε 16 κύριες θεματικές ενότητες. Η λεπτομέρεια της συσταδοποίησης διαχωρίζει, για παράδειγμα, εκλογές προέδρων τμημάτων, κοσμητόρων και εκπροσώπων προσωπικού, καθώς και διακριτές σειρές ακαδημαϊκών ανακοινώσεων. Η κύρια κατηγορία Elections & Governance καλύπτει τα πανεπιστημιακά όργανα, ενώ οι εκλογές συλλόγων προσωπικού εντάσσονται στη Labour & Union Affairs. Η μισθοδοσία αποτελεί ειδική θεματική της University Administration. Η Infrastructure & Digital Services περιλαμβάνει φυσικές και ψηφιακές παροχές και η Health & Welfare περιλαμβάνει θέματα υγείας και κοινωνικής μέριμνας. Το χειροκίνητο βήμα οργανώνει τις συστάδες σε ευρύτερες κατηγορίες χωρίς να καταργεί τη λεπτότερη δομή τους. Οι ονομασίες διατηρούνται στα αγγλικά, όπως στα αρχεία της ανάλυσης και στα διαγράμματα, ώστε πίνακες και εικόνες να παραμένουν συνεπείς.

| Κύρια θεματική                     | Συστάδες | Μηνύματα |
|------------------------------------|----------|----------|
| Academic Events                    | 25       | 3.596    |
| University Administration          | 12       | 1.336    |
| Campus Life                        | 13       | 1.296    |
| Labour & Union Affairs             | 10       | 1.047    |
| Research & Funding                 | 8        | 871      |
| Elections & Governance             | 8        | 717      |
| Health & Welfare                   | 8        | 684      |
| Infrastructure & Digital Services  | 6        | 462      |
| Informal Discussion                | 5        | 444      |
| Postgraduate Programmes            | 2        | 362      |
| Innovation & Entrepreneurship      | 4        | 257      |
| University Rankings & Distinctions | 2        | 193      |
| Miscellaneous                      | 1        | 179      |
| Continuing Education               | 1        | 80       |
| Gender Equality & Inclusion        | 1        | 69       |
| International Programmes           | 1        | 33       |
| (Θόρυβος — μη αποδοθέντα)          | —        | 2.011    |

Πίνακας 8.1: Η ταξινόμια κύριων θεματικών πάνω στις 107 συστάδες.

Από τη χειροκίνητη επιθεώρηση περίπου σαράντα συστάδων εντοπίστηκε μία σαφώς ασυνάρτητη ομάδα, η συστάδα 65 με 179 μηνύματα. Περιέχει προσκλήσεις σεμιναρίων, απαντήσεις και άσχετες ανακοινώσεις, με κοινό γνώρισμα ένα επαναλαμβανόμενο αγγλικό μπλοκ υπογραφής. Της αποδίδεται η κατηγορία Miscellaneous. Η επιθεώρηση καλύπτει μέρος των 107 συστάδων.

# Κεφάλαιο 9

## Επικύρωση

Η φυσική ένσταση απέναντι σε κάθε βελτιστοποίηση ενός μόνο μέτρου είναι ότι το αποτέλεσμα είναι καλό μόνο κατά το μέτρο στο οποίο ρυθμίστηκε. Το κεφάλαιο αυτό την απαντά με τρεις ανεξάρτητους ελέγχους.

### 9.1 Σύγκριση με μεθόδους αναφοράς

Ο k-means (MiniBatch [17], 5 αρχικοποιήσεις) και η συσσωρευτική συσταδοποίηση (σύνδεση Ward [22]) εκτελέστηκαν με το ίδιο  $k = 107$  στις ίδιες μειωμένες από PCA ενσωματώσεις, και βαθμολογήθηκαν με την ταυτόσημη συνάρτηση συνοχής. Και οι δύο μέθοδοι αναφοράς αναθέτουν κάθε σημείο (χωρίς θόρυβο), ενώ η προτεινόμενη ροή αφήνει το 14,7% μη ανατεθειμένο· η διαφορά κάλυψης πρέπει να συνεκτιμάται στη σύγκριση.

Στις μεθόδους αναφοράς χρησιμοποιείται  $k = 107$ , όπως προέκυψε από τη ροή HDBSCAN, χωρίς χωριστή αναζήτηση του  $k$ . Η προτεινόμενη ροή έχει βελτιστοποιηθεί ως προς τη σημασιολογική συνοχή και αξιολογείται στα ανατεθειμένα μηνύματα, ενώ k-means και Ward αναθέτουν κάθε μήνυμα σε συστάδα. Το NPMI προσθέτει έναν έλεγχο που δεν συμμετείχε στην αντικειμενική συνάρτηση, αλλά υπολογίζεται στο ίδιο σώμα κειμένων. Οι διαφορές που ακολουθούν ερμηνεύονται με αυτούς τους όρους· δεν έχει διεξαχθεί έλεγχος στατιστικής σημαντικότητας.

### 9.2 Λεξιλογική συνοχή NPMI

Η κανονικοποιημένη σημειακή αμοιβαία πληροφορία [8] υπολογίζεται από τη `cleaned_text`, χωρίς χρήση διανυσμάτων. Για κάθε συστάδα επιλέγονται έως δέκα όροι με τη μεγαλύτερη συχνότητα εγγράφων μέσα στη συστάδα, με λεξικογραφική επίλυση ισοβαθμιών. Προηγείται κανονικοποίηση NFC για την ενοποίηση κανονικά ισοδύναμων ελληνικών τύπων. Η βαθμολογία κάθε ζεύγους είναι


$$NPMI(t_i, t_j) = \frac{\ln P(t_i, t_j) - \ln P(t_i)P(t_j)}{-\ln P(t_i, t_j)}$$

Οι πιθανότητες υπολογίζονται στο κοινό σώμα αναφοράς των 13.637 μηνυμάτων, συμπεριλαμβανομένου του θορύβου. Η  $p(w)$  είναι το ποσοστό εγγράφων που περιέχουν τον όρο και η  $p(w_i, w_j)$  το ποσοστό που περιέχουν και τους δύο όρους. Το παράθυρο συνεμφάνισης είναι ολόκληρο το μήνυμα. Οι όροι επιλέγονται μέσα σε κάθε συστάδα, ενώ οι πιθανότητες εκτιμώνται στο σύνολο του σώματος. Το NPMI κυμαίνεται στο  $[-1, 1]$ : το μηδέν αντιστοιχεί σε ανεξαρτησία, η θετική τιμή σε συχνότερη και η αρνητική σε σπανιότερη συνεμφάνιση από την αναμενόμενη. Σε μηδενική συνεμφάνιση χρησιμοποιείται  $-1$ . Όταν και οι δύο όροι εμφανίζονται παντού, ο παρονομαστής μηδενίζεται και ορίζεται συμβατικά τιμή 0. Η βαθμολογία συστάδας είναι ο μέσος όρος των ζευγών, έως 45 για δέκα όρους, και η συνολική βαθμολογία ο μέσος όρος σταθμισμένος κατά μέγεθος συστάδας.

| Μέθοδος                     | Σημαιολογική συνοχή | NPMI   |
|-----------------------------|---------------------|--------|
| HDBSCAN (η παρούσα ροή)     | 0,8111              | 0,2067 |
| k-means (k = 107)           | 0,7999              | 0,1892 |
| Συσσωρευτική Ward (k = 107) | 0,8005              | 0,1945 |

Πίνακας 9.1: Σύγκριση με τις μεθόδους αναφοράς και στα δύο μέτρα.

Η προτεινόμενη ροή έχει σημαιολογική συνοχή 0,8111, έναντι 0,7999 για k-means και 0,8005 για Ward. Οι αντίστοιχες τιμές NPMI είναι 0,2067, 0,1892 και 0,1945. Η διαφορά NPMI είναι +0,0175 από το k-means και +0,0121 από τη Ward. Οι δύο μετρήσεις δίνουν υψηλότερες τιμές για τη ροή HDBSCAN, με τη διαφορά κάλυψης και την επιλογή μοντέλου να συνεκτιμώνται όπως περιγράφεται στην Ενότητα 9.1.



Εικόνα 9.1: Σύγκριση HDBSCAN, k-means και Ward ως προς τη σημαιολογική συνοχή και το NPMI, με άξονες που ξεκινούν από το μηδέν.

### 9.3 Ανάλυση ευαισθησίας

Για την ανάλυση ευαισθησίας, καθεμία από τις τέσσερις διακριτές υπερπαραμέτρους της επιλεγμένης λύσης μεταβλήθηκε κατά  $\pm 20\%$ , με τις υπόλοιπες ρυθμίσεις σταθερές (οκτώ διαμορφώσεις). Ο έλεγχος αφορά το στάδιο UMAP+HDBSCAN πριν από τη συγχώνευση και την επανατοποθέτηση θορύβου. Εξετάζεται η μεταβολή της συνοχής στο ίδιο σώμα κειμένων γύρω από τις επιλεγμένες τιμές.

| Διαταραχή                     | Συστάδες | Θόρυβος % | Συνοχή |
|-------------------------------|----------|-----------|--------|
| βάση (βέλτιστες παράμετροι)   | 116      | 15,5      | 0,8126 |
| n_neighbors -20% (11→9)       | 132      | 19,3      | 0,8163 |
| n_neighbors +20% (11→13)      | 123      | 17,3      | 0,8148 |
| n_components -20% (13→10)     | 129      | 17,4      | 0,8152 |
| n_components +20% (13→16)     | 128      | 18,5      | 0,8169 |
| min_cluster_size -20% (32→26) | 154      | 18,4      | 0,8189 |

| Διαταραχή                     | Συστάδες | Θόρυβος % | Συνοχή |
|-------------------------------|----------|-----------|--------|
| min_cluster_size +20% (32→38) | 98       | 18,0      | 0,8102 |
| min_samples -20% (4→3)        | 128      | 19,3      | 0,8159 |
| min_samples +20% (4→5)        | 118      | 17,2      | 0,8150 |

Πίνακας 9.2: Ευαισθησία της λύσης σε διαταραχές υπερπαραμέτρων  $\pm 20\%$ .

Στην ανάλυση ευαισθησίας η συνοχή κυμαίνεται μεταξύ 0,8102 και 0,8189, με τυπική απόκλιση 0,0024 και μέγιστη απόκλιση 0,0063 από τη βάση. Το πλήθος συστάδων κυμαίνεται από 98 έως 154. Ο έλεγχος καλύπτει τις τέσσερις διακριτές υπερπαραμέτρους και καταγράφει μικρή μεταβολή της συνοχής, χωρίς μέτρηση της συμφωνίας των μελών μεταξύ διαμερίσεων. Η min\_dist και το seed παραμένουν σταθερά.


# Κεφάλαιο 10

## Διαχρονική Ανάλυση

Η χρονική ανάλυση εξετάζει τις συχνότητες των θεμάτων στην επικοινωνία της tonima και της υποομάδας announcements (10\_temporal\_analysis.ipynb). Τα έτη 2018–2022 καλύπτονται πλήρως, ενώ το 2023 περιλαμβάνει μόνο Ιανουάριο–Ιούλιο και σημειώνεται στα διαγράμματα. Τα εποχικά προφίλ υπολογίζονται στα πλήρη έτη. Οι συχνότητες εκφράζουν πλήρη μηνυμάτων, μαζί με απαντήσεις, διορθώσεις και υπενθυμίσεις, και όχι μοναδικά γεγονότα. Η περιγραφική εξέταση που ακολουθεί αναδεικνύει χρονικές συγκεντρώσεις και επαναλαμβανόμενα μοτίβα· δεν περιλαμβάνει τυπικό στατιστικό έλεγχο εποχικότητας.

### 10.1 Συνολική κίνηση του ιστορικού αρχείου


Η συνολική κίνηση είναι αξιοσημείωτα σταθερή στα έξι έτη: 2.248 μηνύματα το 2018, 2.625 το 2019, 2.437 το 2020, 2.440 το 2021, 2.545 το 2022, και 1.342 στους επτά μήνες του 2023 (μηνιαίος ρυθμός 191,7, εντός του εύρους των πλήρων ετών). Η πανδημία δεν άφησε ορατό ίχνος στον όγκο: ο όγκος του αρχείου ούτε εκτοξεύθηκε ούτε κατέρρευσε το 2020–2021. Οι ετήσιες μετρήσεις στρέφουν το ενδιαφέρον στη θεματική σύνθεση της επικοινωνίας της ομάδας, χωρίς να αποκλείουν μεταβολές σε μικρότερες χρονικές κλίμακες.



Εικόνα 10.1: Μηνύματα ανά έτος (αριστερά· το 2023 ελλιπές, με διαγράμμιση) και μέσος όρος μηνυμάτων ανά μήνα (δεξιά).

### 10.2 Θεματική σύνθεση ανά έτος

Η Εικόνα 10.2 παρακολουθεί το μερίδιο της ετήσιας κίνησης για τις οκτώ μεγαλύτερες κύριες θεματικές. Η Academic Events παραμένει η κυρίαρχη κατηγορία σε όλη την περίοδο (21,7–32,1% της κίνησης), με κάμψη το 2020 και ανάκαμψη το 2021. Η University Administration κορυφώνεται το 2019 (13,5%), ενώ το μερίδιό της το 2020 είναι 9,1% και το 2023 7,5%. Η Campus Life υποχωρεί από 13,3% το 2018 σε 7,9% το 2021 και αυξάνεται σε 9,2% το 2022. Η Health & Welfare εμφανίζει το μεγαλύτερο μερίδιό της το 2020 (9,4%). Οι μεταβολές αφορούν τη σύνθεση των μηνυμάτων της ομάδας· δεν μετρούν άμεσα τη φυσική παρουσία στην πανεπιστημιούπολη ή τη δραστηριότητα όλων των φοιτητών.




Εικόνα 10.2: Μεριδίο κάθε κύριας θεματικής στην κίνηση του ιστορικού αρχείου τονίμα ανά έτος, για τις οκτώ μεγαλύτερες θεματικές (\* 2023: Ιαν-Ιούλ).

Η σύγκριση του πρώτου και του τελευταίου πλήρους έτους (2018 έναντι 2022) ποσοτικοποιεί τις μετατοπίσεις στη σύνθεση. Τα μεγαλύτερα κέρδη μεριδίου είχαν οι Health & Welfare (+4,17 ποσοστιαίες μονάδες) και Labour & Union Affairs (+3,49 π.μ.). Ακολουθούν οι Infrastructure & Digital Services (+1,61 π.μ.), Gender Equality & Inclusion (+1,53 π.μ.) και University Rankings & Distinctions (+1,48 π.μ.). Τις μεγαλύτερες απώλειες είχαν οι Campus Life (-4,10 π.μ.), Research & Funding (-4,02 π.μ.) και Postgraduate Programmes (-2,25 π.μ.), ενώ η Academic Events υποχώρησε κατά 1,67 π.μ. Οι μεταβολές δείχνουν εντονότερη επικοινωνιακή παρουσία θεμάτων υγείας, εργασιακών διεκδικήσεων και υποδομών. Δεν αποδεικνύουν αιτιότητα ή ότι ένα θέμα απουσίαζε από τη θεσμική ζωή πριν από την αύξησή του.

### 10.3 Η πανδημία ως έλεγχος χρονικής εγκυρότητας


Οι υποθεματικές COVID-19 της Health & Welfare προσφέρουν μια ποιοτική ένδειξη ότι οι ανεπίβλεπτες συστάδες παρακολουθούν πραγματικά γεγονότα. Η Εικόνα 10.3 συνενώνει τις συστάδες 3, 9, 14, 68 και 93, που αφορούν ελέγχους, μέτρα προστασίας, εγκυκλίους και την πανεπιστημιακή λειτουργία κατά την πανδημία. Οι 418 εγγραφές κατανέμονται σε 2 το 2018, 4 το 2019, 190 το 2020, 101 το 2021, 92 το 2022 και 29 στους επτά μήνες του 2023. Οι λίγες εγγραφές πριν από το 2020 αποτυπώνουν τα ετερογενή όρια των συστάδων και δεν ερμηνεύονται ως ανακοινώσεις COVID-19. Η μεγαλύτερη μηνιαία συγκέντρωση εμφανίζεται τον Μάρτιο 2020 (67 μηνύματα), τον μήνα που έκλεισαν τα ελληνικά πανεπιστήμια. Η επικοινωνία παραμένει ενεργή το 2021-2022 με ελέγχους, οδηγίες και ρυθμίσεις διδασκαλίας και εξετάσεων. Η συσταδοποίηση δεν χρησιμοποιεί χρονική πληροφορία. Η συμφωνία του χρονικού μοτίβου με το περιεχόμενο και το γνωστό γεγονός αποτελεί ποιοτική ένδειξη εγκυρότητας, χωρίς να ισοδυναμεί με εξωτερική επικύρωση ή με πλήρη καταγραφή όλων των σχετικών μηνυμάτων.



Εικόνα 10.3: Μηνιαίος όγκος των σχετικών με COVID-19 συστάδων 3, 9, 14, 68 και 93 της Health & Welfare. Η μεγαλύτερη αιχμή εμφανίζεται τον Μάρτιο 2020.

## 10.4 Θεσμικοί εκλογικοί κύκλοι


Η θεματική Elections & Governance εμφανίζει τη χρονική υπογραφή των πανεπιστημιακών οργάνων. Οι τρεις μεγαλύτεροι μήνες είναι ο Ιούλιος 2020 (124 μηνύματα), ο Ιούνιος 2022 (96) και ο Νοέμβριος 2019 (46). Η κορυφή του Ιουλίου 2020 συμπίπτει με την περίοδο των πρωτανικών εκλογών, αλλά το πλήθος αφορά ολόκληρη την κύρια κατηγορία και όχι αποκλειστικά την υποθεματική των πρωτανικών εκλογών. Επαναλαμβανόμενες συγκεντρώσεις γύρω από τον Ιούνιο είναι συμβατές με τις ανακοινώσεις εκλογών προέδρων τμημάτων και κοσμητόρων που περιέχει η θεματική. Το ετήσιο μερίδιο είναι 8,2% το 2020 και 3,4% το 2021. Τα πλήθη μετρούν μηνύματα, μαζί με υπενθυμίσεις και απαντήσεις, όχι αριθμό εκλογικών διαδικασιών.



Εικόνα 10.4: Θεματική Elections & Governance, μηνιαίος όγκος. Η μεγαλύτερη κορυφή εμφανίζεται τον Ιούλιο 2020, στην περίοδο των πρωτανικών εκλογών.

## 10.5 Ακαδημαϊκή εποχικότητα


Στα πλήρη έτη 2018–2022, το μερίδιο της Academic Events στη μηνιαία κίνηση είναι υψηλότερο τον Φεβρουάριο (32,7%) και τον Ιούνιο (30,2%). Τον Ιούλιο είναι 25,5%, ενώ οι χαμηλότερες τιμές εμφανίζονται τον Αύγουστο (18,6%) και τον Απρίλιο (19,9%). Πρόκειται για συγκεντρωτικό προφίλ πολλών ειδών ακαδημαϊκών ανακοινώσεων, χωρίς ομοιόμορφη κορύφωση όλων των υποθεματικών. Η Master's Thesis Presentations έχει τη μεγαλύτερη μηνιαία αιχμή τον Ιούνιο 2022 (45 μηνύματα), ενώ η PhD Defense Announcements τον Ιούλιο 2020 (29). Οι διαφορετικές ετήσιες κορυφές υποδεικνύουν ακαδημαϊκό ρυθμό με διαφοροποιήσεις ανά υποθεματική και έτος, χωρίς να ισοδυναμούν με στατιστικό έλεγχο εποχικότητας.



Εικόνα 10.5: Μερίδιο της Academic Events στη συνολική μηνιαία κίνηση, με συνάθροιση μόνο των πλήρων ετών 2018–2022.


## 10.6 Εποχικές ευχές και προσκλήσεις μεταπτυχιακών

Η υποθεματική Holiday Greetings της Campus Life περιλαμβάνει 125 μηνύματα. Η μεγαλύτερη μηνιαία συγκέντρωση εμφανίζεται τον Δεκέμβριο 2018, με 17 μηνύματα. Ο Δεκέμβριος είναι επίσης ο μήνας κορύφωσης σε κάθε πλήρες έτος 2018–2022 (Εικόνα 10.6), όπως αναμένεται από το περιεχόμενο των εορταστικών ευχών.




Εικόνα 10.6: Μηνιαίος όγκος Campus Life και Holiday Greetings. Ο Δεκέμβριος επαναλαμβάνεται ως ετήσια κορυφή των ευχών στα πλήρη έτη.

Η Postgraduate & Doctoral Admissions / Programme Announcements της Postgraduate Programmes περιλαμβάνει 324 μηνύματα, με μέγιστο τον Ιούλιο 2018 (33). Οι ετήσιες κορυφές εμφανίζονται τον Ιούλιο 2018, τον Ιούλιο 2019, τον Ιούνιο 2020, τον Σεπτέμβριο 2021 και τον Ιούλιο 2022 (Εικόνα 10.7). Οι προσκλήσεις και οι ανακοινώσεις προγραμμάτων μεταπτυχιακών και διδακτορικών σπουδών συγκεντρώνονται κυρίως γύρω από τη θερινή περίοδο, με μεταβολές στον μήνα κορύφωσης.



Εικόνα 10.7: Μηνιαίος όγκος Postgraduate Programmes και Postgraduate & Doctoral Admissions / Programme Announcements, με άξονα μήνα και έτους.


Η Εικόνα 10.8 παρουσιάζει χωριστά τις Master's Thesis Presentations (938 μηνύματα) και PhD Defense Announcements (819) της Academic Events. Οι διαφορετικές αιχμές δείχνουν ότι η συνολική κατηγορία περιλαμβάνει επιμέρους κύκλους ανακοινώσεων. Τα ειδικά θέματα αποτελούν υποσύνολα της κύριας κατηγορίας και εμφανίζονται σε χωριστό πλαίσιο.



Εικόνα 10.8: Μηνιαίος όγκος Academic Events, Master's Thesis Presentations και PhD Defense Announcements.



## 10.7 Συζητήσεις αναδιάρθρωσης και αυξανόμενη θεματολογία ισότητας

Η University Restructuring, TEI Merger & Law School Debate της University Administration περιλαμβάνει 254 μηνύματα. Το 2019 καταγράφονται 187, έναντι 30 το 2018 και 19 το 2020. Οι μεγαλύτερες συγκεντρώσεις είναι ο Μάρτιος 2019 με 76 μηνύματα, ο Απρίλιος με 43 και ο Ιούλιος με 35 (Εικόνα 10.9). Τα θέματα των μηνυμάτων αναφέρονται σε σχέδια απορρόφησης TEI, πανεπιστημιακή αναδιάρθρωση και τη συζήτηση για ίδρυση Νομικής Σχολής, συνδέοντας τη χρονική αιχμή με τη συγκεκριμένη συζήτηση.



Εικόνα 10.9: Μηνιαίος όγκος University Administration και University Restructuring, TEI Merger & Law School Debate.

Η Gender Equality & Inclusion περιλαμβάνει μία ειδική θεματική, Gender Equality Committee Events & Announcements, οπότε οι καμπύλες της Εικόνας 10.10 συμπίπτουν. Οι ετήσιοι όγκοι είναι 1, 3, 0, 14, 40 και 11 για το 2018–2023, με το τελευταίο έτος να καλύπτει επτά μήνες. Η μεγαλύτερη μηνιαία συγκέντρωση είναι ο Μάρτιος 2022 (8). Η αύξηση από το 2021 δείχνει εντονότερη παρουσία του θέματος στο αρχείο, όπου υπήρχαν ήδη λίγα μηνύματα το 2018–2019.




Εικόνα 10.10: Μηνιαίος όγκος της κύριας και ειδικής θεματικής ισότητας. Τα επίπεδα είναι ταυτόσημα επειδή η κύρια κατηγορία περιέχει μία υποθεματική.

## 10.8 Υποδομές, ψηφιακές υπηρεσίες και εξ αποστάσεως λειτουργία

Η Infrastructure & Digital Services περιλαμβάνει 462 μηνύματα σε έξι υποθεματικές φυσικών και ψηφιακών παροχών. Οι ετήσιοι όγκοι για το 2018–2023 είναι 53, 51, 86, 115, 101 και 56, με το 2023 να καλύπτει Ιανουάριο–Ιούλιο. Η Εικόνα 10.11 παρουσιάζει την κύρια κατηγορία και δύο ψηφιακές υποθεματικές. Η σύνδεση με την εξ αποστάσεως λειτουργία εξετάζεται στις ψηφιακές υποθεματικές, καθώς η κύρια κατηγορία περιλαμβάνει και φυσικές υποδομές.

Η eClass & Exams Platform Announcements περιέχει 33 μηνύματα, από τα οποία 16 το 2021: 4 τον Ιανουάριο και 5 τον Φεβρουάριο. Το περιεχόμενο αφορά αναβαθμίσεις eClass/exams, το πρόβλημα πρόσβασης της 3ης Φεβρουαρίου 2021, συζητήσεις αξιολόγησης με το eClass και οδηγίες Zoom για επιτήρηση εξετάσεων. Η συγκέντρωση συνδέεται έτσι με την επικοινωνία για την εξ αποστάσεως εκπαιδευτική λειτουργία.



Εικόνα 10.11: Μηνιαίος όγκος Infrastructure & Digital Services, eClass & Exams Platform Announcements και IT Services & Network Interruptions.

Η IT Services & Network Interruptions περιέχει 73 μηνύματα, με μέγιστο ετήσιο όγκο 24 το 2021. Τα 6 μηνύματα του Μαρτίου 2021 περιλαμβάνουν ενημερώσεις και υπενθυμίσεις για αναβάθμιση του «Ψηφιακού Άλματος» και προγραμματισμένη διακοπή δικτύου. Η μεγαλύτερη μηνιαία συγκέντρωση, τον Ιούλιο 2020 (8), περιλαμβάνει τόσο διακοπές υπηρεσιών όσο και ανακοινώσεις ακαδημαϊκών ταυτοτήτων και ψηφιακών υπογραφών.

Η Digital Services & Mixed Institutional Announcements (62 μηνύματα) περιλαμβάνει ιστοτόπους και μικτές θεσμικές ανακοινώσεις. Οι άλλες υποθεματικές καλύπτουν Campus Utilities & Technical Services (179), Liquid Nitrogen Distribution (66) και Equipment & Consumables Exchange (49). Η ετερογένεια ορισμένων συστάδων περιορίζει την ερμηνεία της συνολικής καμπύλης.

# Κεφάλαιο 11

## Συμπεράσματα, Περιορισμοί και Μελλοντικά Βήματα

### 11.1 Περιορισμοί

Η κάλυψη της έρευνας περιορίζεται στο ιστορικό αρχείο της tonima και στα μέλη της ομάδας, όπως περιγράφονται στην Ενότητα 3.1. Ανακοινώσεις που αφορούν προπτυχιακή διδασκαλία μπορεί να περιλαμβάνονται στο αρχείο, παρότι οι προπτυχιακοί δεν συμμετέχουν στην ομάδα. Οι θεματικές συχνότητες περιγράφουν επομένως αυτή την επικοινωνία και όχι το σύνολο της πανεπιστημιακής κοινότητας.

Οι περιορισμοί που ακολουθούν έχουν ποσοτικοποιηθεί όπου αυτό ήταν εφικτό. Η αφαίρεση αποφωνήσεων ανταλλάσσει ανάκληση με ακρίβεια (κάλυψη 4,7%) και μπορεί να περικόψει λίγες λέξεις στο σπάνιο μήνυμα που ευχαριστεί ουσιαστικά κάποιον και συγχρόνως κλείνει τυπικά κοντά στο τέλος του. Η αφαίρεση διευθύνσεων URL αφήνει θραύσματα στο 0,9% των μηνυμάτων, μια μακριά ουρά μεμονωμένα κακοσχηματισμένων διευθύνσεων. Η περικοπή της εισόδου των ενσωματώσεων αγγίζει το 3,7% των μηνυμάτων, χωρίς ποσοτική μέτρηση της απώλειας σημασιολογικής πληροφορίας. Η προσέγγιση των αγγλικών stopwords διατηρεί εκ σχεδιασμού τις αγγλικές λέξεις περιεχομένου, οπότε μεταγραμμένα ονόματα προσώπων από μπλοκ υπογραφών μπορούν να εμφανιστούν στους όρους TF-IDF (ελέγχθηκαν μέσω  $\min\_df = 5$ , αλλά μία συστάδα, η 65, παραμένει συγκροτημένη κυρίως από επαναλαμβανόμενη υπογραφή). Τα δεδομένα του 2023 καλύπτουν μόνο Ιανουάριο–Ιούλιο, οπότε κάθε σύγκριση συχνοτήτων μεταξύ ετών οφείλει να επισημαίνει το έτος αυτό. Το UMAP εκτελέστηκε με σταθερό seed. Η ανάλυση ευαισθησίας καλύπτει την ανθεκτικότητα στις υπερπαραμέτρους, όχι τη διακύμανση του seed. Τέλος, το NPMI εξαρτάται από την επιλογή όρων και το παράθυρο συνεμφάνισης. Υπολογίζεται στο ίδιο σώμα με τη συσταδοποίηση και δεν υποκαθιστά ανθρώπινη αξιολόγηση ή εξωτερικό σύνολο ελέγχου.

Οι κεφαλίδες κανονικοποιούνται από τον scraper με NFKD, ενώ τα σώματα περιέχουν κυρίως NFC κείμενο. Στο TF-IDF οι τύποι ενοποιούνται με αφαίρεση τόνων και στο NPMI με κανονικοποίηση NFC. Η επίδραση της διαφοράς αυτής στις ενσωματώσεις παραμένει αμέτρητη. Σε μελλοντική εφαρμογή προτείνεται ενιαία κανονικοποίηση NFC πριν από την επεξεργασία όλων των πεδίων, ώστε να υπάρχει συνέπεια και στις αναζητήσεις των κεφαλίδων.

## 11.2 Συμπεράσματα

Η εφαρμογή οργανώνει 13.637 μηνύματα σε 107 συστάδες και 16 κύριες θεματικές, αφήνοντας το 14,7% μη ανατεθειμένο. Η σημασιολογική συνοχή είναι 0,8111, έναντι 0,7999 για k-means και 0,8005 για Ward, και το NPMI 0,2067, έναντι 0,1892 και 0,1945. Η ανάλυση ευαισθησίας καταγράφει μικρές μεταβολές της συνοχής στις εξετασμένες ρυθμίσεις. Στη χρονική ανάλυση εμφανίζονται η πανδημία, οι εκλογικοί κύκλοι, οι ευχές του Δεκεμβρίου, η αναδιάρθρωση του 2019, η αυξημένη επικοινωνία για την ισότητα των φύλων και οι ψηφιακές υπηρεσίες το 2020–2021. Τα αποτελέσματα δείχνουν ότι η μεθοδολογία μπορεί να χρησιμεύσει ως βάση για πιλοτική υπηρεσία θεματικής οργάνωσης του αρχείου.

Πέρα από το κεντρικό αποτέλεσμα, η μεθοδολογική συνεισφορά της εργασίας έγκειται στην πειθαρχία που εφαρμόστηκε σε κάθε στάδιο: τα μοτίβα καθαρισμού κειμένου ελέγχθηκαν ως προς την κάλυψή τους (η ανίχνευση προσφωνήσεων ανεβαίνει από 6,5% σε 16,6% των μηνυμάτων μόλις καλυφθούν όλοι οι κλιτοί τύποι· ένα ελάττωμα του λημματοποιητή που διέρρηξε το 6,75% των μονάδων ως αφιltrάριστα stopwords περιορίστηκε στο 0,012%)· υποψήφιος συνιστώσες της αντικειμενικής συνάρτησης αποκλείστηκαν μόνο αφού αποδείχθηκε η μεροληψία τους· και κάθε κατώφλι της μετεπεξεργασίας (ομοιότητα συγχώνευσης 0,92, ομοιότητα επανατοποθέτησης 0,80, όριο εσωτερικής διασποράς 0,25) τοποθετήθηκε εκεί όπου η αντίστοιχη εμπειρική κατανομή είναι αραιή.

## 11.3 Μελλοντικά βήματα

Η αξιοποίηση της εργασίας μπορεί να ξεκινήσει με πιλοτική υπηρεσία θεματικής πλοήγησης και σημασιολογικής αναζήτησης στο αρχείο του Πανεπιστημίου. Μια διαδικτυακή διεπαφή θα επέτρεπε την αναζήτηση και εξέταση θεμάτων, ενώ ένα API θα δεχόταν πίνακες μηνυμάτων ή JSON records με το σχήμα της Ενότητας 3.4. Για μεγάλες παρτίδες, η επεξεργασία μπορεί να γίνεται ασύγχρονα. Κάθε αποτέλεσμα θα περιλαμβάνει αναγνωριστικό μηνύματος, `cluster_id`, `major_topic`, `specific_topic` και ένδειξη αβεβαιότητας.

Η ανάθεση νέων μηνυμάτων σε γνωστά θέματα απαιτεί αποθήκευση των προσαρμοσμένων PCA, UMAP και HDBSCAN, μαζί με τα κεντροειδή, την ταξινόμια και την έκδοση προεπεξεργασίας. Η παρούσα υλοποίηση αποθηκεύει διανύσματα, συντεταγμένες, ετικέτες και παραμέτρους· η υπηρεσία θα χρειαζόταν επιπλέον τα μοντέλα μετασχηματισμού και πρόβλεψης. Η ανάθεση θα γινόταν στον ίδιο χώρο, με δυνατότητα επιστροφής «άγνωστο» όταν η ομοιότητα ή η βεβαιότητα είναι χαμηλή. Η `approximate_predict` του HDBSCAN διατηρεί τις υπάρχουσες συστάδες [28].

Για την ανακάλυψη νέων θεμάτων μπορούν να συγκεντρώνονται τα μη ανατεθειμένα μηνύματα σε χρονικά παράθυρα και να συσταδοποιούνται χωριστά. Η αποδοχή μιας νέας ομάδας θα βασίζεται στο μέγεθος, τη συνοχή, τη χρονική επιμονή και τη σχέση της με το ιστορικό σώμα. Χρειάζεται ανθρώπινη επιθεώρηση, καθώς μια ομάδα χωρίς παλαιότερη ετικέτα μπορεί να αντιστοιχεί σε θέμα που ήταν αραιό ή είχε ενταχθεί στον θόρυβο.

Η διαχρονική λειτουργία θα πρέπει να διακρίνει τα emergent από τα reemergent θέματα. Τα πρώτα είναι υποψήφια νέα θέματα χωρίς επαρκές αντίστοιχο στο διαθέσιμο ιστορικό σώμα. Τα δεύτερα επανεμφανίζονται μετά από περίοδο χαμηλής ή μηδενικής κίνησης. Ένα ιστορικό κεντροειδών, χαρακτηριστικών όρων και χρονικών περιόδων θα επέτρεπε την αντιστοίχιση νέων ομάδων με παλαιότερες, συνδυάζοντας σημασιολογική και λεξιλογική ομοιότητα. Οι επανεμφανίσεις θα διατηρούν το αναγνωριστικό του θέματος, ενώ οι νέες ομάδες θα λαμβάνουν νέο. Η καταγραφή διασπάσεων και συγχωνεύσεων θα διατηρεί τη συνέχεια της θεματικής ιστορίας.

Η πιλοτική υπηρεσία μπορεί να αξιολογηθεί σε μεταγενέστερα μηνύματα, με ανθρώπινα ελεγμένο δείγμα. Τα κριτήρια περιλαμβάνουν την ορθότητα και κάλυψη της ανάθεσης, την καθυστέρηση εντοπισμού νέων θεμάτων και τη χρησιμότητα των ειδοποιήσεων. Συμπληρωματικά μπορούν να εξεταστούν η επίδραση της κανονικοποίησης Unicode και της περικοπής, η μεταβολή του seed UMAP, άλλοι πολυγλωσσικοί κωδικοποιητές και η υποβολή της ονοματοδοσίας. Η ανάπτυξη της υπηρεσίας θα πρέπει επίσης να καθορίσει την πρόσβαση και τη διατήρηση των μηνυμάτων.

# Βιβλιογραφία

- [1] Blei, D. M., Ng, A. Y., Jordan, M. I. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993–1022.
- [2] Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. *arXiv:2203.05794*.
- [3] McInnes, L., Healy, J., Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. *arXiv:1802.03426*.
- [4] Campello, R. J. G. B., Moulavi, D., Sander, J. (2013). Density-Based Clustering Based on Hierarchical Density Estimates. *Advances in Knowledge Discovery and Data Mining (PAKDD 2013)*, 160–172.
- [5] McInnes, L., Healy, J., Astels, S. (2017). hdbscan: Hierarchical density based clustering. *Journal of Open Source Software*, 2(11), 205.
- [6] Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., Liu, Z. (2024). M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. *arXiv:2402.03216v4*. <https://arxiv.org/abs/2402.03216v4>
- [7] Akiba, T., Sano, S., Yanase, T., Ohta, T., Koyama, M. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2623–2631.
- [8] Bouma, G. (2009). Normalized (Pointwise) Mutual Information in Collocation Extraction. *Proceedings of GSCL*, 31–40. <https://svn.spraakdata.gu.se/repos/gerlof/pub/www/Docs/npmi-pfd.pdf>
- [9] Honnibal, M., Montani, I., Van Landeghem, S., Boyd, A. (2020). spaCy: Industrial-strength Natural Language Processing in Python. *Zenodo*. <https://doi.org/10.5281/zenodo.1212303>
- [10] Reimers, N., Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of EMNLP-IJCNLP 2019*, 3982–3992.
- [11] Angelov, D. (2020). Top2Vec: Distributed Representations of Topics. *arXiv:2008.09470*.
- [12] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [13] Zhang, Y., Li, M., Long, D., et al. (2025). Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models. *arXiv:2506.05176*.
- [14] Jolliffe, I. T., Cadima, J. (2016). Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A*, 374(2065), 20150202.
- [15] Spärck Jones, K. (1972). A statistical interpretation of term specificity and its application in retrieval. *Journal of Documentation*, 28(1), 11–21.
- [16] Salton, G., Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513–523.
- [17] Sculley, D. (2010). Web-scale k-means clustering. *Proceedings of the 19th International Conference on World Wide Web*, 1177–1178.

- [18] Bergstra, J., Bardenet, R., Bengio, Y., Kégl, B. (2011). Algorithms for Hyper-Parameter Optimization. *Advances in Neural Information Processing Systems*, 24.
- [19] Richardson, L. (χ.χ.). Beautiful Soup 4 [Λογισμικό]. <https://www.crummy.com/software/BeautifulSoup/> (πρόσβαση 3 Οκτωβρίου 2026).
- [20] Ollama (χ.χ.). Ollama [Λογισμικό]. <https://ollama.com> (πρόσβαση 3 Οκτωβρίου 2026). Μεταδεδωμένα BGE-M3 και CLS pooling: <https://ollama.com/library/bge-m3/blobs/daec91ffb5dd>
- [21] Harris, C. R., et al. (2020). Array programming with NumPy. *Nature*, 585, 357–362.
- [22] Ward, J. H. (1963). Hierarchical Grouping to Optimize an Objective Function. *Journal of the American Statistical Association*, 58(301), 236–244.
- [23] Devlin, J., Chang, M.-W., Lee, K., Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT 2019*, 4171–4186.
- [24] Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30.
- [25] Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT Press.
- [26] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [27] Lau, J. H., Newman, D., Baldwin, T. (2014). Machine Reading Tea Leaves: Automatically Evaluating Topic Coherence and Topic Model Quality. *Proceedings of EACL 2014*, 530–539. <https://doi.org/10.3115/v1/E14-1056>
- [28] McInnes, L., Healy, J., Astels, S. HDBSCAN documentation, Predicting clusters for new points. [https://hdbscan.readthedocs.io/en/latest/prediction\\_tutorial.html](https://hdbscan.readthedocs.io/en/latest/prediction_tutorial.html) (πρόσβαση 3 Οκτωβρίου 2026).

# Παράρτημα Α: Κατάλογος Συστάδων

Ο πλήρης κατάλογος των 107 συστάδων: αναγνωριστικό, μέγεθος σε μηνύματα, αποδοθείσα κύρια και ειδική θεματική. Οι κορυφαίοι διακριτικοί όροι κάθε συστάδας διατίθενται στο συνοδευτικό αρχείο `cluster_top_terms.csv`. Δείγματα θεμάτων ανά συστάδα περιλαμβάνονται στο `08_tfidf_labeling.ipynb`.

| ID  | Μέγεθος | Κύρια θεματική                     | Ειδική θεματική                                              |
|-----|---------|------------------------------------|--------------------------------------------------------------|
| 26  | 938     | Academic Events                    | Master's Thesis Presentations                                |
| 17  | 819     | Academic Events                    | PhD Defense Announcements                                    |
| 23  | 390     | Campus Life                        | Condolence Announcements                                     |
| 74  | 329     | Academic Events                    | Chemical Engineering & Related Lectures / Thesis Defenses    |
| 40  | 324     | Postgraduate Programmes            | Postgraduate & Doctoral Admissions / Programme Announcements |
| 97  | 308     | Labour & Union Affairs             | Strike Actions & Labour Mobilizations                        |
| 63  | 264     | University Administration          | Rector's Office Press Releases                               |
| 20  | 256     | Research & Funding                 | Research Grants Administration (ELKE / MODY)                 |
| 100 | 254     | University Administration          | University Restructuring, TEI Merger & Law School Debate     |
| 55  | 248     | Elections & Governance             | Departmental President & Vice-President Elections            |
| 86  | 229     | Labour & Union Affairs             | Faculty & Staff Union Statements / Labour Issues             |
| 105 | 222     | Informal Discussion                | General Discussion & Opinion Posts                           |
| 98  | 184     | Labour & Union Affairs             | University Policy Debates & Open Letters                     |
| 56  | 179     | Infrastructure & Digital Services  | Campus Utilities & Technical Services                        |
| 65  | 179     | Miscellaneous                      | Mixed / Unclassified                                         |
| 71  | 161     | Research & Funding                 | ELIDEK Research Funding Calls                                |
| 13  | 154     | University Administration          | Public-Sector & EU Job Calls / Staff Circulars               |
| 1   | 151     | University Administration          | Senate & Rector Council Meeting Agendas                      |
| 99  | 146     | Elections & Governance             | Rector Elections & Related Governance Debate                 |
| 41  | 145     | Research & Funding                 | Research & Academic Job Openings                             |
| 96  | 144     | Academic Events                    | Academic Recognition, Emeritus Status & University History   |
| 57  | 139     | Health & Welfare                   | Medical & Public Health Events                               |
| 30  | 131     | University Rankings & Distinctions | Faculty & Alumni Distinctions & Awards                       |
| 82  | 128     | Academic Events                    | Conference & Scientific Meeting Calls                        |
| 93  | 128     | Health & Welfare                   | COVID-19 Teaching, Exams & Institutional Responses           |
| 66  | 125     | Campus Life                        | Holiday Greetings                                            |
| 22  | 119     | Campus Life                        | Lost & Found                                                 |
| 68  | 117     | Health & Welfare                   | COVID-19 Institutional Announcements                         |

| ID  | Μέγεθος | Κύρια θεματική                    | Ειδική θεματική                                                    |
|-----|---------|-----------------------------------|--------------------------------------------------------------------|
| 42  | 109     | Campus Life                       | University Sports & Gymnasium                                      |
| 61  | 101     | Academic Events                   | Biomedical & Life-Sciences Lectures                                |
| 48  | 100     | Campus Life                       | Science & Technology Museum Events / Newsletters                   |
| 2   | 99      | University Administration         | Rector Council Meeting Agendas                                     |
| 15  | 99      | Campus Life                       | Library News & Services                                            |
| 92  | 97      | Academic Events                   | Book Presentations & Cultural / Literary Events                    |
| 62  | 93      | Academic Events                   | Honorary Doctorate Ceremonies                                      |
| 18  | 92      | Academic Events                   | Master's Thesis Presentations – Mechanical & Aerospace Engineering |
| 73  | 91      | Health & Welfare                  | Social Welfare News & Related Events                               |
| 52  | 90      | Academic Events                   | Physics / Astronomy Lectures & Scientific Events                   |
| 10  | 89      | Research & Funding                | Academic Fellow & Teaching Position Calls – Medicine               |
| 106 | 87      | Labour & Union Affairs            | Higher Education Policy & Legislation Debates                      |
| 76  | 83      | Innovation & Entrepreneurship     | Student Technology Teams & Open-Technology Initiatives             |
| 77  | 82      | Innovation & Entrepreneurship     | Research Collaboration Projects & Partnerships                     |
| 5   | 81      | University Administration         | Procurement & Public Tender Notices                                |
| 53  | 80      | Academic Events                   | Economics & Business Academic Events / Programme Calls             |
| 64  | 80      | Continuing Education              | Continuing Education & Language / Culture Courses                  |
| 103 | 78      | Informal Discussion               | Political & Social Commentary                                      |
| 104 | 77      | Informal Discussion               | Political Commentary on Democracy, Racism & Migration              |
| 29  | 76      | University Administration         | Governance Body Composition & Representation Notices               |
| 35  | 76      | Campus Life                       | University Chapel Monthly Service Schedules                        |
| 14  | 75      | Health & Welfare                  | COVID-19 Public Health Circulars                                   |
| 31  | 75      | Elections & Governance            | EDIP / ETEP Staff Representative Elections                         |
| 8   | 73      | Academic Events                   | Master's Thesis Presentations – Philology                          |
| 59  | 73      | Infrastructure & Digital Services | IT Services & Network Interruptions                                |
| 88  | 72      | Academic Events                   | Department Seminars – Modern Greek & Comparative Philology         |
| 16  | 70      | University Administration         | Payroll Announcements                                              |
| 32  | 69      | Gender Equality & Inclusion       | Gender Equality Committee Events & Announcements                   |
| 47  | 69      | Elections & Governance            | Dean (Κοσμήτορας) Elections                                        |
| 3   | 66      | Health & Welfare                  | COVID-19 Rapid Testing on Campus                                   |
| 11  | 66      | Infrastructure & Digital Services | Liquid Nitrogen Distribution                                       |
| 67  | 66      | Research & Funding                | Horizon 2020 / Europe, ERC & MSCA Funding                          |
| 75  | 65      | Academic Events                   | Biochemistry & Molecular Biology Scientific Events                 |

| ID  | Μέγεθος | Κύρια θεματική                     | Ειδική θεματική                                                |
|-----|---------|------------------------------------|----------------------------------------------------------------|
| 46  | 62      | University Rankings & Distinctions | World University Rankings                                      |
| 51  | 62      | Infrastructure & Digital Services  | Digital Services & Mixed Institutional Announcements           |
| 44  | 61      | Elections & Governance             | School & Department Body Composition Notices                   |
| 83  | 60      | Research & Funding                 | Transnational / European Collaborative Research Calls          |
| 24  | 59      | Academic Events                    | Master's Thesis Presentations – ENT / Medical                  |
| 70  | 59      | Innovation & Entrepreneurship      | Innovation Hub & Entrepreneurship Events (PatrasIQ)            |
| 0   | 58      | Academic Events                    | Thesis & Dissertation Presentations – Food Business Management |
| 19  | 57      | University Administration          | Financial Services & Budget Administration                     |
| 78  | 55      | Campus Life                        | Music Events & Concerts                                        |
| 94  | 54      | Campus Life                        | Poetry, Literary Sharing & Seasonal Greetings                  |
| 33  | 53      | University Administration          | School & Department Body Composition Acts                      |
| 49  | 53      | Campus Life                        | UPFM & Student Welcome / Cultural Events                       |
| 36  | 52      | Academic Events                    | Medical & Chemical Sciences Thesis / Dissertation Defenses     |
| 21  | 49      | Infrastructure & Digital Services  | Equipment & Consumables Exchange                               |
| 80  | 49      | Research & Funding                 | National R&I Funding (Ερευνώ-Καινοτομώ)                        |
| 90  | 46      | Labour & Union Affairs             | Staff Association General Assemblies                           |
| 27  | 45      | Research & Funding                 | Scholarships & Study-Abroad Funding                            |
| 43  | 45      | Labour & Union Affairs             | Staff Association Assemblies & Social Events                   |
| 7   | 44      | Academic Events                    | Architecture Lectures & Department Announcements               |
| 85  | 44      | Labour & Union Affairs             | Staff Association Elections & Campaigns                        |
| 87  | 44      | Academic Events                    | Theatre & Related Humanities Lectures                          |
| 60  | 43      | Academic Events                    | Department Seminars – Biological Sciences                      |
| 6   | 42      | Campus Life                        | @UP University Magazine                                        |
| 34  | 42      | Campus Life                        | University Chapel Services                                     |
| 50  | 42      | Elections & Governance             | Department President & Deputy President Elections              |
| 4   | 41      | Academic Events                    | Master's Thesis Presentations – Rehabilitation Sciences        |
| 54  | 40      | Elections & Governance             | Central Electoral Committee Appointments                       |
| 69  | 39      | University Administration          | Institutional Service Access & Contact Information             |
| 12  | 38      | University Administration          | Staff Evaluation & HR Circulars                                |
| 39  | 38      | Postgraduate Programmes            | Computing & Informatics MSc Admissions                         |
| 89  | 37      | Labour & Union Affairs             | Staff Association Elections & Board Formation                  |
| 91  | 37      | Academic Events                    | Magnaura & Historical / Cultural Lectures                      |
| 25  | 36      | Health & Welfare                   | Blood & Bone Marrow Donation / Volunteering                    |
| 38  | 36      | Elections & Governance             | Museum & Central Laboratory Director Elections                 |
| 102 | 35      | Informal Discussion                | Academic Governance, Ethics & Bureaucracy Commentary           |

| ID  | Μέγεθος | Κύρια θεματική                    | Ειδική θεματική                                             |
|-----|---------|-----------------------------------|-------------------------------------------------------------|
| 101 | 34      | Labour & Union Affairs            | Faculty Association Elections & Campaign Statements         |
| 28  | 33      | Academic Events                   | Master's Thesis Presentations – Environmental & Geosciences |
| 37  | 33      | International Programmes          | Erasmus+ & International Mobility                           |
| 58  | 33      | Infrastructure & Digital Services | eClass & Exams Platform Announcements                       |
| 84  | 33      | Innovation & Entrepreneurship     | Innovation Competitions & Accelerator Calls                 |
| 95  | 33      | Labour & Union Affairs            | Postgraduate & PhD Candidate Labour Issues                  |
| 9   | 32      | Health & Welfare                  | COVID-19 Protection Measures & Staff Testing Circulars      |
| 45  | 32      | Academic Events                   | Medical Chemistry Conferences & Related Academic Events     |
| 72  | 32      | Campus Life                       | Theatre, Opera & Performing Arts                            |
| 79  | 32      | Informal Discussion               | Personal Commentary on University & Public Affairs          |
| 81  | 32      | Academic Events                   | Journal Special Issues & Publication Calls                  |

Πίνακας Α.1: Οι 107 συστάδες της τελικής λύσης.