

Περιεχόμενα

1 Εισαγωγή.....	6
1.1 Σκοπός και ερευνητικά ερωτήματα	7
1.2 Συνεισφορά.....	7
1.3 Δομή της διπλωματικής.....	7
1.4 Σχέση με υπάρχουσες προσεγγίσεις θεματικής μοντελοποίησης	8
2 Θεωρητικό Υπόβαθρο.....	10
2.1 Βασικές έννοιες μηχανικής μάθησης	10
2.2 Παραδείγματα μάθησης.....	11
2.3 Τεχνητά νευρωνικά δίκτυα	11
2.4 Επεξεργασία φυσικής γλώσσας.....	12
2.5 Από τις καταμετρήσεις λέξεων στις κατανεμημένες αναπαραστάσεις	13
2.6 Κωδικοποιητές transformer και ενσωματώσεις προτάσεων	14
2.7 Γεωμετρία υψηλών διαστάσεων και μείωση διαστάσεων	15
2.8 Παραδείγματα συσταδοποίησης.....	15
2.9 Αξιολόγηση ανεπίβλεπτης δομής.....	16
2.10 Μπεϋζιανή βελτιστοποίηση υπερπαραμέτρων	17
2.11 Επεξεργασία φυσικής γλώσσας για τα Νέα Ελληνικά.....	18
3 Συλλογή και Έλεγχος Δεδομένων	19
3.1 Συλλογή δεδομένων	19
3.2 Προέλευση δεδομένων και προστασία προσωπικών δεδομένων.....	19
3.3 Διερευνητική ανάλυση δεδομένων	20
4 Δομική Προεπεξεργασία.....	21
4.1 Κανονικοποίηση του πεδίου παραληπτών.....	21
5 Γλωσσική Προεπεξεργασία.....	22
5.1 Δύο παράλληλες αναπαραστάσεις κειμένου	22
5.2 Δομικός καθαρισμός κειμένου με μετρημένη κάλυψη.....	22
5.3 Λημματοποίηση και η διόρθωση των σύνθετων λημμάτων.....	23
5.4 Φιλτράρισμα stopwords για ελληνικά και αγγλικά.....	24
5.5 Κανονικοποίηση μοτίβων, θορυβώδεις μονάδες και όρια μήκους	24
6 Σημασιολογικές Αναπαραστάσεις Εγγράφων	25
6.1 Υπόβαθρο και μέτρο ομοιότητας	25
6.2 Πείραμα επιλογής μοντέλου	25
6.3 Παραγωγή των ενσωματώσεων	26
7 Συσταδοποίηση.....	27
7.1 Επισκόπηση.....	27

7.2 Προ-μείωση με PCA	27
7.3 UMAP	27
7.4 HDBSCAN.....	28
7.5 Αντικειμενική συνάρτηση και αναζήτηση υπερπαραμέτρων	28
7.6 Μετεπεξεργασία	30
7.6.1 Συγχώνευση σχεδόν όμοιων συστάδων	30
7.6.2 Συντηρητική επανατοποθέτηση θορύβου.....	30
8 Χαρακτηρισμός Συστάδων και Θεματική Ταξινόμια	33
8.1 Εξαγωγή όρων με TF-IDF.....	33
8.2 Θεματική ταξινόμια	33
9 Επικύρωση	35
9.1 Σύγκριση με μεθόδους αναφοράς.....	35
9.2 Λεξιλογική συνοχή NPMI	35
9.3 Ανάλυση ευαισθησίας	36
10 Διαχρονική Ανάλυση.....	37
10.1 Συνολική κίνηση των λιστών.....	37
10.2 Θεματική σύνθεση ανά έτος.....	37
10.3 Η πανδημία ως φυσικό πείραμα	38
10.4 Θεσμικοί εκλογικοί κύκλοι.....	39
10.5 Ακαδημαϊκή εποχικότητα	40
11 Συμπεράσματα, Περιορισμοί και Μελλοντικά Βήματα.....	41
11.1 Περιορισμοί	41
11.2 Συμπεράσματα.....	41
11.3 Μελλοντικά βήματα.....	42
Βιβλιογραφία	43
Παράρτημα Α: Κατάλογος Συστάδων	45

Περίληψη

Η παρούσα διπλωματική εργασία μελετά την ανεπίβλεπτη ανακάλυψη θεματικών ενοτήτων στο δημόσιο αρχείο των λιστών ηλεκτρονικού ταχυδρομείου του Πανεπιστημίου Πατρών (tonima, announcements) για την περίοδο 2018–2023, ένα δίγλωσσο σώμα 13.637 μηνυμάτων στα ελληνικά και τα αγγλικά. Αναπτύσσεται μια πλήρης ροή επεξεργασίας: δομικός και γλωσσικός καθαρισμός με μετρημένη κάλυψη κάθε κανόνα, σημασιολογικές αναπαραστάσεις με το πολυγλωσσικό μοντέλο ενσωματώσεων BGE-M3, μείωση διαστάσεων με PCA και UMAP, πυκνοτική συσταδοποίηση με HDBSCAN, και βελτιστοποίηση υπερπαραμέτρων 200 δοκιμών με το Optuna, με αντικειμενική συνάρτηση βαθμονομημένη πάνω στο ίδιο το σώμα κειμένων.

Η μέθοδος αναδεικνύει 107 σημασιολογικά συνεκτικές συστάδες, οργανωμένες σε 17 κύριες θεματικές ενότητες, με το 14,7% των μηνυμάτων να χαρακτηρίζεται τεκμηριωμένα ως θόρυβος. Το αποτέλεσμα υπερτερεί των μεθόδων αναφοράς k-means και ιεραρχικής συσταδοποίησης τόσο ως προς τη σημασιολογική συνοχή (0,811 έναντι 0,801) όσο και ως προς το ανεξάρτητο λεξιλογικό μέτρο NPMI (−0,208 έναντι −0,29), και παραμένει σταθερό υπό διαταραχές $\pm 20\%$ όλων των υπερπαραμέτρων.

Η διαχρονική ανάλυση δείχνει ότι οι συστάδες αποτυπώνουν πραγματικά θεσμικά γεγονότα: η πανδημία εμφανίζεται ως αιχμή του Μαρτίου 2020 σε θεματική που το 2019 σχεδόν δεν υπήρχε, οι πρωτανικές εκλογές κυριαρχούν τον Ιούλιο του 2020, ενώ η εργασιακή θεματολογία αυξάνει το μερίδιό της κατά 3,4 ποσοστιαίες μονάδες μεταξύ 2018 και 2022, χωρίς η συσταδοποίηση να έχει λάβει καμία χρονική πληροφορία.

Abstract

This thesis studies unsupervised topic discovery in the public mailing-list archive of the University of Patras (tovima, announcements) over 2018–2023, a bilingual Greek–English corpus of 13,637 emails. A complete pipeline is developed: structural and linguistic cleaning with measured coverage for every rule, semantic representations from the multilingual BGE-M3 embedding model, dimensionality reduction with PCA and UMAP, density-based clustering with HDBSCAN, and 200-trial hyperparameter optimisation with Optuna under an objective calibrated on the corpus itself.

The method discovers 107 semantically coherent clusters organised into 17 major topics, with 14.7% of emails identified as noise. The result outperforms k-means and agglomerative baselines on both semantic coherence (0.811 vs 0.801) and the embedding-independent NPMI measure (−0.208 vs −0.29), and is stable under $\pm 20\%$ perturbation of every hyperparameter.

Temporal analysis shows the clusters track real institutional events: the pandemic appears as a March 2020 spike in a topic that scarcely existed in 2019, rectorial elections dominate July 2020, and labour-affairs traffic grows by 3.4 percentage points of share between 2018 and 2022, although the clustering was given no temporal information.

Ευρετήριο Εικόνων

Εικόνα 7.1: Δισδιάστατη προβολή UMAP και των 13.637 μηνυμάτων, χρωματισμένη ανά κύρια θεματική (ο θόρυβος με γκρι). Η προβολή είναι νέα προσαρμογή 2 συνιστωσών για λόγους απεικόνισης· η συσταδοποίηση έγινε στην προβολή 13 συνιστωσών (11_umap_figure.ipynb).	32
Εικόνα 7.2: Κατανομή των μεγεθών των 107 συστάδων (διάμεσος 72, μέγιστο 938).	32
Εικόνα 10.1: Μηνύματα ανά έτος (αριστερά· το 2023 ελλειπές, με διαγράμμιση) και μέσος όρος μηνυμάτων ανά μήνα (δεξιά).	37
Εικόνα 10.2: Μερίδιο κάθε κύριας θεματικής στην κίνηση των λιστών ανά έτος, για τις οκτώ μεγαλύτερες θεματικές (* 2023: Ιαν–Ιούλ).	38
Εικόνα 10.3: Θεματική Health & COVID, μηνιαίος όγκος. Η αιχμή του Μαρτίου 2020 συμπίπτει με το κλείσιμο των ελληνικών πανεπιστημίων.	39
Εικόνα 10.4: Θεματική Elections & Governance, μηνιαίος όγκος. Η κορυφή του Ιουλίου 2020 είναι οι πρωτανικές εκλογές.	39
Εικόνα 10.5: Η Academic Events ως μερίδιο της μηνιαίας κίνησης, με συνάθροιση όλων των ετών.	40

Ευρετήριο Πινάκων

Πίνακας 1.1: Τα στάδια της ροής επεξεργασίας και τα παραγόμενα αρχεία.	6
Πίνακας 3.1: Ευρήματα του ελέγχου δεδομένων και η απόφαση καθαρισμού που υπαγόρευσε το καθένα.	20
Πίνακας 6.1: Σύγκριση μοντέλων ενσωματώσεων σε 30 ζεύγη γνωστής αλήθειας.	25
Πίνακας 8.1: Η ταξινόμια κύριων θεματικών πάνω στις 107 συστάδες.	34
Πίνακας 9.1: Σύγκριση με τις μεθόδους αναφοράς και στα δύο μέτρα.	36
Πίνακας 9.2: Ευαισθησία της λύσης σε διαταραχές υπερπαραμέτρων $\pm 20\%$	36
Πίνακας A.1: Οι 107 συστάδες της τελικής λύσης.	48

Ευρετήριο Αποσπασμάτων Κώδικα

Απόσπασμα 5.1: Η διόρθωση των σύνθετων λημμάτων (04_nlp_preprocessing.ipynb).	23
Απόσπασμα 7.1: Το μέτρο σημασιολογικής συνοχής (07_clustering.ipynb).	28
Απόσπασμα 7.2: Αποτίμηση της αντικειμενικής συνάρτησης μέσα στη δοκιμή του Optuna (07_clustering.ipynb).	29
Απόσπασμα 7.3: Συγχώνευση συστάδων ανεξάρτητη από τη σειρά επεξεργασίας (07_clustering.ipynb).	30

1 Εισαγωγή

Η παρούσα διπλωματική εργασία περιγράφει μια ολοκληρωμένη μεθοδολογία για την ανεπίβλεπτη ανακάλυψη σημασιολογικών θεματικών ενότητων στο δημόσιο αρχείο των λιστών ηλεκτρονικού ταχυδρομείου του Πανεπιστημίου Πατρών (λίστες «tovima» και «announcements»), για την περίοδο 2018–2023. Το σώμα κειμένων αποτελείται από 14.277 ακατέργαστα μηνύματα, γραμμένα κατά κύριο λόγο στα ελληνικά, με σημαντικό ενσωματωμένο αγγλικό περιεχόμενο (ανακοινώσεις προσκεκλημένων ομιλητών, προσκλήσεις συνεδρίων, περιλήψεις εργασιών). Στόχος είναι η οργάνωση του αρχείου σε σημασιολογικά συνεκτικές θεματικές ενότητες χωρίς χειροκίνητη επισήμανση μεμονωμένων μηνυμάτων, με μεθοδολογικές επιλογές που ελέγχονται πάνω στα ίδια τα δεδομένα αντί να υιοθετούνται ως προεπιλογές.

Η ροή επεξεργασίας αποτελείται από διαδοχικά στάδια, καθένα υλοποιημένο σε ξεχωριστό notebook που μπορεί να ελεγχθεί και να επανεκτελεστεί ανεξάρτητα. Κάθε στάδιο καταναλώνει το αρχείο εξόδου του προηγούμενου, ώστε οποιοδήποτε βήμα να μπορεί να επαναληφθεί μεμονωμένα (Πίνακας 1.1).

Στάδιο	Notebook	Είσοδος	Έξοδος
Συλλογή δεδομένων	01_make_dataset.ipynb	mailarchive.upatras.gr	tovima.csv (14.277 γραμμές)
Έλεγχος δεδομένων (EDA)	02_eda_data_audit.ipynb	tovima.csv	ευρήματα ελέγχου
Δομικός καθαρισμός	03_preprocessing.ipynb	tovima.csv	tovima_clean.csv (13.692)
Γλωσσική προεπεξεργασία	04_nlp_preprocessing.ipynb	tovima_clean.csv	tovima_nlp_ready.csv (13.637)
Επιλογή μοντέλου ενσωματώσεων	05_compare_embeddings.ipynb	tovima_nlp_ready.csv	απόφαση μοντέλου (BGE-M3)
Παραγωγή ενσωματώσεων	06_embedding_generation.ipynb	tovima_nlp_ready.csv	διανύσματα 13.637×1024
Συσταδοποίηση	07_clustering.ipynb	ενσωματώσεις	tovima_clustered.csv (107 συστάδες)
Χαρακτηρισμός & ταξινόμια	08_tfidf_labeling.ipynb	tovima_clustered.csv	tovima_final.csv
Επικύρωση	09_validation.ipynb	tovima_final.csv	μέθοδοι αναφοράς, NPMI, ευαισθησία
Διαχρονική ανάλυση	10_temporal_analysis.ipynb	tovima_final.csv	θεματικές τάσεις 2018–2023, διαγράμματα

Πίνακας 1.1: Τα στάδια της ροής επεξεργασίας και τα παραγόμενα αρχεία.

Ένα επαναλαμβανόμενο μοτίβο στην πορεία της εργασίας ήταν ότι προγενέστερες εκδόσεις της ροής περιείχαν παραμέτρους και σχεδιαστικές αποφάσεις που δεν είχαν ελεγχθεί ποτέ έναντι των δεδομένων: κανονικές εκφράσεις με αφανή κενά κάλυψης, λίστες stopwords βασισμένες στη συχνότητα που αφαιρούσαν λέξεις περιεχομένου, μια αντικειμενική συνάρτηση με αυθαίρετη προτίμηση ως προς το πλήθος των συστάδων. Κάθε τέτοια απόφαση είτε επιβεβαιώθηκε με άμεση μέτρηση πάνω στο σώμα κειμένων είτε αντικαταστάθηκε, και η εργασία καταγράφει τόσο τον τελικό σχεδιασμό όσο και τις μετρήσεις που τον υπαγόρευαν.

1.1 Σκοπός και ερευνητικά ερωτήματα

Τα πανεπιστήμια παράγουν μια συνεχή ροή γραπτής επικοινωνίας (ανακοινώσεις, εγκυκλίους, δημόσιες αντιπαραθέσεις, τελετές, κρίσεις) που συσσωρεύεται σε αρχεία λιστών τα οποία σπάνια διαβάζει κανείς εκ των υστέρων. Τα αρχεία αυτά αποτελούν θεσμική μνήμη σε ακατέργαστη μορφή: χωρίς επισημάνσεις, χωρίς δομή, και στην ελληνική περίπτωση γραμμένα σε μια μορφολογικά πλούσια γλώσσα με συγκριτικά περιορισμένους υπολογιστικούς πόρους, αναμειγμένη με αγγλικά. Σκοπός της εργασίας είναι να εξεταστεί κατά πόσο οι σύγχρονες μέθοδοι που βασίζονται σε ενσωματώσεις μπορούν να μετατρέψουν ένα τέτοιο αρχείο σε οργανωμένο, αναλύσιμο υλικό χωρίς χειροκίνητη επισημάνση.

Τρία ερευνητικά ερωτήματα διατρέχουν την εργασία. **EE1:** Μπορεί μια ροή συσταδοποίησης βασισμένη σε ενσωματώσεις να ανακτήσει σημασιολογικά ουσιαστική θεματική δομή από ένα δίγλωσσο ελληνικό θεσμικό σώμα κειμένων; **EE2:** Μπορεί κάθε στάδιο μιας τέτοιας ροής (κανόνες καθαρισμού, επιλογή μοντέλου, υπερπαράμετροι, κατώφλια μετεπεξεργασίας) να τεκμηριωθεί εμπειρικά έναντι του ίδιου του σώματος κειμένων; **EE3:** Αποτυπώνει η δομή που ανακαλύπτεται τη θεσμική πραγματικότητα, όπως αυτό μπορεί να ελεγχθεί μέσω της χρονικής της συμπεριφοράς έναντι γνωστών γεγονότων;

1.2 Συνεισφορά

Η εργασία συνεισφέρει σε τρία επίπεδα. Το βασικό αποτέλεσμα είναι μια πλήρης, επικυρωμένη ροή ανακάλυψης θεματικών ενοτήτων για δίγλωσσο ελληνικό θεσμικό ηλεκτρονικό ταχυδρομείο. Η ροή παράγει 107 συνεκτικές συστάδες κάτω από 17 κύριες θεματικές ενότητες, με τεκμηριωμένο ποσοστό θορύβου 14,7%, υπερτερεί των διαμεριστικών μεθόδων αναφοράς τόσο σε ένα εσωτερικό όσο και σε ένα ανεξάρτητο από τις ενσωματώσεις μέτρο, και παραμένει σταθερή υπό διαταραχές υπερπαραμέτρων $\pm 20\%$. Στην πορεία προέκυψε και ένα σύνολο ευρημάτων ειδικά για τα ελληνικά με αυτοτελή αξία: ένα συστηματικό ελάττωμα σύνθετων λημμάτων στο καθιερωμένο ελληνικό μοντέλο του spaCy και η διόρθωσή του, μετρήσεις κάλυψης για τους ελληνικούς τύπους προσφώνησης και αποφώνησης, και μεθοδολογία βαθμονόμησης για κάθε κατώφλι της ροής. Τέλος, μια διαχρονική ανάλυση δείχνει ότι η ανεπίβλεπτη δομή αναπαράγει την πραγματική θεσμική ιστορία (την έναρξη της πανδημίας, τους εκλογικούς κύκλους, την άνοδο της εργασιακής θεματολογίας), μολονότι η συσταδοποίηση δεν έλαβε καμία χρονική πληροφορία.

1.3 Δομή της διπλωματικής

Η εργασία οργανώνεται ως εξής. Το Κεφάλαιο 2 παρέχει το θεωρητικό υπόβαθρο, από τις βασικές έννοιες της μηχανικής μάθησης, τα παραδείγματα μάθησης και τα νευρωνικά δίκτυα, μέχρι την αναπαράσταση κειμένου, τις ενσωματώσεις προτάσεων με transformers, τη μείωση διαστάσεων, την πυκνοτική συσταδοποίηση, την αξιολόγηση ανεπίβλεπτης δομής, τη μπεϋζιανή βελτιστοποίηση υπερπαραμέτρων και τις ιδιαιτερότητες της νέας ελληνικής. Το Κεφάλαιο 3 καλύπτει τη συλλογή και τον έλεγχο των δεδομένων, το Κεφάλαιο 4 τον δομικό καθαρισμό και το Κεφάλαιο 5 τη γλωσσική προεπεξεργασία. Το Κεφάλαιο 6 επιλέγει και εφαρμόζει το μοντέλο ενσωματώσεων, το Κεφάλαιο 7 αναπτύσσει τη συσταδοποίηση με τη βελτιστοποίηση και τη μετεπεξεργασία της, και το Κεφάλαιο 8 παράγει τους χαρακτηρισμούς των συστάδων και τη θεματική ταξινόμια. Το Κεφάλαιο 9 επικυρώνει το αποτέλεσμα έναντι μεθόδων αναφοράς, ενός ανεξάρτητου μέτρου και διαταραχών, και το

Κεφάλαιο 10 αναλύει το σώμα κειμένων διαχρονικά. Το Κεφάλαιο 11 συνοψίζει τα συμπεράσματα, τους περιορισμούς και τα μελλοντικά βήματα.

1.4 Σχέση με υπάρχουσες προσεγγίσεις θεματικής μοντελοποίησης

Η ανακάλυψη θεματικών ενοτήτων σε συλλογές εγγράφων έχει κλασικά διατυπωθεί ως πιθανοτική γενετική μοντελοποίηση, με χαρακτηριστικό εκπρόσωπο το Latent Dirichlet Allocation (LDA) [1]: τα έγγραφα είναι μείγματα θεμάτων και τα θέματα κατανομές πάνω σε ένα λεξιλόγιο σακούλας λέξεων (bag of words). Για το συγκεκριμένο σώμα κειμένων, η οικογένεια αυτή είναι ακατάλληλη για τρεις λόγους. Τα ελληνικά είναι έντονα κλιτή γλώσσα, οπότε ένα λεξιλόγιο σακούλας λέξεων διασπά κάθε έννοια σε δεκάδες επιφανειακούς τύπους αν δεν προηγηθεί επιθετική λημματοποίηση· το σώμα κειμένων είναι δίγλωσσο, και το LDA δεν διαθέτει μηχανισμό για να αναγνωρίσει ότι μια ελληνική ανακοίνωση και το αγγλικό της αντίστοιχο αφορούν το ίδιο θέμα· και πολλά μηνύματα είναι σύντομα, δηλαδή στην περιοχή όπου οι εκτιμήσεις συνεμφάνισης λέξεων γίνονται αναξιόπιστες.

Μια δεύτερη οικογένεια αντικαθιστά τις καταμετρήσεις λέξεων με πυκνές σημασιολογικές αναπαραστάσεις: τα έγγραφα ενσωματώνονται με έναν προεκπαιδευμένο transformer ενσωματώσεων προτάσεων [10], προβάλλονται σε χώρο χαμηλότερης διάστασης και συσταδοποιούνται, με κάθε συστάδα να περιγράφεται στη συνέχεια λεξιλογικά. Το Top2Vec [11] και, κυρίως, το BERTopic [2] ακολουθούν αυτή τη συνταγή: το BERTopic συνθέτει ενσωματώσεις προτάσεων, UMAP [3], HDBSCAN [4, 5] και ένα TF-IDF βασισμένο σε κλάσεις (c-TF-IDF) για την περιγραφή των συστάδων. Η ροή που αναπτύσσεται στην παρούσα εργασία ανήκει σαφώς σε αυτή την οικογένεια και βρίσκεται αρχιτεκτονικά πολύ κοντά στο BERTopic: η αλληλουχία σταδίων των Κεφαλαίων 6–8 (ενσωμάτωση, μείωση, πυκνοτική συσταδοποίηση, περιγραφή με TF-IDF) είναι η ίδια. Πρόκειται για συνειδητή επιλογή μιας δοκιμασμένης αρχιτεκτονικής, και η συνεισφορά της εργασίας πρέπει να διαβαστεί αντίστοιχα: ως μια μετρημένη, τεκμηριωμένη και επικυρωμένη εφαρμογή μιας καθιερωμένης αρχιτεκτονικής σε ένα δίγλωσσο ελληνικό θεσμικό σώμα κειμένων.

Μέσα σε αυτή την αρχιτεκτονική, η ροή αποκλίνει από το τυπικό BERTopic σε πέντε σημεία, καθένα για λόγο που τεκμηριώνεται στο αντίστοιχο κεφάλαιο. Πρώτον, στην περιγραφή των συστάδων: το c-TF-IDF του BERTopic συνενώνει κάθε συστάδα σε ένα συγκεντρωτικό έγγραφο, πράγμα που περιορίζει την αντίστροφη συχνότητα εγγράφων σε τόσες μόνο τιμές όσες και οι συστάδες και αδυνατεί να διακρίνει έναν όρο που εμφανίζεται σταθερά στα μηνύματα μιας συστάδας από έναν όρο που επαναλαμβάνεται πολλές φορές σε ένα μακροσκελές μήνυμα. Η Ενότητα 8.1 μετρά το φαινόμενο πάνω στο σώμα κειμένων και υιοθετεί TF-IDF σε επίπεδο εγγράφου με μέσους όρους βαρών ανά συστάδα. Δεύτερον, στις υπερπαραμέτρους: αντί για τις προεπιλογές των βιβλιοθηκών, οι παράμετροι των UMAP και HDBSCAN επιλέγονται με αναζήτηση 200 δοκιμών μέσω Optuna [7] υπό αντικειμενική συνάρτηση βαθμονομημένη στο σώμα κειμένων (Ενότητα 7.5), και το επιλεγμένο βέλτιστο αποδεικνύεται ότι βρίσκεται σε ευρύ οροπέδιο (Ενότητα 9.3). Τρίτον, στην προεπεξεργασία: ο σχεδιασμός δύο παράλληλων κειμενικών αναπαραστάσεων του Κεφαλαίου 5 (φυσικό δίγλωσσο κείμενο για το μοντέλο ενσωματώσεων BGE-M3 [6], λημματοποιημένα ελληνικά για τις λεξιλογικές στατιστικές), μαζί με τις μετρημένες διορθώσεις ελληνικών ιδιαιτεροτήτων (το ελάττωμα σύνθετων λημμάτων του ελληνικού μοντέλου του spaCy [9] στην Ενότητα 5.3, η κανονικοποίηση τόνων στην Ενότητα 8.1) αντιμετωπίζει αστοχίες που μια έτοιμη ροή θα κληρονομούσε σιωπηλά. Τέταρτον, στη μετεπεξεργασία: η συγχώνευση μέσω συνεκτικών συνιστωσών, ανεξάρτητη από τη σειρά επεξεργασίας, και η βαθμονομημένη, σκόπιμα συντηρητική επανατοποθέτηση θορύβου της

Ενότητας 7.6 δεν έχουν αντίστοιχο στο τυπικό πλαίσιο. Πέμπτον, στην επικύρωση: η σύγκριση με μεθόδους αναφοράς, ο ανεξάρτητος έλεγχος NPMI [8] και η ανάλυση ευαισθησίας του Κεφαλαίου 9 είναι εξωτερικά ως προς οποιαδήποτε βιβλιοθήκη.

Η έτοιμη βιβλιοθήκη BERTopic δεν εφαρμόστηκε ως έχει ακριβώς εξαιτίας αυτών των διαφορών: αρκετά από τα ελαττώματα που η εργασία εντοπίζει και διορθώνει (η έξοδος σύνθετων λημμάτων του λημματοποιητή, ο διπλασιασμός τονισμένων/άτονων λημμάτων, η συμπεριφορά του c-TF-IDF σε συστάδες που κυριαρχούνται από μακροσκελή συγκεντρωτικά μηνύματα) εμφανίζονται μέσα σε στάδια που το έτοιμο πλαίσιο αντιμετωπίζει ως δεδομένα ή αόρατα. Η χρήση του πλαισίου ως μαύρου κουτιού θα είχε παραγάγει ένα αποτέλεσμα με αστοχίες που δεν θα είχαν μετρηθεί. Η ρητή κατασκευή της ίδιας αρχιτεκτονικής, στάδιο προς στάδιο, είναι αυτό που κατέστησε κάθε κατώφλι της εργασίας μετρημένο μέγεθος.

2 Θεωρητικό Υπόβαθρο

Το κεφάλαιο αυτό συγκεντρώνει τις έννοιες πάνω στις οποίες στηρίζεται η ροή επεξεργασίας των Κεφαλαίων 3–10. Κάθε ενότητα συνδέει τη γενική διατύπωση μιας μεθόδου με τον τρόπο που η εργασία τη χρησιμοποιεί.

2.1 Βασικές έννοιες μηχανικής μάθησης

Η μηχανική μάθηση μελετά αλγορίθμους που βελτιώνουν την επίδοσή τους σε μια εργασία μέσω της εμπειρίας, δηλαδή μέσω της έκθεσης σε δεδομένα, αντί μέσω ρητών, χειρόγραφων κανόνων [26]. Ένα σύστημα μάθησης αποτελείται από τρία μέρη: ένα μοντέλο, δηλαδή μια οικογένεια συναρτήσεων παραμετροποιημένη από ρυθμιζόμενες παραμέτρους· μια αντικειμενική συνάρτηση (ή συνάρτηση κόστους) που βαθμολογεί πόσο καλά αποδίδει μια συγκεκριμένη επιλογή παραμέτρων στα διαθέσιμα δεδομένα· και μια διαδικασία βελτιστοποίησης που αναζητά στον χώρο των παραμέτρων μια επιλογή με καλή βαθμολογία. Η μάθηση είναι επομένως προσαρμογή: ο αλγόριθμος δεν γνωρίζει εκ των προτέρων τίποτα για λίστες ηλεκτρονικού ταχυδρομείου, ελληνική μορφολογία ή πανεπιστημιακές εκλογές. Ό,τι συλλαμβάνει, το συλλαμβάνει επειδή κάποιο ποσοτικό κριτήριο το επιβράβευσε πάνω σε δεδομένα.

Η κεντρική δυσκολία της μάθησης είναι η γενίκευση. Ένα μοντέλο με αρκετή χωρητικότητα μπορεί πάντοτε να προσαρμοστεί τέλεια στα δεδομένα εκπαίδευσής του, μαζί με τον θόρυβο και τις συμπτώσεις τους, και ένα μοντέλο προσαρμοσμένο έτσι αποδίδει κακώς σε δεδομένα που δεν έχει δει. Η αστοχία αυτή ονομάζεται υπερπροσαρμογή (overfitting). Η αντίθετη αστοχία, η υποπροσαρμογή, εμφανίζεται όταν η οικογένεια μοντέλων είναι υπερβολικά περιοριστική για να εκφράσει την πραγματική δομή. Στην πράξη, τα δεδομένα που χρησιμοποιούνται για την προσαρμογή των παραμέτρων διαχωρίζονται από τα δεδομένα με τα οποία κρίνεται η προσαρμογή. Διακρίνονται επίσης οι παράμετροι (που ορίζονται από τη διαδικασία βελτιστοποίησης) από τις υπερπαραμέτρους, δηλαδή ρυθμίσεις της ίδιας της διαδικασίας, όπως το μέγεθος του μοντέλου, κατώφλια ή πλήθη γειτόνων, που πρέπει να επιλεγούν με αναζήτηση σε επίπεδο πάνω από τον βρόχο εκπαίδευσης. Και οι δύο έννοιες επανέρχονται στην εργασία με ανεπίβλεπτη μορφή: το στάδιο συσταδοποίησης του Κεφαλαίου 7 εκθέτει πέντε υπερπαραμέτρους που επιλέγονται με αυτοματοποιημένη αναζήτηση, ενώ η ανησυχία μήπως μια καλά βαθμολογημένη διαμόρφωση αποτελεί υπερπροσαρμοσμένο τυχαίο εύρημα της ρύθμισης απαντάται από την ανάλυση ευαισθησίας του Κεφαλαίου 9, η οποία παίζει τον ρόλο που παίζει η αξιολόγηση σε κρατημένα δεδομένα στην επιβλεπόμενη μάθηση.

Δίπλα στην επιλογή παραδείγματος μάθησης βρίσκεται η οπτική μεροληψίας–διακύμανσης για το σφάλμα ενός μοντέλου: η μεροληψία είναι σφάλμα από υποθέσεις υπερβολικά άκαμπτες για να συλλάβουν την αλήθεια, η διακύμανση σφάλμα από ευαισθησία στο συγκεκριμένο δείγμα. Τα πλούσια μοντέλα ανταλλάσσουν μεροληψία με διακύμανση. Η ομαλοποίηση, τα περισσότερα δεδομένα και η προσεκτική αξιολόγηση διαχειρίζονται την ανταλλαγή. Στην εργασία αυτή η ανταλλαγή εμφανίζεται σε ασυνήθιστο σημείο, στη λεπτομέρεια της συσταδοποίησης: ένα πολύ μικρό ελάχιστο μέγεθος συστάδας παράγει πολλές σφιχτές συστάδες που προσαρμόζονται στις συμπτώσεις του δείγματος (υψηλή διακύμανση), ενώ ένα πολύ μεγάλο συγχωνεύει πραγματικά θέματα (υψηλή μεροληψία). Η ποινή κατακερματισμού και το βαθμονομημένο εύρος αναζήτησης του Κεφαλαίου 7 συγκεκριμενοποιούν αυτή την ανταλλαγή.

2.2 Παραδείγματα μάθησης

Τα προβλήματα μάθησης ταξινομούνται με βάση την εποπτεία που φέρουν τα δεδομένα. Στην επιβλεπόμενη μάθηση κάθε παράδειγμα εκπαίδευσης είναι ζεύγος εισόδου και επιθυμητής εξόδου (ένα μήνυμα και η θεματική του ετικέτα, μια εικόνα και η κατηγορία της) και το μοντέλο μαθαίνει την απεικόνιση από την είσοδο στην έξοδο. Η ταξινόμηση (διακριτές έξοδοι) και η παλινδρόμηση (συνεχείς έξοδοι) είναι οι δύο βασικές της μορφές. Οι επιβλεπόμενες μέθοδοι είναι ισχυρές αλλά προϋποθέτουν ετικέτες, και οι ετικέτες είναι αυτό που ένα αρχείο 13.637 μηνυμάτων δεν διαθέτει: η παραγωγή τους είναι η δαπανηρή χειροκίνητη εργασία που η παρούσα διπλωματική επιδιώκει να αποφύγει.

Στην ανεπιβλεπτή μάθηση τα δεδομένα αποτελούνται μόνο από εισόδους, και ο στόχος είναι η ανακάλυψη δομής: συσταδοποίηση (ομαδοποίηση όμοιων στοιχείων), μείωση διαστάσεων (εύρεση συμπαγών συντεταγμένων που διατηρούν τη σημαντική μεταβλητότητα) και εκτίμηση πυκνότητας (χαρακτηρισμός των περιοχών του χώρου όπου συγκεντρώνονται τα δεδομένα). Η παρούσα εργασία συνθέτει και τα τρία: τα PCA και UMAP μειώνουν τις διαστάσεις, το HDBSCAN εκτιμά πυκνότητα και συσταδοποιεί με βάση αυτήν. Ανάμεσα στα δύο παραδείγματα βρίσκεται η αυτο-επιβλεπόμενη μάθηση, στην οποία η εποπτεία κατασκευάζεται από τα ίδια τα δεδομένα: ένα γλωσσικό μοντέλο που καλείται να προβλέψει μια κρυμμένη λέξη από τα συμφραζόμενά της εκπαιδεύεται σε δισεκατομμύρια τέτοιες αυτόματα παραγόμενες ασκήσεις χωρίς ανθρώπινες ετικέτες. Το παράδειγμα αυτό έχει σημασία εδώ επειδή το μοντέλο ενσωματώσεων στο κέντρο της ροής (Ενότητα 2.6) προεκπαιδεύτηκε ακριβώς με αυτόν τον τρόπο και στη συνέχεια βελτιώθηκε αντιθετικά. Αυτό επιτρέπει στη ροή, από άκρο σε άκρο, να οργανώσει το αρχείο χωρίς ούτε ένα χειροκίνητο επισημασμένο μήνυμα. Άλλα παραδείγματα (ημι-επιβλεπόμενη μάθηση, ενισχυτική μάθηση) δεν χρησιμοποιούνται στην εργασία.

2.3 Τεχνητά νευρωνικά δίκτυα

Τα μοντέλα πίσω από τις σύγχρονες αναπαραστάσεις κειμένου είναι τεχνητά νευρωνικά δίκτυα [25]. Η στοιχειώδης μονάδα τους, ο τεχνητός νευρώνας, υπολογίζει έναν σταθμισμένο μέσο των εισόδων του, προσθέτει έναν όρο μεροληψίας και περνά το αποτέλεσμα από μια μη γραμμική συνάρτηση ενεργοποίησης ϕ :

$$a = \phi(w \cdot x + b)$$

Ένας μεμονωμένος νευρώνας μπορεί να χαράξει μόνο γραμμικό σύνορο. Τα δίκτυα αποκτούν την εκφραστική τους ισχύ διατάσσοντας νευρώνες σε στρώματα, με τις εξόδους κάθε στρώματος να τροφοδοτούν το επόμενο, ώστε τα μεταγενέστερα στρώματα να υπολογίζουν χαρακτηριστικά χαρακτηριστικών. Με επαρκές πλάτος ακόμη και ένα κρυφό στρώμα μπορεί να προσεγγίσει οποιαδήποτε συνεχή συνάρτηση σε φραγμένο χωρίο, το βάθος όμως είναι αυτό που κάνει την προσέγγιση αποδοτική: η ιεραρχική σύνθεση ταιριάζει με την ιεραρχική δομή των πραγματικών σημάτων, όπου γράμματα συνθέτουν λέξεις, λέξεις φράσεις και φράσεις νόημα.

Η εκπαίδευση ενός δικτύου σημαίνει επιλογή των βαρών του ώστε να ελαχιστοποιείται μια συνάρτηση κόστους L πάνω στα δεδομένα εκπαίδευσης. Η βασική διαδικασία είναι η κατάβαση κλίσης: υπολογίζεται η κλίση του κόστους ως προς κάθε βάρος (αποδοτικά μέσω της οπισθοδιάδοσης, μιας συστηματικής εφαρμογής του κανόνα της αλυσίδας προς τα πίσω μέσα από τα στρώματα), και κάθε βάρος μετακινείται αντίθετα προς την κλίση του,

$$\theta \leftarrow \theta - \eta \nabla L(\theta)$$

όπου η είναι ο ρυθμός μάθησης. Στην πράξη οι κλίσεις εκτιμώνται σε μικρές τυχαίες υποομάδες των δεδομένων (στοχαστική κατάβαση κλίσης), ανταλλάσσοντας ακριβείς κλίσεις με πολλά φθηνά, θορυβώδη βήματα. Κανένα δίκτυο δεν εκπαιδεύεται στην παρούσα εργασία: ο κωδικοποιητής transformer της Ενότητας 2.6 έρχεται πλήρως προεκπαιδευμένος από τρίτους σε τεράστια σώματα κειμένων. Η κατανόηση όμως του τρόπου εκπαίδευσής του εξηγεί τι περιμένει ως είσοδο: τα βάρη του διαμορφώθηκαν από φυσικές, διατεταγμένες, κλιτές προτάσεις, και γι' αυτό το Κεφάλαιο 5 του τροφοδοτεί φυσικό κείμενο και επιφυλάσσει το λημματοποιημένο, απαλλαγμένο από stopwords κείμενο για τις μεθόδους που βασίζονται σε καταμετρήσεις.

Οι συναρτήσεις ενεργοποίησης και οι συναρτήσεις κόστους καθορίζουν τι μπορεί να εκφράσει ένα δίκτυο και τι βελτιστοποιεί. Τα πρώτα δίκτυα χρησιμοποιούσαν κορεννύμενες ενεργοποιήσεις (τη σιγμοειδή και την tanh), των οποίων οι κλίσεις μηδενίζονται για μεγάλες εισόδους, στερώντας από τα βαθιά δίκτυα σήμα μάθησης. Η ανορθωμένη γραμμική μονάδα, $\text{ReLU}(z) = \max(0, z)$, διατηρεί τις κλίσεις ζωντανές και έτσι κατέστησε εφικτό το σύγχρονο βάθος. Για την παλινδρόμηση η καθιερωμένη συνάρτηση κόστους είναι το μέσο τετραγωνικό σφάλμα· για την ταξινόμηση η διασταυρούμενη εντροπία,

$$L = - \sum_i y_i \log \hat{y}_i$$

η οποία τιμωρεί αυστηρά τις βέβαιες λανθασμένες προβλέψεις και, ελαχιστοποιούμενη, ωθεί την προβλεπόμενη κατανομή προς την αληθινή. Η διασταυρούμενη εντροπία επανεμφανίζεται δύο φορές στην εργασία με άλλη μορφή: ως η οικογένεια στόχων εκπαίδευσης πίσω από τα προεκπαιδευμένα γλωσσικά μοντέλα της Ενότητας 2.6, και ως η συνάρτηση κόστους αντιστοίχισης γράφων που ελαχιστοποιεί το UMAP στην Ενότητα 2.7.

2.4 Επεξεργασία φυσικής γλώσσας

Η επεξεργασία φυσικής γλώσσας (Natural Language Processing, NLP) ασχολείται με το να καταστεί η ανθρώπινη γλώσσα υπολογίσιμη. Το κείμενο είναι δύσκολο σήμα: είναι διακριτό αντί αριθμητικό, αμφίσημο σε κάθε επίπεδο (λέξεις με πολλές σημασίες, προτάσεις με πολλές συντακτικές αναλύσεις) και, σε μορφολογικά πλούσιες γλώσσες όπως τα ελληνικά, ένα λέξημα διασκορπίζεται σε δεκάδες επιφανειακούς τύπους. Πριν λειτουργήσει οποιαδήποτε στατιστική μέθοδος, το ακατέργαστο κείμενο περνά από μια αλυσίδα προεπεξεργασίας με σταθερά στάδια, ακόμη κι όταν οι υλοποιήσεις τους είναι γλωσσο-εξαρτημένες. Ο τεμαχισμός (tokenisation) χωρίζει τη ροή χαρακτήρων σε μονάδες (λέξεις, στίξη, αριθμούς). Η κανονικοποίηση εξαλείφει την πλασματική ποικιλομορφία: πεζά/κεφαλαία, εναλλακτικές κωδικοποιήσεις Unicode του ίδιου τονισμένου χαρακτήρα, κενά. Η αφαίρεση stopwords απορρίπτει τις λειτουργικές λέξεις (άρθρα, προθέσεις, αντωνυμίες) που φέρουν γραμματική και όχι θεματική πληροφορία — πολύτιμη για τις μεθόδους καταμέτρησης, επιζήμια για μοντέλα που διαβάζουν ολόκληρες προτάσεις.

Το βαθύτερο βήμα κανονικοποίησης αφορά τη μορφολογία. Η αποκοπή καταλήξεων (stemming) περικόπτει τους κλιτούς τύπους σε ένα χονδρικό κοινό πρόθημα με κανόνες· είναι γρήγορη αλλά καταστροφική, και για τα ελληνικά, όπου η κλίση αλλάζει τις καταλήξεις με τρόπους συνυφασμένους με την παραγωγή, παράγει δυσανάγνωστα, συγκρουόμενα θέματα. Η λημματοποίηση αντιθέτως απεικονίζει κάθε τύπο στο λεξικογραφικό του λήμμα μέσω μορφολογικής ανάλυσης, διατηρώντας

αναγνώσιμες, γλωσσολογικά πραγματικές μονάδες. Είναι η μέθοδος που χρησιμοποιείται στην εργασία (Κεφάλαιο 5), όπου η συγκεκριμένη συμπεριφορά της στα ελληνικά, μαζί με ένα συστηματικό ελάττωμα, μετρίεται πάνω στο σώμα κειμένων. Πάνω στο προεπεξεργασμένο κείμενο, η κλασική NLP χτίζει αναπαραστάσεις καταμέτρησης (συχνότητες όρων, n-grams, TF-IDF), ενώ η σύγχρονη NLP χτίζει μαθημένες, πυκνές αναπαραστάσεις. Οι επόμενες ενότητες αναπτύσσουν και τις δύο, γιατί η εργασία χρησιμοποιεί καθεμία εκεί όπου είναι ισχυρότερη: πυκνές ενσωματώσεις για την ανακάλυψη της θεματικής δομής, στατιστικές καταμέτρησης για την περιγραφή και την επικύρωσή της.

Ακόμη και μετά την προεπεξεργασία, το NLP παραμένει δύσκολο εξαιτίας δύο ιδιοτήτων της γλώσσας. Η αμφισημία διαπερνά κάθε επίπεδο: η «γραμμή» μπορεί να είναι ευθεία, ουρά ή πολιτική τοποθέτηση ανάλογα με τα συμφραζόμενα, και το ίδιο θέμα μηνύματος μπορεί να ανακοινώνει ένα σεμινάριο ή να το ακυρώνει. Επιπλέον, το νόημα είναι συνθετικό αλλά όχι αθροιστικό: η σειρά των λέξεων μετρά, η άρνηση αντιστρέφει το περιεχόμενο, οι ιδιωτισμοί ξεφεύγουν από τα συστατικά τους. Γι' αυτό οι αναπαραστάσεις που αγνοούν τη σειρά (οι μέθοδοι καταμέτρησης) μπορούν να περιγράψουν θέματα αλλά δυσκολεύονται με τις αποχρώσεις, και γι' αυτό υπάρχουν τα μοντέλα της Ενότητας 2.6 που λαμβάνουν υπόψη τη σειρά. Τα κλασικά συστήματα ανακτούν μερικώς τα συμφραζόμενα με n-grams, δηλαδή συνεχόμενες ακολουθίες n μονάδων. Η εργασία χρησιμοποιεί unigrams και bigrams στο στάδιο TF-IDF (Κεφάλαιο 8), όπου bigrams όπως «διδασκαλικής διατριβής» αποσαφηνίζουν ότι τα unigrams μόνα τους δεν μπορούν.

2.5 Από τις καταμετρήσεις λέξεων στις κατανεμημένες αναπαραστάσεις

Η κλασική αναπαράσταση ενός εγγράφου είναι η σακούλα λέξεων: ένα διάνυσμα καταμετρήσεων όρων πάνω σε σταθερό λεξιλόγιο, βελτιωμένο με στάθμιση TF-IDF [15, 16] ώστε να κυριαρχούν οι όροι που είναι συχνοί στο έγγραφο αλλά σπάνιοι στη συλλογή. Τα μοντέλα σακούλας λέξεων είναι διαφανή και παραμένουν το κατάλληλο εργαλείο όταν αντικείμενο μελέτης είναι η ακριβής ταυτότητα των μονάδων. Γι' αυτό η εργασία διατηρεί το TF-IDF για την περιγραφή των συστάδων (Κεφάλαιο 8). Ως βάση για τη μέτρηση ομοιότητας εγγράφων, όμως, έχουν δύο δομικές αδυναμίες. Αγνοούν τη συνωνυμία και την παράφραση: δύο ανακοινώσεις για το ίδιο σεμινάριο γραμμένες με διαφορετικό λεξιλόγιο μοιράζονται λίγες συντεταγμένες. Και κλιμακώνονται κακώς με τη μορφολογία: κάθε κλιτός επιφανειακός τύπος είναι ξεχωριστή διάσταση αν δεν προηγηθεί λημματοποίηση.

Οι κατανεμημένες αναπαραστάσεις απαντούν και στις δύο αδυναμίες ενσωματώνοντας λέξεις (και αργότερα ολόκληρες προτάσεις) ως πυκνά διανύσματα σε έναν χώρο όπου η γεωμετρική εγγύτητα προσεγγίζει τη σημασιολογική ομοιότητα. Η κατανεμητική υπόθεση (λέξεις που εμφανίζονται σε παρόμοια συμφραζόμενα έχουν παρόμοιες σημασίες) υλοποιήθηκε πρώτη φορά σε κλίμακα από τα στατικά μοντέλα ενσωματώσεων λέξεων. Ο περιορισμός τους είναι ότι κάθε τύπος λέξης λαμβάνει ένα μόνο διάνυσμα ανεξαρτήτως συμφραζομένων, οπότε η πολυσημία εξομαλύνεται και η σειρά των λέξεων χάνεται εντελώς. Τα συμφραστικά μοντέλα το επιλύουν υπολογίζοντας αναπαράσταση για κάθε μονάδα ως συνάρτηση ολόκληρης της περιβάλλουσας πρότασης.

Το πέρασμα από τις αραιές στις πυκνές αναπαραστάσεις φαίνεται καθαρότερα στα ίδια τα διανύσματα. Ένα διάνυσμα one-hot έχει μήκος όσο το λεξιλόγιο και είναι σχεδόν εξ ολοκλήρου μηδενικό. Κάθε ζεύγος διαφορετικών λέξεων απέχει εξίσου, οπότε η αναπαράσταση δεν γνωρίζει τίποτα. Στατικά μοντέλα όπως το word2vec μαθαίνουν αντ' αυτού μερικές εκατοντάδες πυκνές

διαστάσεις μέσω μιας αυτο-επιβλεπόμενης βοηθητικής εργασίας, δηλαδή την πρόβλεψη μιας λέξης από τους γείτονές της (CBOW) ή των γειτόνων από τη λέξη (skip-gram), και η γεωμετρία που προκύπτει τοποθετεί τα συνώνυμα κοντά και κωδικοποιεί σχέσεις ως κατευθύνσεις. Η ομοιότητα σε τέτοιους χώρους μετριέται κατά σύμβαση με το συνημίτονο της γωνίας μεταξύ διανυσμάτων αντί με ευκλείδεια απόσταση, επειδή το μήκος του διανύσματος συσχετίζεται με τη συχνότητα και όχι με τη σημασία. Γι' αυτόν τον λόγο κάθε ενσωμάτωση στην εργασία κανονικοποιείται κατά L2 πριν υπολογιστεί οποιαδήποτε απόσταση.

2.6 Κωδικοποιητές transformer και ενσωματώσεις προτάσεων

Ο transformer [24] υπολογίζει συμφραστικές αναπαραστάσεις μέσω αυτο-προσοχής (self-attention): κάθε μονάδα σχηματίζει ένα διάνυσμα ερωτήματος q , ένα διάνυσμα κλειδιού k και ένα διάνυσμα τιμής v , και «προσέχει» όλες τις άλλες μονάδες αναλογικά προς τη συμβατότητα ερωτήματος-κλειδιού,

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

όπου d_k είναι η διάσταση των κλειδιών και η κλιμάκωση σταθεροποιεί τις κλίσεις. Η στοίβαξη στρωμάτων προσοχής με μπλοκ πρόσθιας τροφοδότησης δίνει κωδικοποιητές όπως το BERT [23], προεκπαιδευμένους με μοντελοποίηση καλυμμένης γλώσσας σε μεγάλα σώματα κειμένων. Ένας προεκπαιδευμένος κωδικοποιητής παράγει ένα διάνυσμα ανά μονάδα. Μια ενσωμάτωση εγγράφου απαιτεί τη συγκέντρωση (pooling) αυτών σε ένα ενιαίο διάνυσμα, και οι κωδικοποιητές που έχουν προεκπαιδευτεί μόνο σε γλωσσική μοντελοποίηση παράγουν συγκεντρωμένα διανύσματα με γεωμετρία ακατάλληλη για συγκρίσεις ομοιότητας. Τα μοντέλα ενσωματώσεων προτάσεων όπως το Sentence-BERT [10] μικρορυθμίζουν επομένως τον κωδικοποιητή με αντιθετικούς στόχους που έλκουν κοντά τα σημασιολογικά όμοια κείμενα και απωθούν τα ανόμοια, καθιστώντας τη συνημιτονική ομοιότητα μεταξύ των συγκεντρωμένων διανυσμάτων ουσιαστική.

Οι πολυγλωσσικές ενσωματώσεις προτάσεων επεκτείνουν τα παραπάνω με δεδομένα εκπαίδευσης πολλών γλωσσών πάνω σε κοινό λεξιλόγιο, ώστε μια ελληνική πρόταση και η αγγλική της παράφραση να τοποθετούνται κοντά. Αυτή η ιδιότητα επιτρέπει στην εργασία να ενσωματώσει ένα δίγλωσσο σώμα κειμένων σε έναν ενιαίο χώρο. Το μοντέλο που υιοθετείται, το BGE-M3 [6], είναι ένας πολυγλωσσικός κωδικοποιητής 567 εκατομμυρίων παραμέτρων που παράγει ενσωματώσεις 1.024 διαστάσεων με παράθυρο 8.192 μονάδων, εκπαιδευμένος με αυτο-απόσταξη γνώσης σε πολλαπλά επίπεδα ανάκτησης. Η επιλογή του έναντι μεγαλύτερης εναλλακτικής είναι εμπειρικό αποτέλεσμα του Κεφαλαίου 6. Μία συνέπεια του συμφραστικού παραδείγματος έχει σημασία για τον σχεδιασμό της ροής: επειδή το μοντέλο καταναλώνει φυσική γλώσσα (η σειρά των λέξεων, οι λειτουργικές λέξεις και η κλίση είναι σήμα στο οποίο εκπαιδεύτηκε), η είσοδος δεν πρέπει να είναι λημματοποιημένη ούτε απαλλαγμένη από stopwords. Αυτό υπαγορεύει τον σχεδιασμό δύο παράλληλων κειμενικών αναπαραστάσεων του Κεφαλαίου 5.

Πρακτική σημασία έχουν και δύο λεπτομέρειες υλοποίησης των κωδικοποιητών transformer. Η πρώτη είναι ο τεμαχισμός: για να αποφευχθούν απεριόριστα λεξιλόγια και αστοχίες εκτός λεξιλογίου, τα σύγχρονα μοντέλα τεμαχίζουν το κείμενο σε υπολεξικές μονάδες μαθημένες από δεδομένα (byte-pair encoding, WordPiece ή SentencePiece), ώστε μια σπάνια ελληνική σύνθετη λέξη να αναλύεται σε γνωστά τμήματα αντί για άγνωστη μονάδα. Οι υπολεξικοί τεμαχιστές εφαρμόζουν επίσης

εσωτερικά τη δική τους κανονικοποίηση Unicode, ιδιότητα στην οποία η εργασία στηρίζεται ρητά όταν εκτιμά την επίδραση των μεικτών συντεθειμένων/αποσυντεθειμένων ελληνικών τόνων στο σώμα κειμένων (Ενότητα 11.1). Η δεύτερη είναι η συγκέντρωση: ο κωδικοποιητής εκπέμπει ένα διάνυσμα ανά μονάδα, και το διάνυσμα του εγγράφου προκύπτει είτε από ειδική μονάδα ταξινόμησης είτε από τον μέσο όρο των διανυσμάτων των μονάδων (mean pooling). Το BGE-M3 χρησιμοποιεί τον δεύτερο τρόπο, και γι' αυτό οι πολύ μακριές, περικομμένες εισοδοί χάνουν λίγα: οι όψιμες μονάδες συνεισφέρουν φθίνον βάρος στον μέσο όρο (Ενότητα 6.3).

2.7 Γεωμετρία υψηλών διαστάσεων και μείωση διαστάσεων

Οι χώροι ενσωματώσεων είναι πολυδιάστατοι, και οι πολλές διαστάσεις συμπεριφέρονται αντίθετα με τη διαίσθηση: καθώς η διάσταση αυξάνεται, οι αποστάσεις τυχαίων σημείων συγκεντρώνονται, η αντίθεση μεταξύ κοντινότερου και μακρινότερου γείτονα συρρικνώνεται, και οι εκτιμήσεις πυκνότητας απαιτούν εκθετικά περισσότερα δεδομένα. Η πυκνοτική συσταδοποίηση απευθείας σε 1.024 διαστάσεις είναι επομένως αναξιόπιστη, και ένα βήμα μείωσης αποτελεί καθιερωμένη πρακτική. Η ανάλυση κύριων συνιστωσών (PCA) [14] παρέχει το γραμμικό μέρος: προβάλλει στις ορθοκανονικές κατευθύνσεις μέγιστης διακύμανσης, απορρίπτοντας διαστάσεις που φέρουν κυρίως θόρυβο. Στο συγκεκριμένο σώμα κειμένων η διακύμανση φθίνει σταδιακά (οι 256 συνιστώσες διατηρούν το 87,7%), οπότε η PCA λειτουργεί ως υπολογιστική προ-μείωση και όχι ως η τελική γεωμετρία.

Η υπόθεση της πολλαπλότητας δέχεται ότι τα πραγματικά δεδομένα συγκεντρώνονται κοντά σε μια χαμηλοδιάστατη καμπυλωμένη επιφάνεια μέσα στον περιβάλλοντα χώρο. Οι μη γραμμικές μέθοδοι επιδιώκουν να ανακτήσουν συντεταγμένες πάνω σε αυτή την επιφάνεια. Το UMAP [3] το επιτυγχάνει κατασκευάζοντας έναν ασαφή γράφο k κοντινότερων γειτόνων στον χώρο εισόδου και βελτιστοποιώντας μια χαμηλοδιάστατη διάταξη της οποίας ο ασαφής γράφος ταιριάζει με τον αρχικό υπό συνάρτηση κόστους διασταυρούμενης εντροπίας (η τυπική κατασκευή δίνεται στην Ενότητα 7.3). Σε σύγκριση με το t-SNE, το UMAP διατηρεί περισσότερη ολική δομή, κλιμακώνεται καλύτερα και, καθοριστικά εδώ, υποστηρίζει αυθαίρετη διάσταση εξόδου, ώστε να μπορεί να παραγάγει τον χώρο 13 διαστάσεων στον οποίο πραγματοποιείται η συσταδοποίηση και όχι μόνο δισδιάστατες απεικονίσεις. Η στοχαστικότητα του και η ευαισθησία του στις υπερπαραμέτρους αποτελούν πραγματικό κόστος. Στην εργασία αντιμετωπίζονται με σταθερό seed και με την ανάλυση ευαισθησίας του Κεφαλαίου 9.

2.8 Παραδείγματα συσταδοποίησης

Οι διαμεριστικές μέθοδοι αναθέτουν κάθε σημείο σε ακριβώς μία από k συστάδες. Ο k -means ελαχιστοποιεί την ενδοσυσταδική διακύμανση,

$$J = \sum_j \sum_{x \in C_j} \|x - \mu_j\|^2$$

πράγμα που προϋποθέτει κυρτές συστάδες παρόμοιου μεγέθους και απαιτεί το k εκ των προτέρων. Η συσσωρευτική (agglomerative) συσταδοποίηση χτίζει μια ιεραρχία από κάτω προς τα πάνω. Το κριτήριο του Ward [22] συγχωνεύει το ζεύγος συστάδων του οποίου η ένωση αυξάνει λιγότερο τη συνολική ενδοσυσταδική διακύμανση, μοιραζόμενο τη γεωμετρία διακύμανσης του k -means και προσθέτοντας εμφωλευμένη δομή. Και οι δύο οικογένειες χρησιμοποιούνται στο Κεφάλαιο 9 ως

μέθοδοι αναφοράς. Είναι ισχυρές όταν τους δοθεί το σωστό k , και αυτό τις καθιστά κατατοπιστικούς συγκριτές.

Οι πυκνοτικές μέθοδοι ορίζουν αντιθέτως τις συστάδες ως συνεκτικές περιοχές υψηλής πυκνότητας σημείων, χωρισμένες από αραιές περιοχές, και, κρίσιμο για ένα αρχείο λιστών, επιτρέπουν σε σημεία να μην ανήκουν σε καμία συστάδα. Το DBSCAN το τυποποιεί με ένα καθολικό κατώφλι πυκνότητας, το οποίο αποτυγχάνει όταν οι συστάδες έχουν διαφορετικές πυκνότητες. Το HDBSCAN [4, 5] αίρει το καθολικό κατώφλι χτίζοντας την ιεραρχία των πυκνοτικά συνεκτικών συνιστωσών για όλα τα κατώφλια ταυτόχρονα, με αποστάσεις αμοιβαίας προσβασιμότητας, και επιλέγοντας κατόπιν το σύνολο των μη επικαλυπτόμενων συστάδων με μέγιστη σταθερότητα (κριτήριο *excess-of-mass*: οι τυπικοί ορισμοί δίνονται στην Ενότητα 7.4). Οι ιδιότητες που το καθιστούν τη μέθοδο της παρούσας εργασίας συμπίπτουν με τις ιδιότητες των δεδομένων: θεματικές συστάδες πολύ διαφορετικών μεγεθών και πυκνοτήτων, καμία υπερασπίσιμη εκ των προτέρων εκτίμηση για το k , και ένας πραγματικός πληθυσμός μεμονωμένων μηνυμάτων που πρέπει να χαρακτηριστούν θόρυβος αντί να εξαναγκαστούν στην κοντινότερη θεματική.

Για πληρότητα, το πυκνοτικό παράδειγμα γίνεται πιο εύληπτο μέσα από τους ορισμούς του DBSCAN, τους οποίους το HDBSCAN γενικεύει. Ορίζονται μια ακτίνα ϵ και ένα πλήθος minPts : ένα σημείο είναι σημείο πυρήνα αν τουλάχιστον minPts σημεία βρίσκονται σε απόσταση έως ϵ από αυτό· σημεία εντός ϵ από σημείο πυρήνα είναι πυκνοτικά προσβάσιμα από αυτό· μια συστάδα είναι ένα μέγιστο σύνολο αμοιβαία πυκνοτικά συνδεδεμένων σημείων· σημεία μη προσβάσιμα από κανένα σημείο πυρήνα είναι θόρυβος. Η κατασκευή είναι κομψή αλλά εξαρτάται από ένα και μόνο καθολικό ϵ (ένα κατώφλι πυκνότητας για ολόκληρο το σύνολο δεδομένων), το οποίο αποτυγχάνει όποτε οι πραγματικές συστάδες έχουν διαφορετικές πυκνότητες, όπως συμβαίνει με τις θεματικές συστάδες ενός αρχείου ηλεκτρονικού ταχυδρομείου (μια συστάδα 938 ανακοινώσεων διπλωματικών είναι πολύ πυκνότερη από μια συστάδα 33 μηνυμάτων Erasmus). Η συνεισφορά του HDBSCAN είναι η άρση του ϵ : εξετάζει όλα τα κατώφλια ταυτόχρονα και αφήνει κάθε συστάδα να γεννιέται και να διαλύεται στη δική της πυκνότητα.

2.9 Αξιολόγηση ανεπίβλεπτης δομής

Ελλείψει ετικετών αναφοράς, η ποιότητα μιας συσταδοποίησης πρέπει να τεκμηριωθεί από εσωτερικές και ανεξάρτητες ενδείξεις. Τα εσωτερικά μέτρα βαθμολογούν τη συμπαγή δομή και τον διαχωρισμό στην ίδια την αναπαράσταση. Η εργασία χρησιμοποιεί μια σταθμισμένη κατά μέγεθος διάμεσο συνημιτονική συνοχή προς τα κεντροειδή (Ενότητα 7.5), προτιμώμενη από τη *silhouette* επειδή η δεύτερη υποβαθμίζεται σε πολλές διαστάσεις και τιμωρεί τα άνισα μεγέθη συστάδων που το σώμα κειμένων πράγματι διαθέτει. Η αδυναμία κάθε εσωτερικού μέτρου είναι η κυκλικότητα (μπορεί να επιβραβεύσει την αναπαράσταση αντί για τη σημασιολογία), και γι' αυτό η έρευνα θεματικών μοντέλων ανέπτυξε μέτρα λεξιλογικής συνοχής βασισμένα στη συνεμφάνιση όρων, από τα οποία η κανονικοποιημένη σημειακή αμοιβαία πληροφορία (NPMI) [8] συσχετίζεται καλύτερα με τις ανθρώπινες κρίσεις ποιότητας θεμάτων. Το NPMI υπολογίζεται από στατιστικές μονάδων που οι ενσωματώσεις δεν βλέπουν ποτέ, γεγονός που το καθιστά τον εξωτερικό έλεγχο του Κεφαλαίου 9. Μια τρίτη γραμμή τεκμηρίωσης είναι η ανθεκτικότητα: ένα αποτέλεσμα που επιβιώνει διαταραχών των υπερπαραμέτρων του αντανakλά δομή των δεδομένων και όχι ρυθμισμένο τέχνημα. Τα κλασικά πιθανοτικά θεματικά μοντέλα όπως το LDA [1] συνοδεύονται από τη δική τους παράδοση

αξιολόγησης (perplexity σε κρατημένα δεδομένα), η οποία είναι γνωστό ότι συσχετίζεται κακώς με την ανθρώπινη κρίση, ένας ακόμη λόγος που εδώ προτιμάται η οικογένεια της συνοχής.

Όταν υπάρχουν ετικέτες αναφοράς, εξωτερικοί δείκτες όπως ο διορθωμένος δείκτης Rand ή η κανονικοποιημένη αμοιβαία πληροφορία βαθμολογούν τη συμφωνία μεταξύ της διαμέρισης που ανακαλύφθηκε και της αληθινής. Τέτοιες ετικέτες δεν υπάρχουν για το συγκεκριμένο σώμα κειμένων (η παραγωγή τους είναι αυτό που η ροή αντικαθιστά), οπότε η εξωτερική επικύρωση παίρνει εδώ δύο υποκατάστατες μορφές: στοχευμένη χειροκίνητη επιθεώρηση συστάδων έναντι των μηνυμάτων-μελών τους (Κεφάλαιο 8), και τον χρονικό έλεγχο του Κεφαλαίου 10, στον οποίο η δομή που ανακαλύφθηκε αντιπαραβάλλεται με ανεξάρτητα γνωστά θεσμικά γεγονότα. Ο δεύτερος αποτελεί, στην ουσία, έλεγχο εξωτερικής εγκυρότητας με βάση ανεξάρτητα γνωστά γεγονότα αντί για χειροκίνητες ετικέτες.

2.10 Μπεϋζιανή βελτιστοποίηση υπερπαραμέτρων

Το στάδιο συσταδοποίησης εκθέτει πέντε αλληλεπιδρώσες υπερπαραμέτρους, των οποίων η από κοινού επίδραση στην αντικειμενική συνάρτηση είναι μη κυρτή, μη παραγωγίσιμη και ακριβή στην αποτίμηση, δηλαδή ένα πρόβλημα βελτιστοποίησης μαύρου κουτιού. Η αναζήτηση πλέγματος κλιμακώνεται εκθετικά και η τυχαία αναζήτηση σπαταλά αποτιμήσεις σε κακές περιοχές. Η ακολουθιακή βελτιστοποίηση βασισμένη σε μοντέλο προσαρμόζει αντ' αυτού ένα υποκατάστατο μοντέλο στα παρατηρημένα ζεύγη (παραμέτροι, βαθμολογία) και προτείνει την επόμενη δοκιμή εκεί όπου η αναμενόμενη βελτίωση είναι μεγαλύτερη. Ο Tree-structured Parzen Estimator [18], όπως υλοποιείται στο Optuna [7], μοντελοποιεί τις πυκνότητες $l(x)$ των παραμέτρων στις καλές δοκιμές και $g(x)$ στις υπόλοιπες, και προτείνει σημεία που μεγιστοποιούν τον λόγο

$$EI(x) \propto \frac{l(x)}{g(x)}$$

ο οποίος συγκεντρώνει τις δοκιμές σε περιοχές που ιστορικά παρήγαγαν καλές βαθμολογίες διατηρώντας παράλληλα την εξερεύνηση. Σε συνδυασμό με πρόωρη διακοπή (median pruning) των εμφανώς μη υποσχόμενων δοκιμών, αυτό κατέστησε εφικτή μια αναζήτηση 200 δοκιμών στον χώρο UMAP–HDBSCAN σε μέτριο υλικό (Ενότητα 7.5).

Η κύρια εναλλακτική οικογένεια υποκατάστατων μοντέλων είναι οι γκαουσιανές διαδικασίες, που μοντελοποιούν την ίδια την αντικειμενική συνάρτηση και προτείνουν σημεία με βάση την αναμενόμενη βελτίωση υπό αυτό το μοντέλο. Οι γκαουσιανές διαδικασίες διαπρέπουν σε ομαλούς, χαμηλοδιάστατους, συνεχείς χώρους αλλά χειρίζονται αδέξια ακέραιες, κατηγορικές και υπό συνθήκη παραμέτρους και κλιμακώνονται κυβικά με το πλήθος των παρατηρήσεων. Ο TPE αντιστρέφει τη μοντελοποίηση (πυκνότητες παραμέτρων δεδομένης της επίδοσης, αντί επίδοση δεδομένων των παραμέτρων), γεγονός που καθιστά φυσικούς τους μεικτούς και υπό συνθήκη χώρους αναζήτησης. Ο χώρος αναζήτησης του Κεφαλαίου 7 είναι τέτοιος (ακέραιοι, μία συνεχής παράμετρος, και ένα εύρος `min_samples` που εξαρτάται από το `min_cluster_size`), και γι' αυτό ο TPE αποτελεί εδώ την κατάλληλη επιλογή.

2.11 Επεξεργασία φυσικής γλώσσας για τα Νέα Ελληνικά

Τα νέα ελληνικά είναι έντονα κλιτή, συμφυρματική γλώσσα: ουσιαστικά και επίθετα κλίνονται σε τέσσερις πτώσεις, δύο αριθμούς και τρία γένη, και τα ρήματα κλίνονται κατά χρόνο, ποιόν ενεργείας, φωνή, έγκλιση και πρόσωπο. Ένα λέξημα εμφανίζεται έτσι συστηματικά σε δεκάδες τύπους: στο συγκεκριμένο σώμα κειμένων το λέξημα «φοιτητής» εμφανίζεται σε 40 διακριτούς επιφανειακούς τύπους. Για τις στατιστικές συχνοτήτων αυτό καθιστά τη λημματοποίηση απαραίτητη και την ποιότητά της πρωτεύον ζήτημα. Η καθιερωμένη υποδομή είναι το μοντέλο `el_core_news_lg` του `spracy` [9], του οποίου οι συστηματικές συμπεριφορές στο σώμα κειμένων (συμπεριλαμβανομένου ενός ελαττώματος σύνθετων λημμάτων για τα προθετικά συμφύματα) μετρώνται και διορθώνονται στο Κεφάλαιο 5. Το ελληνικό θεσμικό κείμενο, επιπλέον, σπάνια είναι μονόγλωσσο: οι ανακοινώσεις ενσωματώνουν αγγλικές περιλήψεις, ονόματα και ορολογία, οπότε μια ροή που απορρίπτει τις λατινικές μονάδες απορρίπτει περιεχόμενο. Τα ελληνικά παραμένουν συγκριτικά γλώσσα περιορισμένων πόρων (η κάλυψή τους στις πολυγλωσσικές αξιολογήσεις ενσωματώσεων είναι πενιχρή), και γι' αυτό το Κεφάλαιο 6 επιλέγει το μοντέλο ενσωματώσεων με άμεση μέτρηση στο σώμα κειμένων αντί να εμπιστευθεί δημόσιους πίνακες κατάταξης.

Τέλος, το ίδιο το σύστημα γραφής επιβάλλει τεχνικούς περιορισμούς. Τα νέα ελληνικά χρησιμοποιούν από το 1982 το μονοτονικό σύστημα (μία οξεία και τα διαλυτικά), αλλά το Unicode επιτρέπει κάθε τονισμένο γράμμα να κωδικοποιείται είτε ως ένας συντεθειμένος χαρακτήρας είτε ως βασικό γράμμα συν συνδυαζόμενο σημάδι, και τα πραγματικά κείμενα αναμειγνύουν ελεύθερα τις δύο μορφές. Μια ροή που συγκρίνει μονάδες σε επίπεδο `byte` χωρίς κανονικοποίηση θα αντιμετωπίσει σιωπηλά τη «διατριβή» και το αποσυντεθειμένο δίδυμό της ως διαφορετικές λέξεις. Οι συμβάσεις προσθέτουν επιπλέον παγίδες: τα κεφαλαία ελληνικά κατά κανόνα δεν τονίζονται (ΕΚΛΟΓΕΣ έναντι εκλογές), και το σίγμα διαθέτει διακριτό τελικό τύπο (ς). Καθένα από αυτά εμφανίζεται κάπου στην εργασία: στην αφαίρεση τόνων του σταδίου χαρακτηρισμού, στα μη ευαίσθητα σε πεζά/κεφαλαία μοτίβα καθαρισμού, και στα ευρήματα κανονικοποίησης Unicode της Ενότητας 11.1. Με το υπόβαθρο αυτό, τα επόμενα κεφάλαια περνούν από τις έννοιες στο ίδιο το σώμα κειμένων.

3 Συλλογή και Έλεγχος Δεδομένων

3.1 Συλλογή δεδομένων

Το πρώτο πρακτικό στάδιο της ροής είναι η συλλογή των δεδομένων. Πηγή είναι το δημόσιο διαδικτυακό αρχείο των λιστών ηλεκτρονικού ταχυδρομείου του Πανεπιστημίου Πατρών (mailarchive.upatras.gr). Το αρχείο οργανώνεται σε σελιδοποιημένες σελίδες ευρετηρίου HTML, καθεμία με είκοσι μηνύματα, ενώ κάθε μήνυμα σερβίρεται ως ξεχωριστή σελίδα HTML με δομημένα πεδία (Author, Date, To, Subject) και το σώμα του μηνύματος μέσα σε στοιχείο <div class="messageBody">.

Ο scraper υλοποιήθηκε σε Python με τις βιβλιοθήκες requests και BeautifulSoup [19]. Η BeautifulSoup προτιμήθηκε από ένα βαρύτερο πλαίσιο όπως το Scrapy επειδή η εργασία απαιτεί μόνο εξαγωγή απλού κειμένου από έναν μικρό, καλά δομημένο ιστότοπο χωρίς απόδοση JavaScript. Για κάθε σελίδα ευρετηρίου ο scraper συλλέγει τις σχετικές διευθύνσεις των είκοσι μηνυμάτων, τις συμπληρώνει με τον κόμβο του αρχείου, αναλύει κάθε σελίδα μηνύματος και εξάγει τα πέντε πεδία μέσω των ονομάτων κλάσεων του HTML. Η διεύθυνση της επόμενης σελίδας ευρετηρίου λαμβάνεται από το στοιχείο σελιδοποίησης, και η διαδικασία επαναλαμβάνεται μέχρι να καλυφθεί το επιθυμητό χρονικό εύρος.

Επειδή το σώμα κειμένων αναμειγνύει ελληνική και λατινική γραφή, όλο το κείμενο κωδικοποιήθηκε και αποκωδικοποιήθηκε ως UTF-32 κατά τη συλλογή, και το σύνολο δεδομένων αποθηκεύτηκε ως αρχείο CSV με διαχωριστικό στηλοθέτη σε UTF-32. Εκ των υστέρων, το UTF-8 θα ήταν εξίσου ορθή και σημαντικά συμπαγέστερη επιλογή. Το UTF-32 διατηρήθηκε σε όλη τη ροή αποκλειστικά για συμβατότητα μεταξύ των σταδίων. Το ακατέργαστο σύνολο δεδομένων (tovima.csv) περιέχει 14.277 γραμμές και πέντε στήλες: Author, Date, To, Subject, Message.

3.2 Προέλευση δεδομένων και προστασία προσωπικών δεδομένων

Το αρχείο είναι δημόσια προσβάσιμο χωρίς αυθεντικοποίηση, και το περιεχόμενό του αποτελείται από θεσμικές επικοινωνίες απευθυνόμενες σε ανοιχτές πανεπιστημιακές λίστες. Η ανάλυση αντιμετωπίζει παρ' όλα αυτά το υλικό με την προσοχή που αρμόζει σε δεδομένα που κατονομάζουν πραγματικά πρόσωπα. Όλα τα αποτελέσματα που παρουσιάζονται είναι συγκεντρωτικά (συχνότητες θεμάτων, στατιστικές συστάδων, λίστες όρων), και κανένα μήνυμα δεν αναπαράγεται ολόκληρο σε οποιοδήποτε σημείο της εργασίας. Κατά τον δομικό καθαρισμό, τα μηνύματα που περιέχουν ενσωματωμένα στοιχεία επικοινωνίας (αριθμούς τηλεφώνου, προσωπικές διευθύνσεις ηλεκτρονικού ταχυδρομείου· περίπου 8–9% του σώματος κειμένων) επισημάνθηκαν σε ειδική στήλη contains_pii_pattern, και κάθε θέμα ή απόσπασμα που παρατίθεται στην εργασία ή στα παραρτήματά της ελέγχθηκε έναντι αυτής της επισημάνσης και επιθεωρήθηκε χειροκίνητα. Τα παράγωγα αρχεία (ενσωματώσεις, χαρακτηρισμοί συστάδων, στατιστικές όρων) δεν αποκαλύπτουν για κανένα πρόσωπο τίποτα πέρα από όσα δημοσιεύει η ίδια η δημόσια πηγή. Η επεξεργασία διενεργείται για σκοπούς επιστημονικής έρευνας επί δημόσια διαθέσιμων θεσμικών επικοινωνιών, σύμφωνα με τις ερευνητικές προβλέψεις του ΓΚΠΔ.

3.3 Διερευνητική ανάλυση δεδομένων

Πριν από οποιονδήποτε καθαρισμό, ένα ειδικό notebook ελέγχου (02_eda_data_audit.ipynb) χαρτογράφησε τα ακατέργαστα δεδομένα. Ο σκοπός του σταδίου είναι μεθοδολογικός: κάθε επόμενη ενέργεια καθαρισμού πρέπει να ανάγεται σε ένα καταγεγραμμένο, ποσοτικοποιημένο εύρημα. Τα ευρήματα που ακολουθούν αποτελούν το σημείο αναφοράς για τον δομικό και τον γλωσσικό καθαρισμό των δύο επόμενων κεφαλαίων. Τα κύρια ευρήματα συνοψίζονται στον Πίνακα 3.1.

#	Εύρημα	Μέγεθος	Απόφαση
1	Διπλότυπα περιεχομένου στο ζεύγος (Subject, Message)	327 γραμμές (έναντι μόλις 115 πλήρως ταυτόσημων)	Απαλοιφή διπλοτύπων βάσει περιεχομένου, διατήρηση της πρωιμότερης εμφάνισης
2	Μη αναλύσιμες ημερομηνίες	3 γραμμές	Διαγραφή
3	Ελλιπές έτος 2017 (μόνο Δεκέμβριος)	10 γραμμές	Διαγραφή· θόρυβος εκκίνησης του scraper
4	Ελλιπές έτος 2023 (Ιαν–Ιούλ)	7 μήνες	Διατήρηση· επισήμανση στα ετήσια διαγράμματα
5	Υπολείμματα HTML/CSS στα σώματα	~20% των μηνυμάτων	Δομική αφαίρεση ετικετών· επισήμανση γραμμών
6	Αλυσίδες απαντήσεων/προωθήσεων στα θέματα	~6% των θεμάτων	Επισήμανση, όχι διαγραφή
7	Σχεδόν κενά μηνύματα (<20 χαρακτήρες)	276 γραμμές	Διαγραφή
8	Ακατάστατο πεδίο παραληπτών (To)	1.981 διακριτές ακατέργαστες τιμές	Κανονικοποίηση σε κανονικές ετικέτες λιστών
9	Ενσωματωμένα στοιχεία επικοινωνίας (PII)	~8–9% των μηνυμάτων	Επισήμανση για ελέγχους απόκρυψης στα παρατιθέμενα παραδείγματα

Πίνακας 3.1: Ευρήματα του ελέγχου δεδομένων και η απόφαση καθαρισμού που υπαγόρευσε το καθένα.

4 Δομική Προεπεξεργασία

Το δομικό στάδιο (03_preprocessing.ipynb) υλοποιεί τις αποφάσεις ποιότητας δεδομένων σε επίπεδο γραμμής που υπαγόρευσε ο έλεγχος. Δεν εκτελεί καμία γλωσσική επεξεργασία. Η διατήρηση των δύο ζητημάτων σε ξεχωριστά notebooks καθιστά το καθένα ανεξάρτητα ελέγξιμο. Μετά την αφαίρεση ενός τεχνήματος του scraper (ένα αρχικό κενό σε κάθε πεδίο), το στάδιο διαγράφει τις 3 γραμμές με μη αναλύσιμες ημερομηνίες, τις 10 γραμμές του ελλιπούς έτους 2017, 326 διπλότυπα περιεχομένου (απαλοιφή βάσει του ζεύγους (Subject, Message) με διατήρηση της πρωιμότερης εμφάνισης, καθώς οι μεταγενέστερες ταυτόσημες εμφανίσεις αντιμετωπίζονται ως επαναποστολές) και 246 σχεδόν κενά μηνύματα, μειώνοντας το σώμα κειμένων από 14.277 σε 13.692 γραμμές: συνολική απώλεια 4,1%, με κάθε διαγραμμένη γραμμή να ανάγεται σε συγκεκριμένο εύρημα του ελέγχου.

Οι ετικέτες HTML αφαιρούνται με κανονική έκφραση αντιστοίχισης ετικετών, και οι επηρεαζόμενες γραμμές επισημαίνονται στη στήλη `had_html_markup` αντί να ξαναγράφονται σιωπηλά, ώστε η κλίμακα της παρέμβασης να παραμένει ορατή. Τα θέματα απαντήσεων/προωθήσεων επισημαίνονται ομοίως (`is_reply_or_forward`) αντί να διαγράφονται, αφού μια απάντηση μπορεί να φέρει πράγματι νέο περιεχόμενο.

4.1 Κανονικοποίηση του πεδίου παραληπτών

Το ακατέργαστο πεδίο Το περιείχε 1.981 διακριτές τιμές για ό,τι στην πραγματικότητα είναι μια χούφτα λιστών. Τα προβλήματα ήταν τρία. Ορισμένες γραμμές περιείχαν ολόκληρα αποσπάσματα συγκεντρωτικών μηνυμάτων (Old-Topics:, New-Topics:, CC:), ακόμη και πλήρη θέματα προωθημένων μηνυμάτων συνενωμένα μέσα στη συμβολοσειρά των παραληπτών, τέχνημα του scraper από διαφορετική διάταξη σελίδας του αρχείου. Οτιδήποτε από τους δείκτες αυτούς και μετά απορρίφθηκε ως μη ανακτήσιμο. Επιπλέον, παραλλαγές πεζών/κεφαλαίων, εισαγωγικών και γραφής των ίδιων λιστών (tonima, TOVIMA, tonima@upatras.gr, το βήμα, ανακοινώσεις, ...) ενοποιήθηκαν μέσω ρητής αντιστοίχισης σε έξι ετικέτες: `tonima` (69,0% των γραμμών), `announcements` (36,4%), `studentnews` (4,0%), `sdp` (2,1%), `info` (1,5%) και `all` (0,9%). Τέλος, μια μακριά ουρά αρκετών εκατοντάδων ονομάτων προσώπων και διευθύνσεων τμημάτων διατηρήθηκε σε ξεχωριστή στήλη `to_other_recipients` αντί να εξαναγκαστεί σε ψευδή κατηγορία. Η προκύπτουσα στήλη `to_lists` παρέχει ένα αδρό, ημι-ανεξάρτητο σήμα που αξιοποιείται αργότερα για ελέγχους λογικότητας των ανεπίβλεπτων συστάδων.

5 Γλωσσική Προεπεξεργασία

5.1 Δύο παράλληλες αναπαραστάσεις κειμένου

Η κεντρική σχεδιαστική απόφαση αυτού του σταδίου (04_nlp_preprocessing.ipynb) είναι ότι η ροή παράγει δύο παράλληλες στήλες κειμένου που εξυπηρετούν δύο διαφορετικούς καταναλωτές.

embedding_text: αποθροιστικό αλγόριθμο γλωσσικά φυσικό δίγλωσσο κείμενο (αφαιρούνται διευθύνσεις URL, γραμμές παραθέσεων, προσφωνήσεις και αποφωνήσεις· τίποτε άλλο δεν θίγεται). Αυτή είναι η είσοδος του μοντέλου ενσωματώσεων. Τα σύγχρονα μοντέλα transformer εκπαιδεύονται σε φυσική γλώσσα. Η τροφοδότησή τους με λημματοποιημένες, απαλλαγμένες από stopwords «σακούλες ριζών» αφαιρεί τη σειρά των λέξεων, τις λειτουργικές λέξεις και την κλιτική πληροφορία (για παράδειγμα, την ελληνική πτωτική σήμανση που διακρίνει το υποκείμενο από το αντικείμενο) που το μοντέλο εκπαιδεύτηκε να αξιοποιεί.

cleaned_text: λημματοποιημένες, φιλτραρισμένες από stopwords και θόρυβο ακολουθίες μονάδων. Αυτή είναι η είσοδος της λεξιλογικής-στατιστικής πλευράς της ροής (χαρακτηρισμός συστάδων με TF-IDF και συνοχή NPMI), όπου η ακριβής αντιστοίχιση ταυτότητας μονάδων είναι το ζητούμενο. Τα ελληνικά είναι έντονα κλιτική γλώσσα: η άμεση μέτρηση στο σώμα κειμένων έδειξε την έννοια «φοιτητής» κατακερματισμένη σε 40 διακριτούς επιφανειακούς τύπους. Χωρίς λημματοποίηση, οι στατιστικές συχνοτήτων αντιμετωπίζουν τους τύπους αυτούς ως άσχετες μονάδες, αραιώνοντας κάθε καταμέτρηση στην οποία συμμετέχουν.

Η συγχώνευση των δύο αναπαραστάσεων (δηλαδή η τροφοδότηση λημματοποιημένου κειμένου και στο μοντέλο ενσωματώσεων) εξετάστηκε και απορρίφθηκε για τους παραπάνω λόγους.

5.2 Δομικός καθαρισμός κειμένου με μετρημένη κάλυψη

Αφαίρεση διευθύνσεων URL. Μια απλοϊκή έκφραση όπως `https?://\S+` κάνει διάκριση πεζών/κεφαλαίων και υποθέτει ότι δεν υπάρχουν κενά γύρω από τον διαχωριστή του σχήματος. Μετρημένη στο σώμα κειμένων, αφήνει υπόλειμμα `http/https` στο 2,8% των μηνυμάτων, λόγω διευθύνσεων γραμμένων με κεφαλαία και διευθύνσεων που αναδιπλώνονται σε νέα γραμμή με κενό πριν από το «`://`». Η έκφραση που υιοθετήθηκε αγνοεί πεζά/κεφαλαία και ανέχεται κενά γύρω από τον διαχωριστή, μειώνοντας το υπόλειμμα στο 0,9%. Το υπόλοιπο είναι μια μακριά ουρά μεμονωμένα κακοσχηματισμένων διευθύνσεων (αλυσίδες ανακατευθύνσεων με percent-encoding, ελλείποντα σύμβολα άνω-κάτω τελείας) που έγινε αποδεκτή ως τεκμηριωμένος υπολειπόμενος θόρυβος.

Γραμμές παραθέσεων. 939 μηνύματα (6,9%) περιέχουν γραμμές παράθεσης με πρόθεμα «>», σε ορισμένες περιπτώσεις μάλιστα αυτές συνιστούν ολόκληρο το σώμα. Αξιοσημείωτα, το σύνολο αυτό επικαλύπτεται μόνο μερικώς με την επισήμανση απαντήσεων/προωθήσεων στα θέματα (τα δύο σήματα διαφωνούν σε 770 γραμμές), επιβεβαιώνοντας ότι το παρατιθέμενο περιεχόμενο πρέπει να ανιχνεύεται απευθείας στο σώμα. Οι γραμμές παράθεσης αφαιρούνται με έκφραση πολλαπλών γραμμών.

Προσφωνήσεις. Το πρώτο μοτίβο που αξιολογήθηκε περιοριζόταν στους τύπους ενικού του επιθέτου (αγαπητέ/αγαπητή). Η άμεση καταμέτρηση έδειξε ότι οι τύποι πληθυντικού (αγαπητοί: 985 εμφανίσεις, αγαπητές: 333, αγαπητά: 315) υπερτερούν των τύπων ενικού με λόγο περίπου τρία προς

ένα, οπότε ένα τέτοιο μοτίβο χάνει περίπου το 80% των πραγματικών προσφωνήσεων, καλύπτοντας μόλις το 6,5% των μηνυμάτων. Το μοτίβο που υιοθετήθηκε καλύπτει όλους τους κλιτούς τύπους και δεσμεύεται ως προς τη θέση: μια αντιστοίχιση γίνεται δεκτή μόνο μέσα στους πρώτους 80 χαρακτήρες του μηνύματος, αφού η προσφώνηση εξ ορισμού ανοίγει ένα μήνυμα. Η κάλυψη ανέβηκε στο 16,6% χωρίς να βρεθούν ψευδώς θετικά στη χειροκίνητη επιθεώρηση.

Αποφωνήσεις. Ένα μοτίβο αποφώνησης αγκυρωμένο στο τέλος του κειμένου ενεργοποιείται μόλις στο 0,1% των μηνυμάτων (οι υπογραφές σπανίως τερματίζουν το ακατέργαστο κείμενο), ενώ οι λέξεις-κλειδιά αποφώνησης (με εκτίμηση, ευχαριστώ, φιλικά) εμφανίζονται μεμονωμένα σε περίπου 6% των μηνυμάτων. Το αντίθετο άκρο, η άπληστη αντιστοίχιση από μια λέξη-κλειδί μέχρι το τέλος του κειμένου, υπερδιορθώνει: το 43% τέτοιων αντιστοιχίσεων θα παρέσυρε πάνω από 500 χαρακτήρες περιεχομένου, επειδή τα ελληνικά θεσμικά μηνύματα χρησιμοποιούν συχνά το «ευχαριστώ» ως ουσιαστικό περιεχόμενο («θα θέλαμε να ευχαριστήσουμε τον Πρύτανη για...») και όχι ως αποφώνηση. Ο κανόνας που υιοθετήθηκε αφαιρεί από την τελευταία εμφάνιση λέξης-κλειδιού μέσα στο τελευταίο τέταρτο του μηνύματος, και μόνο εφόσον η ουρά που προκύπτει είναι κάτω από 400 χαρακτήρες, μέγεθος συμβατό με πραγματικό μπλοκ υπογραφής. Η κάλυψη είναι 4,7%, με συνειδητή ανταλλαγή ανάκλησης έναντι ακρίβειας. Παραμένει μικρή υπολειπόμενη ανακρίβεια για μηνύματα που ευχαριστούν ουσιαστικά κάποιον και συγχρόνως κλείνουν τυπικά κοντά στο τέλος τους. Αυτή δηλώνεται ως γνωστός περιορισμός.

5.3 Λημματοποίηση και η διόρθωση των σύνθετων λημμάτων

Η λημματοποίηση χρησιμοποιεί το μοντέλο `el_core_news_lg` του `spracy` [9]. Κατά την επαλήθευση εντοπίστηκε ένα συστηματικό ελάττωμα: ο λημματοποιητής επιστρέφει για τα ελληνικά προθετικά συμφύματα (πρόθεση + άρθρο) μια ενιαία συμβολοσειρά λήμματος με εσωτερικό κενό: το «στην» (σε + την) λημματοποιείται στην ενιαία μονάδα «σε ο». Επειδή το σύνολο των `stopwords` περιέχει μόνο μονολεκτικές εγγραφές, οι συγχωνευμένες αυτές μονάδες δεν αντιστοιχίζονταν με τίποτα και περνούσαν το φίλτρο, για να διασπαστούν κατόπιν μηχανικά ξανά σε δύο μονάδες κατά τη σειριοποίηση του καθαρισμένου κειμένου, εμφανιζόμενες ως μαζική διαρροή των `stopwords` «σε» και «ο» (μαζί 6,75% όλων των μονάδων του σώματος κειμένων). Η δειγματοληψία έδειξε ότι το 2,31% όλων των λημματικών μονάδων ήταν σύνθετα με κενό, εκ των οποίων το 99,3% ήταν η καθαρή περίπτωση σε+άρθρο. Η διόρθωση διασπά κάθε λήμμα που περιέχει κενό στις συνιστώσες μονάδες του πριν από το φιλτράρισμα `stopwords` (Απόσπασμα 5.1). Μετά τη διόρθωση, η μετρημένη διαρροή λειτουργικών λέξεων έπεσε από 6,75% σε 0,012% του σώματος κειμένων, ένα υπολειπόμενο δάπεδο θορύβου από διάσπαρτες οριακές περιπτώσεις τύπου/λήμματος.

```
# Το el_core_news_lg επιστρέφει "σε ο" ως ενιαίο λήμμα για συμφύματα
# όπως το "στην". τα λήμματα με κενό διασπώνται ΠΡΙΝ το φίλτρο
# stopwords, αλλιώς η συγχωνευμένη μονάδα δεν αντιστοιχίζεται πουθενά
lemmas = []
for token in doc:
    for part in token.lemma_.lower().split():
        lemmas.append(part)
tokens = [t for t in lemmas
           if t not in GREEK_STOPWORDS and is_informative(t)]
```

Απόσπασμα 5.1: Η διόρθωση των σύνθετων λημμάτων (`04_nlp_preprocessing.ipynb`).

5.4 Φιλτράρισμα stopwords για ελληνικά και αγγλικά

Μια λίστα stopwords παραγόμενη από το ίδιο το σώμα κειμένων (απλώς οι 100 συχνότερες λέξεις) αξιολογήθηκε και απορρίφθηκε: λέξεις περιεχομένου ειδικές του ιδρύματος, όπως το «πανεπιστημίου», κατατάσσονται στην πρώτη τριακοντάδα κατά ακατέργαστη συχνότητα απλώς και μόνο επειδή κάθε μήνυμα προέρχεται από το ίδιο πανεπιστήμιο. Η αφαίρεσή τους αφαιρεί πραγματικό θεματικό σήμα. Η ροή χρησιμοποιεί αντ' αυτής τη γλωσσολογικά επιμελημένη ελληνική λίστα stopwords του spaCy (663 εγγραφές).

Τα αγγλικά απαίτησαν δική τους αντιμετώπιση. Το σώμα κειμένων περιέχει τρία είδη περιεχομένου σε λατινική γραφή: δομικό θόρυβο (οι ετικέτες θεμάτων [TOVIMA]/[ANNOUNCEMENTS]), τυποποιημένο κείμενο υπογραφών («University of Patras», «Department of Biology», παρόν στο 24% των μηνυμάτων) και γνήσιο αγγλικό περιεχόμενο (περιλήψεις εργασιών, προσκλήσεις συνεδρίων, τεχνικούς όρους όπως «biology» ή «semiconductor»). Δοκιμάστηκαν και απορρίφθηκαν, μετά από μέτρηση, ενδιάμεσοι σχεδιασμοί που αφαιρούσαν λατινικές μονάδες βάσει μήκους: κανένα κατώφλι μήκους δεν διαχωρίζει τα μεταγραμμένα ονόματα προσώπων από τον θόρυβο («thramboulidis» και «biochemistry» έχουν και τα δύο 12 χαρακτήρες), και η συλλήβδην αφαίρεση όλων των λατινικών μονάδων διαγράφει ακριβώς τις λέξεις περιεχομένου που μια σημασιολογική συσταδοποίηση οφείλει να ανακαλύψει. Ο τελικός σχεδιασμός είναι συμμετρικός με την ελληνική πλευρά: η αγγλική λίστα stopwords του spaCy (326 εγγραφές, μόνο λειτουργικές λέξεις) εφαρμόζεται στον επιφανειακό τύπο πριν από τη λημματοποίηση, και οι αγγλικές λέξεις περιεχομένου διατηρούνται. Το φιλτράρισμα πριν αγγίζει το κείμενο ο ελληνικός λημματοποιητής παρακάμπτει επίσης οποιαδήποτε απροσδιόριστη συμπεριφορά μιας ελληνικής υποδομής σε είσοδο λατινικής γραφής.

5.5 Κανονικοποίηση μοτίβων, θορυβώδεις μονάδες και όρια μήκους

Επιφανειακά μοτίβα με μεγάλη ποικιλομορφία αλλά ισοδύναμη σημασία αντικαθίστανται με δεσμευτικές μονάδες (placeholders) πριν από τη λημματοποίηση: ώρες ρολογιού (ΩΡΑ), ημερολογιακές ημερομηνίες και έτη (ΗΜΕΡΟΜΗΝΙΑ), ελληνικοί αριθμοί τηλεφώνου (ΤΗΛΕΦΩΝΟ), αναφορές αιθουσών (ΑΙΘΟΥΣΑ) και κωδικοί μαθημάτων (ΜΑΘΗΜΑ). Ένα φίλτρο θορύβου σε επίπεδο μονάδας αφαιρεί υπολείμματα HTML/CSS (nbsp, mso, Opt, style, width, ...), αμιγώς αριθμητικές μονάδες, μονάδες μόνο με στίξη και μονάδες ενός ή δύο χαρακτήρων.

Το στάδιο κλείνει με δύο όρια μήκους. Το ελάχιστο όριο μονάδων (min_tokens = 5, εφαρμοζόμενο μετά τη λημματοποίηση και την αφαίρεση stopwords) αφαιρεί 51 γραμμές των οποίων το περιεχόμενο περιορίζεται σε λιγότερες από πέντε πληροφοριακές μονάδες, συμπληρωματικός έλεγχος προς το δομικό φίλτρο σχεδόν κενών μηνυμάτων, που πιάνει μηνύματα μακριά σε χαρακτήρες αλλά αποτελούμενα σχεδόν εξ ολοκλήρου από stopwords. Η μέγιστη περικοπή ορίστηκε στις 1.000 μονάδες μετά από μέτρηση των υποψήφιων τιμών: στις 500 μονάδες θα περικοβόταν το 14,9% του σώματος κειμένων, και η επιθεώρηση των μακροσκελών μηνυμάτων στο όριο αυτό έδειξε ότι το αφαιρούμενο περιεχόμενο είναι ανάπτυξη του ίδιου θέματος και όχι θεματική μετατόπιση. Ένα αυστηρότερο όριο απορρίπτει σήμα χωρίς να προστατεύει τίποτα. Στις 1.000 μονάδες επηρεάζεται μόλις το 3,8% του σώματος κειμένων. Η τελική γλωσσική έξοδος είναι το tovima_nlp_ready.csv με 13.637 γραμμές.

6 Σημασιολογικές Αναπαραστάσεις Εγγράφων

6.1 Υπόβαθρο και μέτρο ομοιότητας

Με το κείμενο καθαρισμένο, η ροή περνά από τις μονάδες στη γεωμετρία: κάθε μήνυμα αναπαρίσταται ως πυκνό διάνυσμα παραγόμενο από μοντέλο ενσωματώσεων βασισμένο σε transformer [10]. Η σημασιολογική ομοιότητα δύο εγγράφων u και v μετριέται με τη συνημιτονική ομοιότητα:

$$\cos(u, v) = \frac{u \cdot v}{\|u\| \|v\|}$$

Επειδή το BGE-M3 εκπέμπει μη κανονικοποιημένα διανύσματα (μέση νόρμα ≈ 26 στο σώμα κειμένων), όλα τα διανύσματα κανονικοποιούνται κατά L2 κατά τη φόρτωση. Έπειτα η συνημιτονική ομοιότητα συμπίπτει με το εσωτερικό γινόμενο και η ευκλείδεια απόσταση γίνεται μονότονη συνάρτηση της συνημιτονικής απόστασης, ιδιότητα που αξιοποιείται αργότερα, όταν το HDBSCAN (που απαιτεί μετρικό χώρο) εκτελείται με ευκλείδεια απόσταση σε κανονικοποιημένα, μειωμένα από το UMAP δεδομένα.

6.2 Πείραμα επιλογής μοντέλου

Συγκρίθηκαν δύο τοπικά εκτελέσιμα υποψήφια μοντέλα: το qwen3-embedding:4b [13] (4,0 δισεκατομμύρια παράμετροι, έξοδος 2.560 διαστάσεων) και το BGE-M3 [6] (567 εκατομμύρια παράμετροι, 1.024 διαστάσεις). Αντί εμπιστοσύνης σε δημόσιους πίνακες κατάταξης (κανένας από τους οποίους δεν αναφέρει επιδόσεις ειδικά για τα ελληνικά), τα μοντέλα συγκρίθηκαν απευθείας στο σώμα κειμένων με έλεγχο ζευγών γνωστής αλήθειας. Ως αλήθεια αναφοράς χρησιμοποιήθηκαν τέσσερις κατηγορίες θεμάτων που είναι αδιαμφισβήτητες με απλή επιθεώρηση: παρουσιάσεις διπλωματικών/διδακτορικών (1.201 μηνύματα στο σώμα κειμένων), ανακοινώσεις COVID (117), αγγελίες πένθους (112) και τμηματικές εκλογές (129). Ελήφθησαν έξι μηνύματα ανά κατηγορία, από τα οποία σχηματίστηκαν 15 ζεύγη ίδιου θέματος και 15 ζεύγη διαφορετικού θέματος (23 μοναδικά κείμενα). Κάθε μοντέλο ενσωμάτωσε τα ίδια κείμενα, και υπολογίστηκαν δύο στατιστικές: το χάσμα (μέση ομοιότητα ίδιου θέματος μείον μέση ομοιότητα διαφορετικού θέματος, όπου μεγαλύτερο είναι καλύτερο) και η επικάλυψη (το ποσό κατά το οποίο το χειρότερο ζεύγος ίδιου θέματος βαθμολογείται κάτω από το καλύτερο ζεύγος διαφορετικού θέματος, όπου μικρότερη είναι καλύτερη, με το μηδέν να σημαίνει διαχωρίσιμες κατανομές).

Μοντέλο	Μ.Ο. ίδιου θέματος	Μ.Ο. διαφορετικού	Χάσμα	Επικάλυψη
qwen3-embedding:4b	0,630	0,500	0,130	0,179
BGE-M3	0,598	0,481	0,117	0,093

Πίνακας 6.1: Σύγκριση μοντέλων ενσωματώσεων σε 30 ζεύγη γνωστής αλήθειας.

Το qwen3 πετυχαίνει οριακά μεγαλύτερο μέσο χάσμα, αλλά το BGE-M3 υποδιπλασιάζει την επικάλυψη (0,093 έναντι 0,179). Για τη συσταδοποίηση, η επικάλυψη είναι η στατιστική με τις μεγαλύτερες συνέπειες: ένα μοντέλο του οποίου οι κατανομές ομοιότητας ίδιου και διαφορετικού θέματος διασταυρώνονται θα συγχωνεύει συστηματικά διακριτά θέματα ή θα διασπά ενιαία ακριβώς στις οριακές περιπτώσεις, ανεξαρτήτως καλού μέσου όρου. Η επιθεώρηση των χειρότερων ζευγών έδειξε ότι και τα δύο μοντέλα δυσκολεύτηκαν με τα ίδια γνησίως αμφίσημα στοιχεία (ιδίως

μια ανακοίνωση για πρωτόκολλα COVID κατά την ημέρα εκλογών, που δικαιολογημένα εκτείνεται σε δύο κατηγορίες, ένδειξη ότι ο έλεγχος μετρά πραγματική δυσκολία και όχι τεχνήματα των μοντέλων). Επιλέχθηκε το BGE-M3. Ένας πρακτικός περιορισμός ενίσχυσε την επιλογή: το μοντέλο των 4 δισεκατομμυρίων παραμέτρων υπερβαίνει τα 4 GB VRAM της διαθέσιμης κάρτας γραφικών (GTX 970) και δεν μπορεί να εκτελεστεί σε κλίμακα σε αυτό το υλικό, ενώ το BGE-M3 εκτελείται άνετα. Και τα δύο μοντέλα αξιολογήθηκαν αποκλειστικά σε CPU (παράμετρος num_gpus 0 στο Modelfile του Ollama) ώστε η σύγκριση να είναι ισότιμη.

6.3 Παραγωγή των ενσωματώσεων

Και τα 13.637 μηνύματα ενσωματώθηκαν από τη στήλη embedding_text με το BGE-M3 σε ρεβιρισμένο μέσω Ollama [20] (Modelfile: num_ctx 8192, num_batch 8192, num_gpus 0 — η παράμετρος παρτίδας έχει σημασία επειδή το BGE-M3 είναι κωδικοποιητής τύπου BERT που επεξεργάζεται ολόκληρη την είσοδό του ως μία παρτίδα, και η προεπιλεγμένη παρτίδα 2.048 μονάδων του Ollama απορρίπτει μακρύτερες εισόδους). Οι εισόδοι περικοπήθηκαν στους 7.000 χαρακτήρες, ρύθμιση που επηρεάζει 511 μηνύματα (3,7% του σώματος κειμένων). Η περικοπή είναι αποδεκτή για δύο λόγους: η επιθεώρηση κατά την προεπεξεργασία έδειξε ότι το περιεχόμενο πέρα από το σημείο αυτό στα μακροσκελή μηνύματα είναι ανάπτυξη του ίδιου θέματος (συγκεντρωτικά μηνύματα, επαναλαμβανόμενο τυποποιημένο κείμενο), και υπό mean pooling η οριακή συνεισφορά των όψιμων μονάδων στο συγκεντρωμένο διάνυσμα φθίνει. Η εκτέλεση διήρκεσε περίπου 2 ώρες και 11 λεπτά σε CPU (Intel i5-6500) και παρήγαγε πίνακα 13.637×1.024 τύπου float32 χωρίς NaN και χωρίς ολομηδενικές γραμμές, αποθηκευμένο ως πίνακα NumPy [21] ευθυγραμμισμένο γραμμή προς γραμμή με το dataframe.

7 Συσταδοποίηση

7.1 Επισκόπηση

Το στάδιο συσταδοποίησης είναι ο αναλυτικός πυρήνας της ροής: απεικονίζει τις κανονικοποιημένες ενσωματώσεις μέσω PCA (γραμμική προ-μείωση), κατόπιν UMAP (μη γραμμική μείωση σε χαμηλοδιάστατη πολλαπλότητα) και τέλος HDBSCAN (πυκνωτική συσταδοποίηση). Οι υπερπαράμετροι του συνδυασμού UMAP+HDBSCAN επιλέγονται με αναζήτηση 200 δοκιμών μέσω Optuna που μεγιστοποιεί μια αντικειμενική συνάρτηση βασισμένη στη συνοχή, ακολουθούμενη από δύο βήματα μετεπεξεργασίας: συγχώνευση σχεδόν όμοιων συστάδων ανεξάρτητη από τη σειρά επεξεργασίας, και συντηρητική επανατοποθέτηση σημείων θορύβου.

7.2 Προ-μείωση με PCA

Η PCA [14] προβάλλει τις ενσωματώσεις 1.024 διαστάσεων στις κύριες κατευθύνσεις διακύμανσης. Με τον πίνακα προβολής W περιορισμένο σε ορθοκανονικές στήλες, οι συνιστώσες μεγιστοποιούν τη διατηρούμενη διακύμανση. Το σώμα κειμένων παρουσιάζει σταδιακή φθορά της διακύμανσης χωρίς έντονο «αγκώνα» (τυπικό των αναπαραστάσεων οικογένειας BERT), με τις 300 συνιστώσες να διατηρούν το 91,0% της διακύμανσης. Η ροή χρησιμοποιεί 256 συνιστώσες, διατηρώντας το 87,7%, ως συμβιβασμό μεταξύ της δομής που διατηρείται και του κόστους κατασκευής του γράφου γειτόνων του UMAP. Η PCA λειτουργεί εδώ αμιγώς ως υπολογιστική προ-μείωση· τη μη γραμμική δομή που ενδιαφέρει τη συσταδοποίηση την ανακτά το UMAP.

7.3 UMAP

Το UMAP [3] (Uniform Manifold Approximation and Projection) κατασκευάζει έναν ασαφή γράφο πάνω στους k κοντινότερους γείτονες κάθε σημείου στον χώρο εισόδου και βρίσκει μια χαμηλοδιάστατη διάταξη της οποίας ο ασαφής γράφος ταιριάζει με τον αρχικό. Για το σημείο i με γείτονα j , η κατευθυνόμενη ισχύς συμμετοχής είναι

$$p_{j|i} = \exp\left(-\frac{\max(0, d(x_i, x_j) - \rho_i)}{\sigma_i}\right)$$

όπου ρ_i είναι η απόσταση προς τον πλησιέστερο γείτονα (εξασφαλίζοντας τοπική συνεκτικότητα) και σ_i ένα εύρος ανά σημείο επιλεγμένο ώστε το ενεργό μέγεθος γειτονιάς να ταιριάζει με το $n_neighbors$. Οι συμμετρικοποιημένες συμμετοχές $p_{ij} = p_{j|i} + p_{i|j} - p_{j|i} p_{i|j}$ ορίζουν τον ασαφή γράφο υψηλών διαστάσεων. Στον χώρο ενσωμάτωσης, η ομοιότητα σημείων y_i, y_j μοντελοποιείται ως $q_{ij} = (1 + a\|y_i - y_j\|^{2b})^{-1}$, και η διάταξη ελαχιστοποιεί τη διασταυρούμενη εντροπία ασαφών συνόλων μεταξύ των δύο γράφων:

$$CE = \sum_{ij} [p_{ij} \ln \frac{p_{ij}}{q_{ij}} + (1 - p_{ij}) \ln \frac{1 - p_{ij}}{1 - q_{ij}}]$$

Το UMAP εκτελείται με συνημιτονική μετρική πάνω στην έξοδο της PCA. Οι παράμετροι $n_neighbors$ (τοπικότητα της εκτίμησης της πολλαπλότητας), $n_components$ (διάσταση-στόχος) και min_dist (πυκνότητα διάταξης) αφήνονται στην αναζήτηση υπερπαραμέτρων αντί να καθοριστούν εκ των προτέρων.

7.4 HDBSCAN

Το HDBSCAN [4, 5] εκτελεί ιεραρχική πυκνοτική συσταδοποίηση. Η πυκνότητα αποτυπώνεται μέσω της απόστασης πυρήνα ενός σημείου, δηλαδή της απόστασης προς τον k -οστό κοντινότερο γείτονά του ($k = \text{min_samples}$), και της απόστασης αμοιβαίας προσβασιμότητας μεταξύ σημείων a και b :

$$d_{\text{mreach}}(a, b) = \max\{\text{core}_k(a), \text{core}_k(b), d(a, b)\}$$

Ένα ελάχιστο συνδετικό δένδρο πάνω στις αποστάσεις αμοιβαίας προσβασιμότητας δίνει μια ιεραρχία συνεκτικών συνιστωσών καθώς μεταβάλλεται ένα κατώφλι πυκνότητας $\lambda = 1/d$. Συστάδες μικρότερες από min_cluster_size αντιμετωπίζονται ως σημεία που εγκαταλείπουν τη μητρική τους συστάδα και όχι ως συστάδες. Η σταθερότητα κάθε συστάδας είναι το ολοκλήρωμα της συμμετοχής της στο εύρος του λ για το οποίο επιβιώνει,

$$S(C) = \sum_{x \in C} (\lambda_x - \lambda_{\text{birth}}(C))$$

και το κριτήριο excess-of-mass (EOM) επιλέγει το σύνολο των μη επικαλυπτόμενων συστάδων που μεγιστοποιεί τη συνολική σταθερότητα. Σημεία που δεν απορροφώνται ποτέ από καμία επιλεγμένη συστάδα λαμβάνουν την ετικέτα θορύβου (-1), έγκυρο αποτέλεσμα πρώτης τάξης: μεμονωμένες ανακοινώσεις χωρίς σημασιολογικούς γείτονες υπάρχουν πράγματι σε ένα αρχείο λιστών, και ο εξαναγκασμός τους σε συστάδες μόνο θα τις μόλυνε. Το HDBSCAN εκτελείται στην έξοδο του UMAP με ευκλείδεια απόσταση (έγκυρη επιλογή, αφού η είσοδος ολόκληρης της αλυσίδας είναι κανονικοποιημένη κατά $L2$).

7.5 Αντικειμενική συνάρτηση και αναζήτηση υπερπαραμέτρων

Το σήμα ποιότητας που καθοδηγεί την αναζήτηση είναι η σημασιολογική συνοχή, υπολογιζόμενη στον αρχικό (προ-PCA) χώρο ενσωματώσεων ώστε να είναι ανεξάρτητη από τη μείωση που ρυθμίζεται. Για μια επισήμανση L με συστάδες $C_1 \dots C_m$ και κεντροειδή μ_j :

$$\text{Coh}(L) = \frac{\sum_j |C_j| \cdot \text{median}_{x \in C_j} \cos(x, \mu_j)}{\sum_j |C_j|}$$

Η διάμεσος (αντί του μέσου όρου) καθιστά τη βαθμολογία κάθε συστάδας ανθεκτική σε λίγα ακραία μέλη. Η στάθμιση κατά μέγεθος εμποδίζει πολλές μικροσκοπικές σφιχτές συστάδες να κυριαρχήσουν στη βαθμολογία επιπέδου σώματος κειμένων. Το Απόσπασμα 7.1 δείχνει την υλοποίηση. Σημειώνεται ότι δέχεται τις αρχικές ενσωματώσεις 1.024 διαστάσεων, όχι τη μειωμένη αναπαράσταση που ρυθμίζεται.

```
def semantic_coherence(embeddings, labels, min_cluster_size=10):
    scores, weights = [], []
    for c in set(labels) - {-1}:
        idx = np.where(labels == c)[0]
        if len(idx) < min_cluster_size:
            continue
        vecs = embeddings[idx]
        centroid = vecs.mean(axis=0, keepdims=True)
        sims = cosine_similarity(vecs, centroid).ravel()
        scores.append(np.median(sims))
        weights.append(len(idx))
    return float(np.average(scores, weights=weights))
```

Απόσπασμα 7.1: Το μέτρο σημασιολογικής συνοχής (07_clustering.ipynb).

Η πλήρης αντικειμενική συνάρτηση είναι

$$S = Coh(L) - 1.0 \cdot \max(0, \nu - 0.15) - 0.3 \cdot \max\left(0, 1 - \frac{\tilde{m}}{50}\right)$$

όπου ν το ποσοστό θορύβου και $\tilde{m}$ το διάμεσο μέγεθος συστάδας. Και οι δύο σταθερές ποινής βαθμονομήθηκαν στα δεδομένα: πιλοτικές εκτελέσεις έδειξαν ότι με λογικές παραμέτρους προκύπτει φυσικά περίπου 15% θόρυβος, οπότε η ανοχή τοποθετείται εκεί (μια χαλαρότερη ανοχή 20% με το μισό βάρος δοκιμάστηκε και σχεδόν ποτέ δεν ενεργοποιήθηκε). Ο όρος κατακερματισμού αναμένει οι συστάδες να έχουν κατά μέσο όρο τουλάχιστον 50 μηνύματα σε σώμα 13.637 μηνυμάτων. Αποτελέσματα με λιγότερες από 5 ή περισσότερες από 200 συστάδες απορρίπτονται εξαρχής. Δύο συνιστώσες που εμφανίζονται συχνά σε τέτοιες αντικειμενικές συναρτήσεις δοκιμάστηκαν και απορρίφθηκαν. Μια εκ των προτέρων προτίμηση ν για το πλήθος συστάδων αποκλείστηκε επειδή στερείται ερείσματος για πυκνοτική συσταδοποίηση και αντιστρατεύεται ενεργά την ικανότητα του αλγορίθμου να βρει τη δομή που πράγματι υπάρχει. Η βαθμολογία σταθερότητας του HDBSCAN αποκλείστηκε ομοίως από την αντικειμενική συνάρτηση (παραμένει καταγεγραμμένη ανά δοκιμή) αφού μια σάρωση παραμέτρων έδειξε ισχυρή συσχέτισή της με την παραγωγή λιγότερων, μεγαλύτερων συστάδων (η σταθερότητα ήταν κατά μέσο όρο 0,32 σε λύσεις 7 συστάδων έναντι 0,15 σε λύσεις 21 συστάδων), οπότε η στάθμισή της θα μερολήπτει συστηματικά την αναζήτηση προς αδρές λύσεις.

Το Απόσπασμα 7.2 δείχνει τον πυρήνα βαθμολόγησης της αντικειμενικής συνάρτησης, όπως αποτιμάται σε κάθε δοκιμή.

```
n_clusters = len(set(labels) - {-1})
if n_clusters < 5 or n_clusters > 200:
    return -999.0 # άμεση απόρριψη
noise_pct = float(np.mean(labels == -1))
coherence = semantic_coherence(embeddings_orig, labels)
sizes = [np.sum(labels == c) for c in set(labels) - {-1}]
median_size = float(np.median(sizes))
noise_penalty = max(0.0, noise_pct - 0.15) * 1.0
frag_penalty = max(0.0, 1.0 - median_size / 50.0) * 0.3
score = coherence - noise_penalty - frag_penalty
```

Απόσπασμα 7.2: Αποτίμηση της αντικειμενικής συνάρτησης μέσα στη δοκιμή του Optuna (07_clustering.ipynb).

Ο χώρος αναζήτησης ήταν: $n_neighbors \in [10, 50]$, $n_components \in [5, 20]$, $min_dist \in [0, 0.1]$, $min_cluster_size \in [30, 150]$ (το ανυψωμένο κατώτατο όριο λειτουργεί ως δομικό ανάχωμα κατά του κατακερματισμού, συμπληρωματικό της ποινής στην αντικειμενική συνάρτηση), $min_samples \in [3, min_cluster_size/3]$. Ο δειγματολήπτης TPE του Optuna [7, 18] εκτέλεσε 200 δοκιμές με median pruning. Η καλύτερη δοκιμή πέτυχε βαθμολογία 0,8081 με $n_neighbors = 11$, $n_components = 13$, $min_dist = 0,0141$, $min_cluster_size = 32$, $min_samples = 4$, παράγοντας 116 συστάδες με 15,45% θόρυβο και συνοχή 0,8126.

7.6 Μετεπεξεργασία

7.6.1 Συγχώνευση σχεδόν όμοιων συστάδων

Το HDBSCAN κατά περίπτωση υπερτεμαχίζει ένα θέμα για λόγους πυκνότητας. Ζεύγη συστάδων των οποίων τα κεντροειδή υπερβαίνουν συνημιτονική ομοιότητα 0,92 συγχωνεύονται. Το κατώφλι βαθμονομήθηκε έναντι της εμπειρικής κατανομής των ανά ζεύγη ομοιοτήτων κεντροειδών: η διασυσταδική ομοιότητα συγκεντρώνεται γύρω στο 0,73, λιγότερα από δέκα ζεύγη υπερέβαιναν το 0,92 σε πιλοτική λύση, και κανένα δεν υπερέβαινε το 0,95. Το 0,92 βρίσκεται δηλαδή σε αραιή περιοχή και δεν τέμνει πυκνή ζώνη. Η συγχώνευση υπολογίζεται ως συνεκτικές συνιστώσες του γράφου με ακμές τα ζεύγη πάνω από το κατώφλι (Απόσπασμα 7.3), κατασκευή ανεξάρτητη από τη σειρά επεξεργασίας. Η προφανής άπληστη εναλλακτική (απορρόφηση, για κάθε συστάδα κατά σειρά αναγνωριστικού, κάθε αχρησιμοποίητης συστάδας πάνω από το κατώφλι) απορρίφθηκε επειδή η έξοδος της εξαρτάται από τη σειρά των αναγνωριστικών όποτε υπάρχουν τρίγωνα ομοιότητας (οι συστάδες 15/22/23 στην πιλοτική λύση σχημάτιζαν τέτοιο τρίγωνο: και οι τρεις ανά ζεύγη ομοιοτήτες υπερέβαιναν ή πλησίαζαν το κατώφλι, οπότε η έξοδος ενός άπληστου βρόχου εξαρτάται από το ποια συστάδα τυχαίνει να επεξεργαστεί πρώτη). Η συγχώνευση μείωσε τις 116 συστάδες σε 107.

```
sims = cosine_similarity(centroid_matrix) # k x k
adj = {i: set() for i in range(k)}
for i in range(k):
    for j in range(i + 1, k):
        if sims[i, j] > 0.92:
            adj[i].add(j); adj[j].add(i)
# συνεκτικές συνιστώσες μέσω BFS: κάθε αμοιβαία όμοια ομάδα
# συγχωνεύεται ως σύνολο, ανεξάρτητα από τη σειρά επεξεργασίας
visited, groups = set(), []
for start in range(k):
    if start in visited: continue
    comp, queue = [], [start]
    while queue:
        node = queue.pop()
        if node in visited: continue
        visited.add(node); comp.append(node)
        queue.extend(adj[node] - visited)
    groups.append(comp)
```

Απόσπασμα 7.3: Συγχώνευση συστάδων ανεξάρτητη από τη σειρά επεξεργασίας (07_clustering.ipynb).


7.6.2 Συντηρητική επανατοποθέτηση θορύβου

Ορισμένα σημεία που το HDBSCAN χαρακτηρίζει θόρυβο είναι οριακές περιπτώσεις υπάρχουσας συστάδας. Ένα σημείο θορύβου επανατοποθετείται στο πλησιέστερο κεντροειδές μόνο εφόσον ισχύουν και οι τρεις συνθήκες: ομοιότητα με το κεντροειδές αυτό τουλάχιστον 0,80· εσωτερική διακύμανση της συστάδας (1 – μέση ομοιότητα μέλους-κεντροειδούς) το πολύ 0,25· και το δεύτερο πλησιέστερο κεντροειδές τουλάχιστον 0,05 μακρύτερα (φραγή αμφισημίας: ένα σημείο σχεδόν ισαπέχον από δύο συστάδες βρίσκεται πράγματι ανάμεσά τους). Και τα τρία κατώφλια βαθμονομήθηκαν στα δεδομένα: οι βέλτιστες ομοιότητες των σημείων θορύβου συγκεντρώνονται πυκνά γύρω στο 0,71–0,73 και πέφτουν απότομα πάνω από το 0,80 (μόλις το 3,4% των σημείων θορύβου το υπερβαίνει). Ένα υποψήφιο κατώφλι 0,73, αντιθέτως, θα βρισκόταν στη μέση αυτού του γκρεμού, όπου μετατοπίσεις $\pm 0,02$ μεταβάλλουν το ποσοστό επανατοποθέτησης κατά δέκα ποσοστιαίες μονάδες, ενώ ένα κατώφλι διακύμανσης 0,35 θα υπερέβαινε τη μέγιστη παρατηρημένη διακύμανση συστάδας (0,2965) και δεν θα ενεργοποιούνταν ποτέ. Με τον βαθμονομημένο κανόνα, επανατοποθετήθηκαν 96 από τα 2.107 σημεία θορύβου (4,6%), σκόπιμα συντηρητική έκβαση,


συνεπής με την ερμηνεία ότι ο θόρυβος του σώματος κειμένων είναι κατά κύριο λόγο πραγματικός (μεμονωμένα μηνύματα) και δεν αποτελεί τέχνημα αυστηρών κατωφλίων πυκνότητας. Τελικό αποτέλεσμα: 107 συστάδες, 2.011 σημεία θορύβου (14,7%), διάμεσο μέγεθος συστάδας 72, μεγαλύτερη 938, μικρότερη 32.

Το περιεχόμενο του θορύβου εξετάστηκε άμεσα. Μόλις το 5% περίπου των 2.011 μηνυμάτων θορύβου ταιριάζει με ισχυρά μοτίβα θεμάτων υπαρχουσών θεματικών, και η διάμεση συνημιτονική τους ομοιότητα προς το πλησιέστερο κεντροειδές είναι 0,730, δηλαδή μέσα στη δια-συσταδική ζώνη που εντοπίστηκε κατά τη βαθμονόμηση των κατωφλίων. Η επανασυσταδοποίηση μόνο του υποσυνόλου θορύβου (ίδια ροή, `min_cluster_size` = 15) ανακτά 50 μικρές ομάδες με σταθμισμένη κατά μέγεθος συνοχή 0,799, κάτω από το 0,811 της κύριας λύσης. Οι δύο μεγαλύτερες ανακτημένες ομάδες είναι υφολογικές συναθροίσεις άσχετων μεταξύ τους κειμένων γνώμης και όχι θέματα, ενώ μια μειονότητα αποτελεί γνήσιες ήπιες θεματικές (εκδηλώσεις του τμήματος φιλοσοφίας, εκστρατείες αλληλεγγύης σε καταστροφές, εποχικές ευχές, δράσεις εξωστρέφειας), που αθροίζονται σε περίπου 300–500 μηνύματα.

Ο υπόλοιπος θόρυβος περιγράφεται επομένως καλύτερα ως ένα μέρος γνησίως μη συσταδοποιήσιμης μεμονωμένης κίνησης και ένα μέρος δευτερεύουσας ήπιας δομής που πέφτει κάτω από τα κατώφλια πυκνότητας και μεγέθους στα οποία είναι βαθμονομημένη η κύρια λύση. Πρόκειται για ιδιότητα του σώματος κειμένων: η μείωση του `min_cluster_size` αρκετά ώστε να γίνουν δεκτές οι ήπιες θεματικές κατακερματίζει την πρωτεύουσα δομή που η εργασία επικυρώνει. Το ποσοστό θορύβου που αναφέρεται παντού (14,7%) πρέπει να διαβάζεται με αυτή τη σύνθεση κατά νου.



Εικόνα 7.1: Δισδιάστατη προβολή UMAP και των 13.637 μηνυμάτων, χρωματισμένη ανά κύρια θεματική (ο θόρυβος με γκρι). Η προβολή είναι νέα προσαρμογή 2 συνιστωσών για λόγους απεικόνισης· η συσταδοποίηση έγινε στην προβολή 13 συνιστωσών (figures.ipynb).



Εικόνα 7.2: Κατανομή των μεγεθών των 107 συστάδων (διάμεσος 72, μέγιστο 938).

8 Χαρακτηρισμός Συστάδων και Θεματική Ταξινόμια

8.1 Εξαγωγή όρων με TF-IDF

Για να αξιοποιηθεί η δομή που ανακαλύφθηκε, κάθε συστάδα πρέπει να μπορεί να διαβαστεί. Χαρακτηρίζεται επομένως από τους πλέον διακριτικούς της όρους, υπολογισμένους με TF-IDF [15, 16] πάνω στη λημματοποιημένη στήλη `cleaned_text` των 11.626 επισημασμένων μηνυμάτων. Με τη διατύπωση του `scikit-learn` [12] και υπογραμμική συχνότητα όρων, το βάρος του όρου t στο έγγραφο d είναι

$$w(t, d) = (1 + \ln tf(t, d)) \cdot \left(\ln \frac{1 + N}{1 + df(t)} + 1 \right)$$

ακολουθούμενο από κανονικοποίηση L2 κάθε διανύσματος εγγράφου. Η υπογραμμική κλιμάκωση εμποδίζει ένα μεμονωμένο μήνυμα που επαναλαμβάνει μια λέξη πενήντα φορές (σύνηθες στις προωθημένες ανακοινώσεις) να κυριαρχήσει. Η εξομαλυσμένη IDF υποβαθμίζει τους όρους που είναι κοινοί σε όλο το σώμα κειμένων. Περιορισμοί λεξιλογίου: `unigrams` και `bigrams`· ένας όρος πρέπει να εμφανίζεται σε τουλάχιστον 5 μηνύματα (`min_df = 5`, ρύθμιση που εξαλείφει μεμονωμένα τεχνήματα λημματοποίησης και θραύσματα προσωπικών ονομάτων από υπογραφές) και σε έως 60% των μηνυμάτων· οι μονάδες πρέπει να έχουν τουλάχιστον 4 χαρακτήρες (οι τρίγραμμαμες μονάδες στο σώμα κειμένων είναι σχεδόν αποκλειστικά θραύσματα ή θόρυβος).

Μια βασική σχεδιαστική απόφαση αφορά το επίπεδο του εγγράφου. Η προφανής κατασκευή (συνένωση κάθε συστάδας σε ένα συγκεντρωτικό έγγραφο και εκτέλεση TF-IDF στα 107 συγκεντρωτικά) περιορίζει την IDF σε 107 δυνατές τιμές και καθιστά αδύνατη τη διάκριση ενός όρου που εμφανίζεται σταθερά στα μηνύματα μιας συστάδας από έναν όρο που εμφανίζεται πολλές φορές σε ένα μακροσκελές μήνυμα. Το TF-IDF προσαρμόζεται αντ' αυτού σε όλα τα 11.626 μηνύματα μεμονωμένα (λεξιλόγιο: 64.088 όροι), και η βαθμολογία κάθε συστάδας για έναν όρο είναι ο μέσος όρος των βαρών TF-IDF των μελών της, επιβραβεύοντας έτσι τους όρους που είναι σπάνιοι στο σώμα κειμένων και σταθεροί εντός της συστάδας, δηλαδή αυτούς που ταυτοποιούν ένα θέμα.

Της διανυσματοποίησης προηγούνται δύο κανονικοποιήσεις σε επίπεδο κειμένου. Κατ' αρχάς, μια ρητή λίστα εξαιρέσεων αφαιρείται από το ίδιο το κείμενο (όχι απλώς εκ των υστέρων από τις λίστες κορυφαίων όρων, πράγμα που θα άφηνε μολυσμένα `bigrams` όπως «`tonima` διανομη»): οι δεσμευτικές μονάδες των μοτίβων (ημερομηνια, ωρα, ...), οι δομικές ετικέτες λιστών (`tonima`, `announcements`) και το υπολειπόμενο αγγλικό τυποποιημένο κείμενο (`the`, `and`, `of`, `university`). Οι μονάδες αυτές δεν φέρουν θεματικό σήμα: οι δεσμευτικές μονάδες εμφανίζονται σχεδόν σε κάθε ανακοίνωση και οι ετικέτες σχεδόν σε κάθε θέμα εκ κατασκευής. Έπειτα, οι ελληνικοί τόνοι αφαιρούνται μέσω αποσύνθεσης Unicode NFD (αφαίρεση συνδυαζόμενων σημαδιών), ενοποιώντας τις τονισμένες/άτονες παραλλαγές λημμάτων της ίδιας λέξης (διπλωματική/διπλωματική) που ο λημματοποιητής εκπέμπει ασυνεπώς και που διαφορετικά θα διασπούσαν τις καταμετρήσεις των όρων.

8.2 Θεματική ταξινόμια

Οι 15 κορυφαίοι όροι ανά συστάδα, μαζί με δειγματοληπτημένα θέματα μηνυμάτων, στήριξαν τη χειροκίνητη απόδοση ετικέτας δύο επιπέδων σε κάθε συστάδα: μιας ειδικής θεματικής (τι είναι αυτή η συστάδα) και μιας κύριας θεματικής (μιας ευρύτερης κατηγορίας που ομαδοποιεί συγγενείς

συστάδες). Οι 107 συστάδες συμπύσσονται σε 17 κύριες θεματικές ενότητες. Η λεπτομέρεια της συσταδοποίησης αποδείχθηκε πραγματικά τμηματική: διαχωρίζει, για παράδειγμα, τέσσερα διακριτά είδη πανεπιστημιακών εκλογών (πρόεδροι τμημάτων, κοσμήτορες, ορισμοί εφορευτικών επιτροπών, εκπρόσωποι προσωπικού) και ανά τμήμα σειρές σεμιναρίων. Το χειροκίνητο βήμα τα ομαδοποιεί όπου η ανάλυση απαιτεί ευρύτερες κατηγορίες, χωρίς να καταστρέφει τη λεπτότερη δομή. Οι ονομασίες των θεματικών διατηρούνται στα αγγλικά, όπως αποδόθηκαν στα αρχεία της ανάλυσης και στα διαγράμματα, ώστε πίνακες και εικόνες να παραμένουν συνεπείς.

Κύρια θεματική	Συστάδες	Μηνύματα
Academic Events	22	3.383
Campus Life	15	1.573
University Administration	13	1.443
Elections & Governance	12	886
Research & Funding	9	942
Labour & Union Affairs	7	932
Health & COVID	6	465
Informal Discussion	5	444
Postgraduate Programmes	4	509
Innovation & Entrepreneurship	4	257
Digital Infrastructure	3	168
University Rankings & Distinctions	2	193
Continuing Education	1	80
Payroll	1	70
Gender Equality & Inclusion	1	69
International Programmes	1	33
Miscellaneous	1	179
(Θόρυβος — μη αποδοθέντα)	—	2.011

Πίνακας 8.1: Η ταξινόμια κύριων θεματικών πάνω στις 107 συστάδες.

Η χειροκίνητη επιθεώρηση σαράντα περίπου συστάδων εντόπισε ακριβώς μία γνησίως ασυνάρτητη συστάδα (συστάδα 65, 179 μηνύματα): ένα μείγμα προσκλήσεων σεμιναρίων, αλυσίδων απαντήσεων και άσχετων ανακοινώσεων με μοναδικό σταθερό γνώρισμα ένα επαναλαμβανόμενο αγγλικό μπλοκ υπογραφής, ουσιαστικά δομικό θόρυβο που επιβίωσε ως συστάδα. Της αποδίδεται η κατηγορία Miscellaneous. Το ότι μόλις μία στις 107 συστάδες είναι ασυνάρτητη αποτελεί από μόνο του ένδειξη ότι η ροή δεν κατασκευάζει τεχνητή συνοχή εκεί όπου δεν υπάρχει.

9 Επικύρωση

Η φυσική ένσταση απέναντι σε κάθε βελτιστοποίηση ενός μόνο μέτρου είναι ότι το αποτέλεσμα είναι καλό μόνο κατά το μέτρο στο οποίο ρυθμίστηκε. Το κεφάλαιο αυτό την απαντά με τρεις ανεξάρτητους ελέγχους.

9.1 Σύγκριση με μεθόδους αναφοράς

Ο k-means (MiniBatch [17], 5 αρχικοποιήσεις) και η συσσωρευτική συσταδοποίηση (σύνδεση Ward [22]) εκτελέστηκαν με το ίδιο $k = 107$ στις ίδιες μειωμένες από PCA ενσωματώσεις, και βαθμολογήθηκαν με την ταυτόσημη συνάρτηση συνοχής. Και οι δύο μέθοδοι αναφοράς αναθέτουν κάθε σημείο (χωρίς θόρυβο), οπότε η συνοχή τους είναι άμεσα συγκρίσιμη.

Η σύγκριση έχει δύο ασυμμετρίες. Η πρώτη: οι μέθοδοι αναφοράς λαμβάνουν δωρεάν το $k = 107$, την τιμή που ανακάλυψε η ίδια η ροή του HDBSCAN, ενώ στην πράξη το k μιας διαμεριστικής μεθόδου πρέπει να επιλεγεί και αυτό. Η σύγκριση αξιολογεί επομένως την ποιότητα της διαμέρισης σε αντίστοιχη λεπτομέρεια, όχι το πλήρες πρόβλημα επιλογής μοντέλου κάθε μεθόδου. Η δεύτερη: η σημασιολογική συνοχή είναι επίσης το μέγεθος που η ροή του HDBSCAN ρυθμίστηκε να μεγιστοποιεί, και υπολογίζεται στο 85,3% των μηνυμάτων που το HDBSCAN διατηρεί, ενώ οι μέθοδοι αναφοράς πρέπει να τοποθετήσουν κάθε σημείο, ακόμη και τα δυσκολότερα. Και οι δύο ασυμμετρίες ευνοούν την προτεινόμενη ροή, και γι' αυτό η σύγκριση δεν στηρίζεται στη συνοχή μόνη: το NPMI δεν βελτιστοποιήθηκε ποτέ από καμία μέθοδο, υπολογίζεται από λεξιλογικά δεδομένα που οι ενσωματώσεις δεν βλέπουν, και εμφανίζει το μεγαλύτερο περιθώριο από όλα, ενώ η ανάλυση ευαισθησίας της Ενότητας 9.3 δείχνει ότι το αποτέλεσμα δεν αποτελεί τέχνημα ρύθμισης σε εύθραυστο βέλτιστο. Η σύγκριση διαβάζεται αντίστοιχα ως ένδειξη για την ποιότητα της δομής που ανακαλύφθηκε στη δική της λεπτομέρεια, με το ποσοστό θορύβου να αναφέρεται πάντοτε δίπλα.

9.2 Λεξιλογική συνοχή NPMI

Ως εξωτερικό μέτρο, η κανονικοποιημένη σημειακή αμοιβαία πληροφορία [8] υπολογίζεται αμιγώς από τη στήλη `cleaned_text`, χωρίς καμία εμπλοκή ενσωματώσεων, άρα πλήρως ανεξάρτητη από το μέγεθος που βελτιστοποίησε η συσταδοποίηση. Για κάθε συστάδα λαμβάνονται οι δέκα όροι με την υψηλότερη ενδοσυσταδική συχνότητα εγγράφων, και για κάθε ζεύγος όρων το NPMI είναι

$$NPMI(t_i, t_j) = \frac{\ln P(t_i, t_j) - \ln P(t_i)P(t_j)}{-\ln P(t_i, t_j)}$$

με τις πιθανότητες να εκτιμώνται ως συχνότητες εγγράφων (η συνεμφάνιση μετριέται μία φορά ανά μήνυμα). Η βαθμολογία κάθε συστάδας είναι ο μέσος όρος στα 45 ζεύγη όρων της, και η βαθμολογία του σώματος κειμένων ο σταθμισμένος κατά μέγεθος μέσος όρος στις συστάδες. Το NPMI φράσσεται στο $[-1, 1]$. Οι αρνητικές τιμές είναι φυσιολογικές σε σώματα ηλεκτρονικού ταχυδρομείου (οι θεματικοί όροι τείνουν να εμφανίζονται σε διαφορετικές προτάσεις ενός μηνύματος και όχι πάντοτε μαζί), οπότε το πληροφοριακό μέγεθος είναι η κατάταξη μεταξύ των μεθόδων, όχι το πρόσημο.

Μέθοδος	Σημαιολογική συνοχή	NPMI
HDBSCAN (η παρούσα ροή)	0,8111	-0,2077
k-means (k = 107)	0,8009	-0,2979
Συσσωρευτική Ward (k = 107)	0,8005	-0,2893

Πίνακας 9.1: Σύγκριση με τις μεθόδους αναφοράς και στα δύο μέτρα.

Το HDBSCAN υπερτερεί και των δύο μεθόδων αναφοράς και στα δύο μέτρα. Το περιθώριο συνοχής είναι μέτριο (+0,010), κάτι αναμενόμενο αφού οι διαμεριστικές μέθοδοι με το σωστό k είναι ισχυρές, αλλά το περιθώριο NPMI είναι ουσιαστικό (+0,090 έναντι του k-means, +0,082 έναντι της Ward) και συνιστά την ισχυρότερη ένδειξη, καθώς υπολογίζεται από δεδομένα που η βελτιστοποίηση δεν είδε ποτέ. Το HDBSCAN παρέχει επιπλέον ετικέτα θορύβου για το 14,7% των μηνυμάτων που πράγματι δεν συσταδοποιούνται με τίποτα, δυνατότητα που οι διαμεριστικές μέθοδοι στερούνται εκ κατασκευής.

9.3 Ανάλυση ευαισθησίας

Καθεμία από τις τέσσερις διακριτές υπερπαραμέτρους της βέλτιστης λύσης διαταράχθηκε κατά $\pm 20\%$ μεμονωμένα (οκτώ διαμορφώσεις) και ολόκληρη η ροή UMAP+HDBSCAN επανεκτελέστηκε. Αν το βέλτιστο του Ortuna ήταν στενή αιχμή, οι μικρές διαταραχές θα κατέρρεαν την ποιότητα της λύσης.

Διαταραχή	Συστάδες	Θόρυβος %	Συνοχή
βάση (βέλτιστες παράμετροι)	116	15,5	0,8126
n_neighbors -20% (11→9)	132	19,3	0,8163
n_neighbors +20% (11→13)	123	17,3	0,8148
n_components -20% (13→10)	129	17,4	0,8152
n_components +20% (13→16)	128	18,5	0,8169
min_cluster_size -20% (32→26)	154	18,4	0,8189
min_cluster_size +20% (32→38)	98	18,0	0,8102
min_samples -20% (4→3)	128	19,3	0,8159
min_samples +20% (4→5)	118	17,2	0,8150

Πίνακας 9.2: Ευαισθησία της λύσης σε διαταραχές υπερπαραμέτρων $\pm 20\%$.


Η συνοχή παραμένει εντός του [0,8102, 0,8189] σε όλες τις διαταραχές (τυπική απόκλιση 0,0024, μέγιστη απόκλιση 0,0063 από τη βάση). Το πλήθος συστάδων μεταβάλλεται (98–154), αφού το min_cluster_size ελέγχει άμεσα τη λεπτομέρεια, αλλά η σηματολογική ποιότητα της δομής που βρίσκεται είναι ουσιαστικά επίπεδη: το βέλτιστο βρίσκεται σε ευρύ οροπέδιο, και η δομή της συσταδοποίησης αποτελεί ιδιότητα των δεδομένων και όχι μιας εύθραυστης ρύθμισης παραμέτρων.

10 Διαχρονική Ανάλυση

Με κάθε μήνυμα να φέρει πλέον επικυρωμένη θεματική ετικέτα, το αρχείο γίνεται διαχρονική καταγραφή του τι επικοινωνούσε ένα μεγάλο ελληνικό πανεπιστήμιο, και πότε. Το κεφάλαιο αυτό αναλύει τη θεματική συχνότητα για την περίοδο 2018–2023 (10_temporal_analysis.ipynb). Μία επιφύλαξη κάλυψης ισχύει σε όλο το κεφάλαιο: τα έτη 2018–2022 είναι πλήρη ημερολογιακά έτη, ενώ το 2023 καλύπτει μόνο Ιανουάριο–Ιούλιο. Όλες οι συγκρίσεις μεταξύ ετών χρησιμοποιούν επομένως μερίδια της ετήσιας κίνησης (μέτρο σύνθεσης που δεν επηρεάζεται από συντομότερο έτος) ή επισημαίνουν ρητά το 2023 ως ελλιπές (σήμανση * στα διαγράμματα).

10.1 Συνολική κίνηση των λιστών


Η συνολική κίνηση είναι αξιοσημείωτα σταθερή στα έξι έτη: 2.248 μηνύματα το 2018, 2.625 το 2019, 2.437 το 2020, 2.440 το 2021, 2.545 το 2022, και 1.342 στους επτά μήνες του 2023 (μηνιαίος ρυθμός 191,7, εντός του εύρους των πλήρων ετών). Η πανδημία δεν άφησε ορατό ίχνος στον όγκο: η λίστα ούτε εκτοξεύθηκε ούτε κατέρρευσε το 2020–2021. Η ενδιαφέρουσα δυναμική βρίσκεται επομένως εξ ολοκλήρου στη σύνθεση, στο περί τίνος ήταν η κίνηση, και όχι στην ποσότητα.



Εικόνα 10.1: Μηνύματα ανά έτος (αριστερά· το 2023 ελλιπές, με διαγράμμιση) και μέσος όρος μηνυμάτων ανά μήνα (δεξιά).

10.2 Θεματική σύνθεση ανά έτος

Η Εικόνα 10.2 παρακολουθεί το μερίδιο της ετήσιας κίνησης για τις οκτώ μεγαλύτερες κύριες θεματικές. Η Academic Events παραμένει η κυρίαρχη κατηγορία σε όλη την περίοδο (20,8–30,3% της κίνησης), με ορατή κάμψη το 2020 (τη χρονιά που οι διά ζώσης παρουσιάσεις και τα σεμινάρια διαταράχθηκαν) και πλήρη ανάκαμψη έως το 2021. Η University Administration κορυφώνεται το 2019–2020 (13,4% και 12,6%) πριν υποχωρήσει κάτω από 8% έως το 2023, ενώ η Campus Life ακολουθεί την αντίστροφη πορεία, με κάμψη στα χρόνια της πανδημίας (9,3% το 2021) και ανάκαμψη στη συνέχεια. Και οι δύο πορείες είναι συμβατές με μια πανεπιστημιούπολη που άδειασε και μετά ξαναγέμισε.




Εικόνα 10.2: Μερίδιο κάθε κύριας θεματικής στην κίνηση των λιστών ανά έτος, για τις οκτώ μεγαλύτερες θεματικές (* 2023: Ιαν–Ιούλ).

Η σύγκριση του πρώτου και του τελευταίου πλήρους έτους (2018 έναντι 2022) ποσοτικοποιεί τις δομικές μετατοπίσεις. Τα μεγαλύτερα κέρδη μεριδίου είχαν οι Labour & Union Affairs (+3,37 ποσοστιαίες μονάδες), Health & COVID (+2,82 π.μ.), Gender Equality & Inclusion (+1,53 π.μ., αναδυόμενη ουσιαστικά από το μηδέν, καθώς η κίνηση της αρμόδιας επιτροπής ξεκινά μόλις το 2021) και University Rankings & Distinctions (+1,48 π.μ.). Τις μεγαλύτερες απώλειες είχαν οι Research & Funding (−3,21 π.μ.), Academic Events (−2,99 π.μ.) και Campus Life (−2,62 π.μ.). Εδώ διαβάζονται δύο θεσμικές εξελίξεις: η όξυνση των εργασιακών διεκδικήσεων και της συνδικαλιστικής κινητοποίησης στα ελληνικά πανεπιστήμια στην περίοδο αυτή, και η εμφάνιση εντελώς νέων θεσμικών θεμάτων (επιτροπές ισότητας των φύλων, διεθνείς κατατάξεις) που το 2018 δεν είχαν καμία παρουσία στις λίστες.

10.3 Η πανδημία ως φυσικό πείραμα


Η θεματική Health & COVID προσφέρει την πιο καθαρή απόδειξη ότι οι ανεπίβλεπτες συστάδες παρακολουθούν πραγματικά γεγονότα. Η θεματική σχεδόν δεν υπάρχει πριν από το 2020 (30 μηνύματα σε όλο το 2019, κυρίως ανακοινώσεις ρουτίνας δημόσιας υγείας) και εκτινάσσεται στα 133 μηνύματα το 2020, με μεγαλύτερο μεμονωμένο μήνα τον Μάρτιο του 2020 (42 μηνύματα), ακριβώς τον μήνα που έκλεισαν τα ελληνικά πανεπιστήμια. Στη συνέχεια η θεματική δεν εξαφανίζεται αλλά φθίνει αργά (103 μηνύματα το 2021, 108 το 2022), καθώς τα πρωτόκολλα ελέγχων, οι εγκύκλιοι τηλεργασίας και οι αναφορές κρουσμάτων έγιναν θεσμική ρουτίνα. Η συσταδοποίηση δεν έλαβε ποτέ καμία χρονική πληροφορία. Το γεγονός ότι απομονώνει μια θεματική της οποίας η χρονοσειρά αναπαράγει την έναρξη και την ομαλοποίηση της πανδημίας αποτελεί ανεξάρτητη ποιοτική ένδειξη για την εγκυρότητα της δομής που ανακαλύφθηκε.



Εικόνα 10.3: Θεματική Health & COVID, μηνιαίος όγκος. Η αιχμή του Μαρτίου 2020 συμπίπτει με το κλείσιμο των ελληνικών πανεπιστημίων.

10.4 Θεσμικοί εκλογικοί κύκλοι


Η θεματική Elections & Governance εμφανίζει την περιοδική υπογραφή της θεσμικής ζωής. Οι τρεις μεγαλύτεροι μήνες σε ολόκληρο το αρχείο είναι ο Ιούλιος 2020 (126 μηνύματα: οι πρυτανικές εκλογές, των οποίων οι προεκλογικές ανακοινώσεις, τα προγράμματα υποψηφίων και οι ειδοποιήσεις εφορευτικών επιτροπών κυριάρχησαν στη λίστα εκείνον τον μήνα), ο Ιούνιος 2022 (96 μηνύματα) και ο Νοέμβριος 2019 (51 μηνύματα), με επαναλαμβανόμενη συγκέντρωση κάθε Ιούνιο, που αντιστοιχεί στο θεσμοθετημένο παράθυρο του τέλους του ακαδημαϊκού έτους για τις εκλογές προέδρων τμημάτων και κοσμητόρων. Το ετήσιο μερίδιο της θεματικής ταλαντώνεται αντίστοιχα (8,9% στη χρονιά των πρυτανικών εκλογών 2020 έναντι 5,0% το 2021) αντί να ακολουθεί τάση.



Εικόνα 10.4: Θεματική Elections & Governance, μηνιαίος όγκος. Η κορυφή του Ιουλίου 2020 είναι οι πρυτανικές εκλογές.

10.5 Ακαδημαϊκή εποχικότητα

Συναθροίζοντας όλα τα έτη, το μερίδιο της θεματικής Academic Events στη μηνιαία κίνηση ακολουθεί το ημερολόγιο των παρουσιάσεων: κορυφώνεται στους μήνες γύρω από τις εξεταστικές (με μέγιστο τον Ιούλιο, όταν οι παρουσιάσεις μεταπτυχιακών και διδακτορικών συγκεντρώνονται πριν από τη θερινή διακοπή) και καταρρέει τον Αύγουστο, όταν το πανεπιστήμιο ουσιαστικά κλείνει. Ο ρυθμός αυτός λειτουργεί ως χρήσιμος έλεγχος λογικότητας σε λεπτότερη κλίμακα από την ετήσια ανάλυση: οι ετικέτες αναπαράγουν όχι μόνο τις πολυετείς θεσμικές μετατοπίσεις αλλά και τον ενδοετήσιο ακαδημαϊκό κύκλο.



Εικόνα 10.5: Η Academic Events ως μερίδιο της μηνιαίας κίνησης, με συνάθροιση όλων των ετών.

11 Συμπεράσματα, Περιορισμοί και Μελλοντικά Βήματα

11.1 Περιορισμοί

Οι περιορισμοί που ακολουθούν έχουν ποσοτικοποιηθεί όπου αυτό ήταν εφικτό. Η αφαίρεση αποφωνήσεων ανταλλάσσει ανάκληση με ακρίβεια (κάλυψη 4,7%) και μπορεί να περικόψει λίγες λέξεις στο σπάνιο μήνυμα που ευχαριστεί ουσιαστικά κάποιον και συγχρόνως κλείνει τυπικά κοντά στο τέλος του. Η αφαίρεση διευθύνσεων URL αφήνει θραύσματα στο 0,9% των μηνυμάτων, μια μακριά ουρά μεμονωμένα κακοσχηματισμένων διευθύνσεων. Η περικοπή της εισόδου των ενσωματώσεων αγγίζει το 3,7% των μηνυμάτων, με το περικομμένο υλικό επαληθευμένο με επιθεώρηση ως ανάπτυξη του ίδιου θέματος. Η προσέγγιση των αγγλικών stopwords διατηρεί εκ σχεδιασμού τις αγγλικές λέξεις περιεχομένου, οπότε μεταγραμμένα ονόματα προσώπων από μπλοκ υπογραφών μπορούν να εμφανιστούν στους όρους TF-IDF (ελέγχθηκαν μέσω `min_df = 5`, αλλά μία συστάδα, η 65, παραμένει συγκροτημένη κυρίως από επαναλαμβανόμενη υπογραφή). Τα δεδομένα του 2023 καλύπτουν μόνο Ιανουάριο–Ιούλιο, οπότε κάθε σύγκριση συχνοτήτων μεταξύ ετών οφείλει να επισημαίνει το έτος αυτό. Το UMAP εκτελέστηκε με σταθερό seed. Η ανάλυση ευαισθησίας καλύπτει την ανθεκτικότητα στις υπερπαραμέτρους, όχι τη διακύμανση του seed. Τέλος, οι τιμές NPMI αναφέρονται μόνο για την κατάταξη των μεθόδων. Το απόλυτο (αρνητικό) επίπεδό τους αντανakλά το παράθυρο συνεμφάνισης σε επίπεδο εγγράφου και όχι αποτυχία της συσταδοποίησης.

Μία ασυνέπεια ποιότητας δεδομένων πρέπει να καταγραφεί ρητά: η κανονικοποίηση Unicode. Ο scraper εφάρμοσε κανονικοποίηση NFKD στα πεδία κεφαλίδας αλλά όχι στα σώματα των μηνυμάτων, οπότε περίπου το 80% των τιμών Subject (και συνεπώς τα προερχόμενα από το θέμα ανοίγματα των `embedding_text` και `cleaned_text`) φέρουν αποσυντεθειμένους (NFD) ελληνικούς τόνους, ενώ τα σώματα είναι συντεθειμένα (NFC). Η επίδραση εκτιμήθηκε συγκεκριμένα. Το στάδιο TF-IDF είναι εκ κατασκευής ανεπηρέαστο, αφού η αφαίρεση τόνων του λειτουργεί μέσω αποσύνθεσης NFD και ενοποιεί αμφότερες τις μορφές· το NPMI επηρεάζεται ελαφρά, αλλά πανομοιότυπα και για τις τρεις συγκρινόμενες μεθόδους, αφήνοντας άθικτη την κατάταξη της επικύρωσης· και ο τεμαχιστής SentencePiece του μοντέλου ενσωματώσεων εφαρμόζει τη δική του εσωτερική κανονικοποίηση Unicode, οπότε τα διανύσματα, και άρα η συσταδοποίηση, είναι πολύ απίθανο να επηρεάζονται. Οι υπολειπόμενες συνέπειες είναι μια ελαφρά διάσπαση τύπων στη `cleaned_text` και υποκαταμέτρηση σε κάθε τονο-ευαίσθητη αναζήτηση μοτίβων στα θέματα. Η καθαρή αποκατάσταση, μία ενιαία κανονικοποίηση NFC σε όλα τα πεδία κειμένου κατά τον δομικό καθαρισμό ακολουθούμενη από επανεκτέλεση της λεξιλογικής γραμμής, καταγράφεται ως εργασία συντήρησης, καθώς δεν απειλεί κανένα από τα αναφερόμενα συμπεράσματα.

11.2 Συμπεράσματα

Η ροή οργανώνει 13.637 μηνύματα από το αρχείο των λιστών του Πανεπιστημίου Πατρών σε 107 σημασιολογικά συνεκτικές συστάδες ομαδοποιημένες σε 17 κύριες θεματικές ενότητες, με το 14,7% των μηνυμάτων να χαρακτηρίζεται τεκμηριωμένα ως μη συσταδοποιήσιμες μεμονωμένες ανακοινώσεις. Το αποτέλεσμα υπερτερεί των μεθόδων αναφοράς k-means και συσσωρευτικής συσταδοποίησης τόσο σε ένα εσωτερικό μέτρο (συνοχή ενσωματώσεων, 0,8111 έναντι 0,801) όσο και σε ένα εξωτερικό, ανεξάρτητο από τις ενσωματώσεις μέτρο (NPMI, -0,208 έναντι -0,29). Παραμένει επίσης σταθερό υπό διαταραχές $\pm 20\%$ κάθε υπερπαραμέτρου (τυπική απόκλιση συνοχής 0,0024). Εφαρμοσμένες διαχρονικά, οι ετικέτες μετατρέπουν το αρχείο σε αναγνώσιμη θεσμική

καταγραφή: η έναρξη της πανδημίας εμφανίζεται ως αιχμή του Μαρτίου 2020 σε θεματική που το 2019 σχεδόν δεν υπήρχε, οι πρυτανικές εκλογές κυριαρχούν τον Ιούλιο του 2020, η εργασιακή θεματολογία κερδίζει 3,4 ποσοστιαίες μονάδες μεριδίου μεταξύ 2018 και 2022, και η επικοινωνία για την ισότητα των φύλων αναδύεται από το μηδέν, χωρίς η συσταδοποίηση να έχει λάβει καμία χρονική πληροφορία.

Πέρα από το κεντρικό αποτέλεσμα, η μεθοδολογική συνεισφορά της εργασίας έγκειται στην πειθαρχία που εφαρμόστηκε σε κάθε στάδιο: τα μοτίβα καθαρισμού κειμένου ελέγχθηκαν ως προς την κάλυψή τους (η ανίχνευση προσφωνήσεων ανεβαίνει από 6,5% σε 16,6% των μηνυμάτων μόλις καλυφθούν όλοι οι κλιτοί τύποι· ένα ελάττωμα του λημματοποιητή που διέρρηξε το 6,75% των μονάδων ως αφιλτράριστα stopwords περιορίστηκε στο 0,012%)· υποψήφιες συνιστώσες της αντικειμενικής συνάρτησης αποκλείστηκαν μόνο αφού αποδείχθηκε η μεροληψία τους· και κάθε κατώφλι της μετεπεξεργασίας (ομοιότητα συγχώνευσης 0,92, ομοιότητα επανατοποθέτησης 0,80, όριο διακύμανσης 0,25) τοποθετήθηκε εκεί όπου η αντίστοιχη εμπειρική κατανομή είναι αραιή.

11.3 Μελλοντικά βήματα

Η εργασία αφήνει ανοιχτές αρκετές φυσικές προεκτάσεις. Η ενιαία κανονικοποίηση NFC όλων των πεδίων κειμένου κατά τον δομικό καθαρισμό και η επανεκτέλεση της λεξιλογικής γραμμής θα εξαλείψουν την ασυνέπεια Unicode της Ενότητας 11.1. Μια μελέτη διακύμανσης του seed του UMAP (πολλαπλές εκτελέσεις με διαφορετικούς σπόρους και μέτρηση της συμφωνίας των διαμερίσεων) θα συμπλήρωνε την ανάλυση ευαισθησίας στις υπερπαραμέτρους. Η ροή μπορεί επίσης να εφαρμοστεί σε πρόσθετες λίστες και μεταγενέστερες περιόδους του ίδιου αρχείου, ώστε η διαχρονική εικόνα να επεκταθεί και να ελεγχθεί η μεταφερσιμότητα των βαθμονομημένων κατωφλίων σε νέο υλικό. Ο χειροκίνητος χαρακτηρισμός των συστάδων μπορεί να υποβοηθηθεί από αυτόματη παραγωγή περιγραφικών τίτλων πάνω στους όρους TF-IDF και σε δειγματοληπτημένα θέματα, με τον αναλυτή να διατηρεί τον τελικό έλεγχο. Τέλος, το βαθμονομημένο πλαίσιο αξιολόγησης (συνοχή, NPMI, ανάλυση ευαισθησίας) μπορεί να επαναχρησιμοποιηθεί αυτούσιο για τη σύγκριση νεότερων πολυγλωσσικών μοντέλων ενσωματώσεων στο ίδιο σώμα κειμένων, καθώς αυτά καθίστανται διαθέσιμα.

Βιβλιογραφία

- [1] Blei, D. M., Ng, A. Y., Jordan, M. I. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993–1022.
- [2] Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. *arXiv:2203.05794*.
- [3] McInnes, L., Healy, J., Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. *arXiv:1802.03426*.
- [4] Campello, R. J. G. B., Moulavi, D., Sander, J. (2013). Density-Based Clustering Based on Hierarchical Density Estimates. *Advances in Knowledge Discovery and Data Mining (PAKDD 2013)*, 160–172.
- [5] McInnes, L., Healy, J., Astels, S. (2017). hdbscan: Hierarchical density based clustering. *Journal of Open Source Software*, 2(11), 205.
- [6] Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., Liu, Z. (2024). BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. *arXiv:2402.03216*.
- [7] Akiba, T., Sano, S., Yanase, T., Ohta, T., Koyama, M. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2623–2631.
- [8] Bouma, G. (2009). Normalized (Pointwise) Mutual Information in Collocation Extraction. *Proceedings of GSCL*, 31–40.
- [9] Honnibal, M., Montani, I., Van Landeghem, S., Boyd, A. (2020). spaCy: Industrial-strength Natural Language Processing in Python. *Zenodo*.
- [10] Reimers, N., Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of EMNLP-IJCNLP 2019*, 3982–3992.
- [11] Angelov, D. (2020). Top2Vec: Distributed Representations of Topics. *arXiv:2008.09470*.
- [12] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [13] Zhang, Y., Li, M., Long, D., et al. (2025). Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models. *arXiv:2506.05176*.
- [14] Jolliffe, I. T., Cadima, J. (2016). Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A*, 374(2065), 20150202.
- [15] Spärck Jones, K. (1972). A statistical interpretation of term specificity and its application in retrieval. *Journal of Documentation*, 28(1), 11–21.
- [16] Salton, G., Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513–523.
- [17] Sculley, D. (2010). Web-scale k-means clustering. *Proceedings of the 19th International Conference on World Wide Web*, 1177–1178.
- [18] Bergstra, J., Bardenet, R., Bengio, Y., Kégl, B. (2011). Algorithms for Hyper-Parameter Optimization. *Advances in Neural Information Processing Systems*, 24.

- [19] Richardson, L. (2023). Beautiful Soup (Version 4) [Λογισμικό]. <https://www.crummy.com/software/BeautifulSoup/>
- [20] Ollama (2024). Ollama: Run language models locally [Λογισμικό]. <https://ollama.com>
- [21] Harris, C. R., et al. (2020). Array programming with NumPy. *Nature*, 585, 357–362.
- [22] Ward, J. H. (1963). Hierarchical Grouping to Optimize an Objective Function. *Journal of the American Statistical Association*, 58(301), 236–244.
- [23] Devlin, J., Chang, M.-W., Lee, K., Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT 2019*, 4171–4186.
- [24] Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30.
- [25] Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT Press.
- [26] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

Παράρτημα Α: Κατάλογος Συστάδων

Ο πλήρης κατάλογος των 107 συστάδων: αναγνωριστικό, μέγεθος σε μηνύματα, αποδοθείσα κύρια και ειδική θεματική. Οι κορυφαίοι διακριτικοί όροι κάθε συστάδας διατίθενται στο συνοδευτικό αρχείο `cluster_top_terms.csv`. Δείγματα θεμάτων ανά συστάδα περιλαμβάνονται στο `08_tfidf_labeling.ipynb`.

ID	Μέγεθος	Κύρια θεματική	Ειδική θεματική
26	938	Academic Events	Master's Thesis Presentations
17	819	Academic Events	PhD Defense Announcements
23	390	Campus Life	Condolence Announcements
74	329	Academic Events	Department Seminars – Chemical Engineering
40	324	Postgraduate Programmes	MSc Programme Calls & Admissions
97	308	Labour & Union Affairs	Strike Actions & Labour Mobilizations
63	264	University Administration	Rector's Office Press Releases
20	256	Research & Funding	Research Grants Administration (ELKE / MODY)
100	254	University Administration	Senate Decisions & University Restructuring Debates
55	248	Elections & Governance	Departmental President & Vice-President Elections
86	229	Labour & Union Affairs	Faculty Union (ΠΟΣΔΕΠ) Announcements
105	222	Informal Discussion	General Discussion & Opinion Posts
98	184	Labour & Union Affairs	University Policy Debates & Open Letters
56	179	Campus Life	Campus Utilities Interruptions (Power / Water)
65	179	Miscellaneous	Mixed / Unclassified
71	161	Research & Funding	ELIDEK Research Funding Calls
13	154	University Administration	Administrative Circulars – Directorates
1	151	University Administration	Procurement & Public Contracts
99	146	Elections & Governance	Rector Elections
41	145	Research & Funding	Research & Academic Job Openings
96	144	Academic Events	University Milestone & Honorary Events
57	139	Health & COVID	Medical & Public Health Events
30	131	University Rankings & Distinctions	Faculty & Alumni Distinctions & Awards
82	128	Research & Funding	Conference Calls for Papers (CFPs)
93	128	University Administration	COVID-19 Institutional Decisions & Gov Circulars
66	125	Campus Life	Holiday Greetings
22	119	Campus Life	Lost & Found
68	117	Health & COVID	COVID-19 Institutional Announcements
42	109	Campus Life	University Sports & Gymnasium
61	101	Academic Events	Department Seminars – Life Sciences & Informatics
48	100	Campus Life	University Theatre Performances

ID	Μέγεθος	Κύρια θεματική	Ειδική θεματική
2	99	University Administration	Procurement Notices (Diakirixi)
15	99	Campus Life	Library News & Services
92	97	Academic Events	Book Presentations
62	93	Academic Events	Honorary Doctorate Ceremonies
18	92	Academic Events	Master's Thesis Presentations – Mechanical & Aerospace Engineering
73	91	Campus Life	Social Welfare Services
52	90	Academic Events	Department Seminars – Physics & Atmospheric Sciences
10	89	Postgraduate Programmes	Academic Positions – Medical (PhD Scholar)
106	87	Labour & Union Affairs	Higher Education Policy & Legislation Debates
76	83	Innovation & Entrepreneurship	Student Robotics & Technology Teams
77	82	Innovation & Entrepreneurship	Research Collaboration Projects & Partnerships
5	81	University Administration	Procurement – Lab & Scientific Equipment
53	80	Academic Events	Department Seminars – Economics & Business
64	80	Continuing Education	Lifelong Learning Centre (KEDIVIM) Programmes
103	78	Informal Discussion	Political & Social Commentary
104	77	Informal Discussion	Far-Right / Extreme Posts
29	76	University Administration	Senate Official Documents
35	76	Campus Life	University Chapel Monthly Service Schedules
14	75	Health & COVID	COVID-19 Public Health Circulars
31	75	Elections & Governance	EDIP / ETEP Staff Representative Elections
8	73	Academic Events	Master's Thesis Presentations – Philology
59	73	Digital Infrastructure	IT Services & Network Interruptions
88	72	Academic Events	Department Seminars – Modern Greek & Comparative Philology
16	70	Payroll	Payroll Announcements
32	69	Gender Equality & Inclusion	Gender Equality Committee Events & Announcements
47	69	Elections & Governance	Dean (Κοσμήτορας) Elections
3	66	Health & COVID	COVID-19 Rapid Testing on Campus
11	66	Campus Life	Liquid Nitrogen Distribution
67	66	Research & Funding	Horizon Europe & Marie Curie Funding Calls
75	65	Academic Events	Department Seminars – Biochemistry
46	62	University Rankings & Distinctions	World University Rankings
51	62	Digital Infrastructure	Digital Certificates & Misc IT Services
44	61	Elections & Governance	Dean Electoral Process & Committee Appointments
83	60	Research & Funding	International Bilateral Research Cooperation
24	59	Academic Events	Master's Thesis Presentations – ENT / Medical
70	59	Innovation & Entrepreneurship	Innovation Hub & Entrepreneurship Events (PatrasIQ)

ID	Μέγεθος	Κύρια θεματική	Ειδική θεματική
0	58	Postgraduate Programmes	MSc Programme – Food Business Management
19	57	University Administration	Financial Services & Budget Administration
78	55	Campus Life	Music Events & Concerts
94	54	Elections & Governance	School Laboratory Director Elections
33	53	University Administration	Official Acts & Organ Compositions (Diavgeia)
49	53	Campus Life	University Radio Station – Volunteering & Events
36	52	Academic Events	Thesis & PhD Defenses – Medical Chemistry
21	49	University Administration	Printer Consumables & IT Supplies
80	49	Research & Funding	National R&I Funding (Ερευνώ-Καινοτομώ)
90	46	Labour & Union Affairs	Administrative Staff Union (SYLDIPRO) Announcements
27	45	Research & Funding	University Scholarship Programmes (Mentzéloopoulos)
43	45	Labour & Union Affairs	Staff Association Assemblies & Social Events
7	44	Academic Events	Department Seminars – Architecture
85	44	Elections & Governance	Administrative Staff Union Elections
87	44	Academic Events	Department Seminars – Theatre Studies
60	43	Academic Events	Department Seminars – Biological Sciences
6	42	Academic Events	@UP University Magazine
34	42	Campus Life	University Chapel Services
50	42	Elections & Governance	Departmental President Elections (Smaller Depts)
4	41	Academic Events	Master's Thesis Presentations – Rehabilitation Sciences
54	40	Elections & Governance	Central Electoral Committee Appointments
69	39	University Administration	Campus Security & Emergency Contacts
12	38	University Administration	Staff Evaluation & HR Circulars
39	38	Postgraduate Programmes	MSc Programme – Computer Engineering
89	37	Elections & Governance	Administrative Staff Union General Assemblies
91	37	Campus Life	Magnaura Greek Culture Lecture Series
25	36	Health & COVID	Blood Donation Drives
38	36	Elections & Governance	Science Museum Director Elections
102	35	Informal Discussion	Student Election Season Commentary
101	34	Elections & Governance	Faculty Union (ΠΟΣΔΕΠ / ΔΗΠΑΚ) Elections
28	33	Academic Events	Master's Thesis Presentations – Environmental & Geosciences
37	33	International Programmes	Erasmus+ Staff Mobility
58	33	Digital Infrastructure	eClass & Exams Platform Announcements
84	33	Innovation & Entrepreneurship	Innovation & Entrepreneurship Competitions
95	33	Labour & Union Affairs	Postgraduate & PhD Candidate Labour Issues
9	32	Health & COVID	COVID-19 Vulnerable Groups & Telework

ID	Μέγεθος	Κύρια θεματική	Ειδική θεματική
45	32	Academic Events	Medical Chemistry Conference
72	32	Campus Life	University Radio Station (UPFM)
79	32	Informal Discussion	Personal Election Campaign & Political Opinion
81	32	Research & Funding	Special Issue Journal Calls

Πίνακας Α.1: Οι 107 συστάδες της τελικής λύσης.