

Ανεπίβλεπτη ανακάλυψη θεμάτων σε πανεπιστημιακά emails

Το ιστορικό αρχείο tonima του Πανεπιστημίου Πατρών

Δημήτριος Περδικούρης
Επιβλέπων: Νικόλαος Αβούρης

Πανεπιστήμιο Πατρών
Οκτώβριος 2026

Κίνητρο και ερευνητικό ερώτημα

Proof of concept για μελλοντική υπηρεσία του Πανεπιστημίου

Η ανάγκη


Θεματική οργάνωση μεγάλου αρχείου
emails
Χωρίς προκαθορισμένες ετικέτες

Η μελλοντική υπηρεσία

Σημασιολογική αναζήτηση
Θεματική πλοήγηση στο αρχείο
Παρακολούθηση ανακοινώσεων

Ερευνητικό ερώτημα: ανεπίβλεπτη ανακάλυψη συνεκτικών και ερμηνεύσιμων θεμάτων

Δεδομένα και χρονική κάλυψη



13.637


τελικά μηνύματα

14.277

στην αρχική συλλογή

2018-2022: πλήρη έτη. 2023*: Ιανουάριος-Ιούλιος

Συνολική ροή επεξεργασίας



Ημερομηνία
μόνο
στη χρονική
ανάλυση

Δύο αναπαραστάσεις του κειμένου

embedding_text

Φυσικό κείμενο με διατήρηση
συμφραζομένων

Είσοδος στο BGE-M3

cleaned_text

Λημματοποίηση και αφαίρεση stopwords

Είσοδος σε TF-IDF και NPMI

Καθαρισμός δομικού θορύβου

Αφαίρεση ετικετών HTML
Φιλτράρισμα υπολειμμάτων HTML/CSS

Αφαίρεση URL και γραμμών παράθεσης
Συντηρητικός καθαρισμός υπογραφών

Καθαρισμός με διατήρηση του ουσιαστικού περιεχομένου των μηνυμάτων

Σημασιολογικές ενσωματώσεις BGE-M3

Μοντέλο	Χάσμα ομοιότητας	Επικάλυψη
Qwen3-Embedding-4B	0,130	0,179
BGE-M3	0,117	0,093

1.024 διαστάσεις ανά μήνυμα

13.637 διανύσματα μέσω Ollama σε CPU
Χρόνος παραγωγής περίπου 2 ώρες και 11 λεπτά

Έλεγχος 30 ζευγών γνωστής θεματικής σχέσης. Μικρό δείγμα επιλογής μοντέλου

Συσταδοποίηση και επιλογή παραμέτρων

PCA

1.024 σε 256 διαστάσεις
87,7% διακύμανσης

UMAP

256 σε 13 διαστάσεις
Μετρική cosine

HDBSCAN

Ομάδες πυκνότητας
Μετρική Euclidean

200 δοκιμές Optuna

Σημασιολογική συνοχή στα αρχικά διανύσματα
Ποινές για υψηλό θόρυβο και κατακερματισμό

Μετεπεξεργασία και ονοματοδοσία

116 σε 107 συστάδες

Συγχώνευση όταν η ομοιότητα κεντροειδών υπερβαίνει το 0,92

96 αναθέσεις θορύβου


Από 2.107 μη ανατεθειμένα μηνύματα με αυστηρά κριτήρια ομοιότητας

TF-IDF και θέματα μηνυμάτων

**Χειροκίνητη ονοματοδοσία δύο επιπέδων
107 συστάδες και 16 κύριες θεματικές**

Ο όρος «ανεπίβλεπτη» αφορά την ανακάλυψη των συστάδων

Η τελική θεματική οργάνωση



107

συστάδες

16

κύριες θεματικές

14,7%
μη ανατεθειμένα

Οκτώ μεγαλύτερες κύριες θεματικές. Ο θόρυβος περιλαμβάνει 2.011 μηνύματα


Οι 16 κύριες θεματικές

Κύρια θεματική	Μηνύματα
Academic Events	3.596
University Administration	1.336
Campus Life	1.296
Labour & Union Affairs	1.047
Research & Funding	871
Elections & Governance	717
Health & Welfare	684
Infrastructure & Digital Services	462
Ανατεθειμένα	11.626

Κύρια θεματική	Μηνύματα
Informal Discussion	444
Postgraduate Programmes	362
Innovation & Entrepreneurship	257
University Rankings & Distinctions	193
Miscellaneous	179
Continuing Education	80
Gender Equality & Inclusion	69
International Programmes	33
Μη ανατεθειμένα	2.011

16 κύριες θεματικές, 11.626 ανατεθειμένα και 2.011 μη ανατεθειμένα μηνύματα

Οπτική εξέταση των συστάδων



Χρώματα ανά κύρια θεματική
Γκρι: μη ανατεθειμένα μηνύματα

13D σε 2D

60,7%
της διακύμανσης
στην προβολή

**Η εικόνα
αποτελεί
εργαλείο
εξερεύνησης**

Ποσοτική αξιολόγηση της λύσης

Μέθοδος	Σημασιολογική συνοχή	NPMI
Προτεινόμενη ροή	0,8111	0,2067
k-means, k = 107	0,7999	0,1892
Ward, k = 107	0,8005	0,1945

Υψηλότερες τιμές και στα δύο μέτρα

Η σύγκριση συνεκτιμά την κάλυψη και τη βελτιστοποίηση της προτεινόμενης ροής ως προς τη συνοχή

HDBSCAN: 85,3% ανάθεση. k-means και Ward: 100% ανάθεση


Ευαισθησία υπερπαραμέτρων

Διαταραχή	Συστάδες	Θόρυβος	Συνοχή
Βάση	116	15,5%	0,8126
n_neighbors –20%	132	19,3%	0,8163
n_components +20%	128	18,5%	0,8169
min_cluster_size –20%	154	18,4%	0,8189
min_cluster_size +20%	98	18,0%	0,8102

Μικρή μεταβολή συνοχής, μεγαλύτερη μεταβολή πλήθους συστάδων

Έλεγχος πριν από τη μετεπεξεργασία. Σταθερά min_dist και seed


COVID: η αιχμή του Μαρτίου 2020



67 μηνύματα τον Μάρτιο 2020

Συστάδες COVID-19: 190 μηνύματα το 2020. 2023: Ιαν-Ιουλ


Εκλογές: Θεσμικοί κύκλοι



Ιούλιος 2020: 124 μηνύματα στην εκλογική θεματική

Κύρια θεματική Elections & Governance. 2023: Ιαν-Ιούλ

Ευχές: επαναλαμβανόμενη κορυφή τον Δεκέμβριο



Δεκέμβριος: ετήσια κορυφή σε όλα τα πλήρη έτη 2018-2022

Ειδική θεματική της Campus Life, 125 μηνύματα. 2023: Ιαν-Ιούλ


Αναδιάρθρωση και ΤΕΙ: συγκέντρωση το 2019



187 από τα 254 μηνύματα εμφανίζονται το 2019

Μάρτιος 2019: 76 μηνύματα. Ειδική θεματική της University Administration. 2023: Ιαν-Ιούλ


Ακαδημαϊκή επικοινωνία μέσα στο έτος



Φεβρουάριος 32,7% και Ιούνιος 30,2%

Μερίδιο στη συνολική κίνηση ανά ημερολογιακό μήνα. Συνάθροιση πλήρων ετών 2018-2022


Μεταπτυχιακά: προσκλήσεις γύρω από το καλοκαίρι



Θερινή συγκέντρωση με μεταβολές στον μήνα κορύφωσης

324 μηνύματα. Μέγιστο: Ιούλιος 2018, 33 μηνύματα. 2023: Ιαν-Ιούλ

Μεταβολές στη σύνθεση της επικοινωνίας



Labour & Union Affairs: αύξηση περίπου 3,5 ποσοσטיαίων μονάδων

Μερίδιο κάθε θεματικής στην ετήσια κίνηση. Πλήρη έτη 2018-2022

Περιορισμοί

Κάλυψη και καθαρισμός

Ένα ιστορικό αρχείο επικοινωνίας
2023: μόνο Ιανουάριος-Ιούλιος
Περικοπή εισόδου στο 3,7% των
μηνυμάτων

Ανάθεση και ερμηνεία

14,7% μη ανατεθειμένα
Μερική ανθρώπινη επιθεώρηση
Μία σαφής ομάδα λόγω υπογραφής

Επικύρωση

Αξιολόγηση στο ίδιο σώμα, χωρίς εξωτερικό σύνολο ελέγχου
Περιγραφικά χρονικά μοτίβα, χωρίς τυπικό έλεγχο εποχικότητας
Ευαισθησία υπερπαραμέτρων με σταθερό seed

Μελλοντική αξιοποίηση

Πιλοτική υπηρεσία αναζήτησης και θεματικής πλοήγησης

Νέα μηνύματα

Ανάθεση σε γνωστά θέματα
Δυνατότητα επιστροφής «άγνωστο»
Χρονικά παράθυρα για νέα θέματα

Εξωτερική αξιολόγηση

Μεταγενέστερα δεδομένα
Ανθρώπινα ελεγμένο δείγμα
Έλεγχος νέων και επανεμφανιζόμενων
θεμάτων

Συμπεράσματα

13.637 μηνύματα

107 συστάδες

16 κύριες θεματικές

Αναγνωρίσιμα χρονικά μοτίβα
χωρίς χρονική πληροφορία στη συσταδοποίηση

Ερωτήσεις